

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN

KHOA CÔNG NGHỆ THÔNG TIN

BỘ MÔN THỊ GIÁC MÁY TÍNH

Phân đoạn hình ảnh y khoa

Môn: Thị giác máy tính

Thông tin Sinh viên:

23127165 - Nguyễn Hải Đăng

23127181 - Nguyễn Trần Quốc Duy

Giảng viên:

Thầy Võ Hoài Việt

Thầy Phạm Minh Hoàng

Thầy Phạm Thanh Tùng

Ngày 8 tháng 4 năm 2026



Mục lục

1	Tóm tắt	2
2	Tên đề tài	2
3	Mô hình Đề xuất	2
3.1	Tổng quan Mô hình	2
3.2	Chi tiết kiến trúc đề xuất	3
3.3	Pipeline 3 bước tự động	5
3.3.1	Bước 1 — Huấn luyện Teacher	5
3.3.2	Bước 2 — Structured Pruning & Blueprint	5
3.3.3	Bước 3 — Student Training với Distillation + Learnable Gating	6
3.4	Metrics đánh giá	6
4	Thực nghiệm Pipeline với Teacher UNetResNet152	6
4.1	Cấu Hình Thực Nghiệm	6
4.1.1	Dataset: CVC-ClinicDB	6
4.1.2	Cấu hình chạy thực nghiệm	7
4.2	Chi tiết về Metrics đánh giá	7
4.3	Kết Quả Training — Teacher (UNetResNet152)	7
4.3.1	Loss curve và convergence	7
4.3.2	Kết quả định tính Teacher — Visualization	8
4.3.3	Phân tích chi tiết 8 sample Teacher:	10
4.3.4	Tổng kết định lượng Teacher trên 8 samples hiển thị:	10
4.3.5	Nhận xét tổng quan Teacher	10
4.4	Kết Quả Training — Student (PGD-UNet)	10
4.4.1	Loss curve và dynamics của Student	10
4.4.2	Phân tích các Loss Components	11
4.4.3	Kết quả định tính Student	12
4.5	So Sánh Trực Tiếp: Teacher vs Student	14
4.5.1	Bảng so sánh case-by-case	14
4.5.2	Tổng kết định lượng 8 samples	14
4.6	Phân Tích Nguyên Nhân Suy Giảm	14
4.6.1	Hypothesis chính: Insufficient distillation epochs	14
4.6.2	Hypothesis phụ: Prune ratio 0.5 quá aggressive với CVC-ClinicDB	14
4.6.3	Hypothesis phụ: $\lambda_2 = 0.3$ quá lớn	14
4.6.4	Impact của hard pruning timing	15
4.7	Đề Xuất Cải Tiến dựa trên Kết Quả	15
5	So sánh PGD-UNet với các Baseline	16

1 Tóm tắt

Ung thư đại tràng là một trong những nguyên nhân gây tử vong hàng đầu do ung thư trên toàn thế giới. Phát hiện sớm polyp đại tràng qua nội soi là chiến lược phòng ngừa chủ yếu, tuy nhiên tỷ lệ bỏ sót polyp của bác sĩ có kinh nghiệm vẫn có thể vượt 20% do sơ suất của người chuẩn đoán và sự đa dạng về hình thái polyp. Các hệ thống phân đoạn ảnh tự động dựa trên deep learning đã đạt kết quả cao nhưng hầu hết quá nặng về mặt tính toán, không phù hợp triển khai thực tế trong phòng nội soi.

Nghiên cứu này đề xuất một phương pháp mới gồm 4 bước: (1) huấn luyện một mô hình Teacher mạnh (UNet + ResNet152); (2) áp dụng Structured Pruning có hướng dẫn để tìm ra kiến trúc tối ưu (blueprint); (3) xây dựng mô hình Student nhỏ gọn dựa trên blueprint đó; (4) huấn luyện Student với cơ chế Learnable Channel Gating kết hợp Knowledge Distillation và hàm mất mát tổng hợp ba thành phần ($L_{seg} + L_{distill} + L_{sparsity}$). Mục tiêu là đạt Dice $\sim 0.88 - 0.91$ với chỉ 3 – 5M tham số và tốc độ inference phù hợp thời gian thực.

Ở report này, chúng em sẽ chạy thực nghiệm toàn bộ pipeline của kiến trúc đề xuất với các Teacher Model: *ResidualUNet2D*, *UNetResNet152*, *UNet2D*, *UNETR2D*, *VNet2D* trên tập dữ liệu CVC-ClinicDB để so sánh và đánh giá chọn ra Teacher Model tốt nhất cho Student Model. Metrics bao gồm Dice, IoU, HD95, Params, FLOPs và FPS. Kết quả kỳ vọng đầy khoáng trống giữa các model nhẹ (BiSe-UNet: Dice 0.78, 2.5M) và các model nặng SOTA (Polyp-PVT: Dice 0.917, hàng chục triệu params).

2 Tên đề tài


Tối ưu kiến trúc UNet thông qua Pruning có hướng dẫn và Knowledge Distillation với Learnable Channel Gating cho phân đoạn Polyp Đại tràng trong thời gian thực

(**Tiêu đề tiếng Anh:** *Architecture-Aware Pruning and Knowledge Distillation with Learnable Channel Gating for Lightweight Real-Time Polyp Segmentation*)

3 Mô hình Đề xuất

3.1 Tổng quan Mô hình

Hình 1 mô tả tổng quan quy trình nghiên cứu toàn diện gồm 4 giai đoạn. Từ việc chuẩn bị dữ liệu (1), đề tài tập trung vào việc áp dụng Pruning trên mô hình Teacher để trích xuất blueprint tối ưu (2). Dựa vào đó, một Student nhỏ gọn được xây dựng và huấn luyện kết hợp cơ chế Learnable Gating cùng Knowledge Distillation (3), hướng tới kết quả đầu ra là một mô hình nhẹ, đạt chuẩn thời gian thực (4).



Hình 1: Tổng quan 4 bước pipeline của phương pháp đề xuất


- **(1) Data Input & Preprocessing:** Tiền xử lý và tăng cường 5 bộ dữ liệu nội soi (Kvasir-SEG, CVC-ClinicDB, ...).
- **(2) Built Pruned Skeleton:** Rút trích kiến trúc tối ưu (blueprint) từ Teacher thông qua Structured Pruning.
- **(3) Compression Training & Distillation:** Huấn luyện Student sử dụng Learnable Channel Gating và Hàm mất mát tổng hợp (L_{Total}).
- **(4) Evaluation & Output:** Suy luận và đánh giá toàn diện các metrics (Dice, IoU, FLOPs, FPS, ...).

Điểm khác biệt cốt lõi so với các nghiên cứu hiện có (BiSe-UNet, U-Net-MobileNetV2) là thay vì thiết kế kiến trúc lightweight theo cách thủ công, phương pháp này dùng dữ liệu để TỰ ĐỘNG tìm ra kiến trúc tối ưu qua pruning, sau đó dùng learnable gating để mô hình tiếp tục TỰ HỌC cần giữ hay bỏ kernel nào trong quá trình training.

3.2 Chi tiết kiến trúc đề xuất

Bước 1: Huấn luyện Teacher

Bước đầu sẽ chạy lần lượt các Teacher Model: ResidualUNet2D, UNetResNet152, UNet2D, UNETR2D, VNet2D trên CVC-ClinicDB, kết quả được freeze (không update weights) trong các bước sau.



Hình 2: Chi tiết kiến trúc Teacher $\rightarrow$ Student với Learnable Gate (minh hoạ tổng quan)

Bước 2: Structured Pruning $\rightarrow$ Blueprint

Áp dụng structured pruning trên Teacher để đánh giá độ quan trọng của từng filter/channel:

- **Tiêu chí (1) — L1 Norm:** $importance_i = \|W\|_1$, filter có norm nhỏ $\rightarrow$ ít đóng góp $\rightarrow$ ứng viên loại bỏ
- **Tiêu chí (2) — BatchNorm γ :** $importance_i = \|y\|_i$, giá trị nhỏ $\rightarrow$ scale feature map gần 0 $\rightarrow$ có thể loại bỏ

Sau khi sắp xếp theo importance, loại bỏ 50% channels thấp nhất ở mỗi layer. Kết quả là một **pruned blueprint** — ví dụ từ $[64 \rightarrow 128 \rightarrow 256 \rightarrow 512]$ thành $[32 \rightarrow 64 \rightarrow 128 \rightarrow 256]$. Blueprint này là trực tiếp khởi tạo cấu trúc Student, không phải thiết kế tay.

Bước 3: Xây dựng Student

Student được khởi tạo từ blueprint thu được ở bước 2. Khác biệt so với Teacher ở chỗ mỗi convolution block được bọc thêm một Learnable Gate:

$$gate_i = \text{sigmoid}(\alpha_i)$$

$$output = gate_i \times conv(x)$$

Trong đó α_i là tham số học được (scalar per channel), sigmoid đưa về khoảng (0,1). Khi $gate_i \approx 1$: kernel được giữ nguyên. Khi $gate_i \approx 0$: kernel bị tắt dần — tương đương pruning động trong quá trình training. Cơ chế này cho phép Student tự điều chỉnh kiến trúc của mình trong khi train, thay vì chỉ nhận blueprint cố định.

Bước 4: Huấn luyện Student với Distillation + Learnable Gating

Student được tối ưu đồng thời bằng hàm mất mát 3 thành phần:


$$L_{total} = L_{seg} + \lambda_1 \cdot L_{distill} + \lambda_2 \cdot L_{sparsity}$$

- $L_{seg} = \text{Dice Loss} + \text{Binary Cross-Entropy}$: đảm bảo segmentation chính xác, xử lý class imbalance (Dice) và cung cấp gradient ổn định (BCE).
- $L_{distill} = \|F_{student} - F_{teacher}\|_2$: student học bắt chước intermediate feature maps của teacher, giữ lại kiến trúc của model lớn.
- $L_{sparsity} = \sum |gate_i|$: áp các gate về gần 0 để tiếp tục sparse hóa model, kết hợp với blueprint từ bước 2.

Các siêu tham số λ_1 và λ_2 được xác định qua ablation study (grid search trong $\{0.1, 0.3, 0.5\}$). Kết quả ở báo cáo này thì được chạy với $\lambda_1 = \lambda_2 = 0.3$. Weights của Teacher được freeze hoàn toàn trong bước này.

3.3 Pipeline 3 bước tự động

PGD-UNet không phải một mô hình được thiết kế thủ công mà là kết quả của pipeline tự động hóa quá trình tối ưu kiến trúc:



Hình 3: Pipeline PGD-UNet: 3 bước Teacher → Pruning → Student với data flow

3.3.1 Bước 1 — Huấn luyện Teacher

Teacher là *UNetResNet152* (encoder ResNet152 pretrained ImageNet + decoder U-Net).

Loss:

$$L = 0.5 \times L_{CE} + 0.5 \times L_{Dice}$$

Teacher được train hoàn chỉnh trên CVC-ClinicDB và checkpoint best được lưu lại. Đây là nguồn prior knowledge cho toàn bộ pipeline.

3.3.2 Bước 2 — Structured Pruning & Blueprint

Phân tích Teacher để xác định channel nào quan trọng nhất tại mỗi stage. Tiêu chí đánh giá ưu tiên **BN scaling factor** γ (nếu có BatchNorm), fallback về **L1-norm** của filter. Kết quả là

`blueprint.json` — kiến trúc rút gọn cho Student, đồng thời transfer weight đã học từ Teacher vào Student theo `kept_channel_indices` (không phải random init).

3.3.3 Bước 3 — Student Training với Distillation + Learnable Gating

Student khởi đầu từ pruned weight của Teacher, được tinh chỉnh với loss tổng hợp 3 thành phần:

$$L_{\text{total}} = L_{\text{seg}} + \lambda_1 \times L_{\text{distill}} + \lambda_2 \times L_{\text{sarsity}}$$

Late hard pruning xảy ra ở cửa sổ epoch cuối dựa trên gate values đã học.

3.4 Metrics đánh giá

Các metrics đánh giá được sử dụng trong nghiên cứu bao gồm:

Metric	Nhóm	Ý nghĩa
Dice (DSC)	Accuracy	Primary metric chuẩn của field, độ overlap giữa prediction và ground truth
IoU (Jaccard)	Accuracy	Metric overlap bổ sung, luôn đi kèm Dice trong polyp segmentation
HD95	Boundary	Đo sai lệch tại viền, quan trọng với polyp hình dạng bất thường
Params (M)	Efficiency	Số tham số mô hình — core contribution của paper
FLOPs (G)	Efficiency	Chi phí tính toán — chứng minh lightweight
FPS	Efficiency	Tốc độ inference — chứng minh real-time feasibility (target ≥ 30 FPS)

Bảng 1: Các metrics đánh giá được sử dụng trong nghiên cứu

4 Thực nghiệm Pipeline với Teacher UNetResNet152

4.1 Cấu Hình Thực Nghiệm

4.1.1 Dataset: CVC-ClinicDB

CVC-ClinicDB là bộ dữ liệu nội soi đại tràng chuẩn, được tổ chức phối hợp bởi Hospital Clinic of Barcelona, Tây Ban Nha. Đặc điểm:

Thuộc tính	Chi tiết
Tổng số ảnh	612 frames nội soi đại tràng RGB
Nguồn gốc	29 video sequences từ các ca nội soi khác nhau
Độ phân giải	384×288 pixels
Annotation	Mask nhị phân pixel-level, annotated bởi chuyên gia
Đặc điểm khó	Polyp đa dạng kích thước (5px–200px), đa dạng texture, specular reflection
Split sử dụng	80% train (490 ảnh) / 10% val (61 ảnh) / 10% test (61 ảnh)

Thách thức đặc thù của CVC-ClinicDB: CVC-ClinicDB có đặc điểm khó hơn Kvasir-SEG ở chỗ các ảnh được trích xuất từ video sequences liên tục, nhiều frame liên tiếp có appearance tương tự nhưng mask annotation khác nhau nhỏ. Điều này tạo ra data leakage risk nếu không split cẩn thận theo sequence, và cũng giải thích một phần các trường hợp Dice thấp trong kết quả.

4.1.2 Cấu hình chạy thực nghiệm

Hyperparameter	Teacher	Student
Architecture	UNetResNet152 (ResNet152 encoder)	PGD-UNet (channel_config từ blueprint)
Epochs	50	50
Optimizer	SGD (momentum=0.9, wd=1e-4)	AdamW ($\beta_1 = 0.9$, $\beta_2 = 0.999$)
Learning rate	0.01 (poly decay)	1e-4 (CosineAnnealingLR)
Batch size	8	8
Input size	256×256 px	256×256 px
Prune ratio	—	0.5
λ_1 (distillation)	—	0.3
λ_2 (sparsity)	—	0.3
Student variant	—	full (distill + gate + sparsity)
Seed	1337	1337


4.2 Chi tiết về Metrics đánh giá

Metric	Ký hiệu	Công thức / Ý nghĩa
Dice Similarity Coefficient	DSC $\uparrow$	$\frac{2 P \cap G }{ P + G }$ — overlap chính
Intersection over Union	IoU $\uparrow$	$\frac{\text{DSC}}{2 - \text{DSC}}$ — bổ sung cho Dice
Hausdorff Distance 95th	HD95 $\downarrow$	khoảng cách boundary 95th percentile
Parameters	M $\downarrow$	Tổng trainable params ($\times 10^6$)
FLOPs	G $\downarrow$	Multiply-Accumulate Ops ($\times 10^9$)
Inference time	ms/img $\downarrow$	Thời gian xử lý 1 ảnh trên GPU

4.3 Kết Quả Training — Teacher (UNetResNet152)

4.3.1 Loss curve và convergence

Từ hình bên dưới, có thể quan sát quá trình training Teacher trên CVC-ClinicDB:



Hình 4: Teacher training: Loss curve và val_macro_dice qua 50 epochs

Mô tả hình:

- **train_total_loss** (xanh dương) giảm từ ~ 0.3 về ~ 0.03
- **val_total_loss** (cam) giảm song song
- **val_macro_dice** (xanh lá) tăng từ ~ 0.5 lên $\sim 0.9+$


Convergence tốt sau ~ 30 epochs.

Phân tích Teacher loss curve:

- **Tốc độ convergence:** Loss giảm nhanh trong 10 epoch đầu (SGD + poly decay hiệu quả), sau đó ổn định dần từ epoch 25–30.
- **val_macro_dice:** Tăng ổn định và đạt plateau sau 35 epochs, cho thấy không có overfitting đáng kể trong 50 epochs.
- **Train-val gap:** Gap nhỏ giữa **train_total_loss** và **val_total_loss** thể hiện model generalize tốt trên val set, một phần nhờ ResNet152 pretrained.
- **Convergence pattern:** Loss curve mượt, không dao động mạnh, SGD với poly LR decay phù hợp với bài toán segmentation này.

4.3.2 Kết quả định tính Teacher — Visualization

Đây là 8 sample của test set của CVC-ClinicDB được đánh giá bởi Teacher UNetResNet152. Kết quả visualization thể hiện rõ khả năng của Teacher:



Hình 5: Teacher test visualization: 8 samples (Image | GT | Prediction | Dice)

Mô tả hình: 8 hàng, mỗi hàng 3 panel: ảnh nội soi gốc, ground truth mask (màu đỏ/hồng), prediction mask. Dice score ghi trên mỗi prediction.

4.3.3 Phân tích chi tiết 8 sample Teacher:

Sample	Dice Teacher	Nhận xét phân tích
Image (4)	0.9785	Polyp lớn, màu sắc tương phản rõ — Teacher phân đoạn gần như hoàn hảo, boundary rõ nét.
Image (6)	0.9603	Polyp trung bình với hình dạng phức tạp — Teacher capture được đúng hình dạng, minimal false positive.
Image (15)	0.6921	Polyp lớn, texture giống niêm mạc — Teacher phân đoạn bị phân mảnh (fragmented), có false negative vùng trung tâm.
Image (23)	0.8355	Polyp nhỏ trên nền sáng — Teacher phát hiện đúng nhưng boundary bị over-segment nhẹ.
Image (25)	0.4404	Polyp lớn với specular reflection mạnh — Đây là hard case: texture polyp gần giống mô xung quanh. Teacher bị false negative nặng.
Image (28)	0.9429	Đa polyp (2 polyp nhỏ) — Teacher phát hiện và phân đoạn chính xác cả 2, shape đúng.
Image (32)	0.9689	Polyp tròn, màu sắc đặc trưng — Phân đoạn xuất sắc, prediction gần như khớp GT.
Image (35)	0.9565	Polyp nhỏ-trung bình — Teacher phát hiện chính xác, có một chút false positive nhỏ ở rìa.

4.3.4 Tổng kết định lượng Teacher trên 8 samples hiển thị:

- Mean Dice (8 samples): $\frac{(0.9785+0.9603+0.6921+0.8355+0.4404+0.9429+0.9689+0.9565)}{8} = 0.8469$
- Samples tốt (Dice ≥ 0.90): 5/8 samples = 62.5%
- Samples trung bình ($0.70 \leq \text{Dice} < 0.90$): 2/8 samples = 25%
- Samples khó (Dice < 0.70): 1/8 samples = 12.5% (Image 25 — specular reflection)

4.3.5 Nhận xét tổng quan Teacher


Teacher UNetResNet152 thể hiện hiệu suất tốt trên đa số cases. Điểm yếu tập trung ở:

- Polyp có texture tương đồng với niêm mạc xung quanh (Image 15, 25) — ResNet152 dù mạnh vẫn bị nhầm do thiếu context toàn cục;
- Specular reflection làm nhiễu đặc trưng màu sắc (Image 25). Đây là "hard case" mang tính đặc thù của CVC-ClinicDB.

4.4 Kết Quả Training — Student (PGD-UNet)

4.4.1 Loss curve và dynamics của Student

Quá trình training Student trên CVC-ClinicDB có thể quan sát được nhiều hơn Teacher do Student có đến 13 tracked metrics:



Hình 6: Student training: Loss curves, gate dynamics và val_macro_dice qua 50 epochs

Mô tả hình:

- `train_total_loss`, `train_segmentation_loss`, `train_distillation_loss`, `train_sparsity_loss` (đường solid)
- `val_total_loss`, `val_macro_dice`, `epoch_gate_mean`, `epoch_gate_near_off_ratio`, `epoch_lambda_distill`, `epoch_lambda_sparsity` (đường dash)

4.4.2 Phân tích các Loss Components

- **`train_total_loss` và `val_total_loss`:** Loss tổng giảm từ ~ 2 về gần 0.4 trong 50 epochs. Đáng chú ý là loss ban đầu cao (~ 2) so với Teacher (~ 0.3) — điều này bình thường vì L_{total} bao gồm cả $L_{distill}$ và $L_{sparsity}$. `val_total_loss` song song với train, cho thấy không overfitting trong khoảng epoch quan sát được.
- **`train_segmentation_loss` và `val_segmentation_loss`:** Component quan trọng nhất — giảm nhanh trong 10 epoch đầu (Student đang học cơ bản từ ground truth), sau đó ổn định. `val_seg` thường cao hơn `train_seg` một chút — hành vi bình thường của regularization từ sparsity loss.
- **`train_distillation_loss`:** Giảm dần qua epochs phản ánh Student đang học xấp xỉ logits của Teacher ngày càng tốt hơn. Distillation loss chỉ giảm dần về ~ 0.9 — điều này tốt vì nếu về 0 có nghĩa Student chỉ copy Teacher mà không học từ GT.

- **train_sparsity_loss**: Xu hướng của $L_{\text{sparsity}} = \sum |\text{gate}|$ phản ánh trực tiếp tổng gate values. Nếu L_{sparsity} giảm $\rightarrow$ gate values trung bình đang giảm $\rightarrow$ soft pruning đang xảy ra. Cần đối chiếu với `epoch_gate_mean` để xác nhận.

4.4.3 Kết quả định tính Student


Student PGD-UNet cũng được đánh giá trên đúng 8 sample test giống Teacher. Điều này cho phép so sánh trực tiếp case-by-case:

Nhận xét

Về mặt định tính, mô hình student vẫn cho kết quả tốt trên một số mẫu tương đối đơn giản, chẳng hạn các ảnh có hệ số Dice cao như Image (4) với Dice = 0.9711, Image (32) với Dice = 0.9105 và Image (35) với Dice = 0.8526.

Tuy nhiên, ở những trường hợp khó hơn, đặc biệt khi vùng tổn thương có biên phức tạp hoặc hình dạng không đều, mô hình thường xuất hiện hiện tượng dự đoán thiếu vùng hoặc phân mảnh đối tượng, thể hiện rõ ở các ảnh như Image (15), Image (23) và đặc biệt là Image (25). Mặc dù mô hình teacher cũng gặp khó khăn ở các trường hợp này, teacher vẫn giữ được nhiều thông tin không gian và hình dạng hơn, trong khi student bị suy giảm rõ rệt về khả năng tái tạo vùng mục tiêu.

Điều này cho thấy mô hình student vẫn chưa bảo toàn tốt các đặc trưng ngữ nghĩa và đặc trưng biên quan trọng sau quá trình pruning, nhất là đối với các mẫu có cấu trúc phức tạp hoặc vùng tổn thương lớn. Từ đó, một hướng phát triển tiếp theo là thử nghiệm các hàm loss có khả năng ràng buộc mạnh hơn lên thông tin biên và hình dạng, nhằm cải thiện chất lượng phân đoạn trong các trường hợp khó.



Hình 7: Student test visualization: 8 samples (Image | GT | Prediction | Dice)

4.5 So Sánh Trực Tiếp: Teacher vs Student

4.5.1 Bảng so sánh case-by-case

Bảng dưới đây so sánh trực tiếp Dice của Teacher và Student trên 8 sample test, rút ra từ các visualization files:

Sample	Dice Teacher	Dice Student	Delta (S-T)	Phân tích
Image (4)	0.9785	0.9711	$0.0074 \approx 0$	Student duy trì gần như tương đương. Polyp lớn rõ ràng — cả hai model đều xử lý tốt.
Image (6)	0.9603	0.8033	$0.1570 \downarrow$	Student suy giảm đáng kể. Polyp trung bình phức tạp — Student mất chi tiết boundary sau pruning.
Image (15)	0.6921	0.3938	$0.2983 \downarrow\downarrow$	Suy giảm nặng nhất. Hard case: Student bị fragmentation nghiêm trọng hơn Teacher.
Image (23)	0.8355	0.4616	$0.3739 \downarrow\downarrow$	Suy giảm rất mạnh. Student phân mảnh prediction thành nhiều đốm nhỏ thay vì vùng liên tục.
Image (25)	0.4404	0.1706	$0.2698 \downarrow\downarrow$	Cả hai đều kém (hard case), nhưng Student tệ hơn đáng kể. Ít channel sau pruning → kém robust.
Image (28)	0.9429	0.8577	$0.0852 \downarrow$	Suy giảm nhẹ-vừa. Đa polyp nhỏ — Student vẫn phát hiện cả 2, nhưng boundary kém hơn.
Image (32)	0.9689	0.9105	$0.0584 \approx 0$	Suy giảm nhẹ. Polyp tròn đặc trưng — Student vẫn perform tốt.
Image (35)	0.9565	0.8526	$0.1039 \downarrow$	Suy giảm vừa. Student false positive tăng nhẹ ở rìa polyp.

4.5.2 Tổng kết định lượng 8 samples

Metric	Teacher	Student	Delta	Đánh giá
Mean Dice	0.8469	0.6777	-0.1692	Giảm ~16.9 điểm - cao hơn mong đợi
Max Dice	0.9785 (Img 4)	0.9711 (Img 4)	-0.0074	Tốt - peak performance gần như duy trì
Min Dice	0.4404 (Img 25)	0.1706 (Img 25)	-0.2698	Hard cases bị ảnh hưởng nặng nhất
Std Dice	0.183	0.285	+0.102	Student kém ổn định hơn - variance cao hơn
Samples Dice ≥ 0.9	5/8 (62.5%)	2/8 (25%)	-3 samples	Giảm mạnh ở các case trung bình
Samples Dice < 0.5	1/8 (12.5%)	3/8 (37.5%)	-2 samples	Nhiều hard cases hơn sau pruning

4.6 Phân Tích Nguyên Nhân Suy Giảm

4.6.1 Hypothesis chính: Insufficient distillation epochs

Student chỉ được train 50 epochs bằng với Teacher. Tuy nhiên, task của Student khó hơn nhiều: không chỉ học từ GT như Teacher, mà còn phải đồng thời:

- (1) minimize L_{seg} ,
- (2) khớp logits Teacher (L_{distill}),
- (3) học gate distribution tối ưu (L_{sparsity}).

Ba objective này cạnh tranh nhau, đặc biệt trong giai đoạn đầu training khi gate chưa ổn định. 50 epochs có thể chưa đủ để Student tìm được equilibrium tốt.

4.6.2 Hypothesis phụ: Prune ratio 0.5 quá aggressive với CVC-ClinicDB

CVC-ClinicDB chỉ có 490 ảnh train — nhỏ hơn đáng kể so với Kvasir-SEG (800 ảnh). Với dataset nhỏ, mô hình cần nhiều capacity hơn để generalize tốt. Prune ratio 0.5 cắt bỏ 50% channel ở mỗi stage với dataset nhỏ như CVC-ClinicDB, mỗi channel đều có đóng góp lớn hơn so với dataset lớn. Cần thử `prune_ratio = 0.3` để xem có cải thiện không.

4.6.3 Hypothesis phụ: $\lambda_2 = 0.3$ quá lớn

L_{sparsity} với $\lambda_2 = 0.3$ tạo áp lực lớn ép gate về 0. Quan sát từ hình 6, nếu `train_sparsity_loss` giảm nhanh → `gate_mean` giảm mạnh → nhiều channel bị tắt trước khi Student kịp học từ Teacher. Giá trị $\lambda_2 = 0.01$ hoặc 0.05 sẽ an toàn hơn cho dataset nhỏ, đặc biệt trong giai đoạn đầu training.

4.6.4 Impact của hard pruning timing

warmup_pruning_epochs mặc định = 4 có nghĩa hard pruning xảy ra tại epoch 46 ($50 - 4 = 46$). Sau epoch 46, compact student chỉ còn 4 epochs để fine-tune — quá ít. Với một số hard cases phức tạp, Student cần nhiều hơn để recover sau hard pruning event. Tăng max_epochs_student lên 100 hoặc tăng warmup_pruning_epochs lên 15–20 sẽ cho Student nhiều thời gian recover hơn.

4.7 Đề Xuất Cải Tiến dựa trên Kết Quả

Dựa trên phân tích định tính 8 samples và loss dynamics, chúng em đề xuất các điều chỉnh sau cho các thực nghiệm tiếp theo:

Điều chỉnh	Giá trị hiện tại	Đề xuất mới	Lý do kỳ vọng cải thiện
max_epochs	50	100–150	Teacher cần nhiều epochs hơn để đạt được hiệu suất tốt nhất
max_epochs_student	50	100–150	Student cần nhiều epochs hơn để balance 3 objectives
prune_ratio	0.5	0.3–0.35	CVC-ClinicDB nhỏ, cần giữ nhiều channel hơn
λ_2 (sparsity)	0.3	0.01–0.05	Giảm áp lực pruning, ưu tiên accuracy hơn sparsity
warmup_pruning_epochs	4	15–20	Student cần nhiều epoch hơn để recover sau hard prune
student_variant	full	pruned_distill (ablation)	Test xem bỏ gate có giúp stable hơn không

Về việc cải tiến loss

Mặc dù mô hình Student đã đạt được những kết quả khá tốt trong hầu hết các trường hợp, tuy nhiên, một số khó khăn vẫn tồn tại, đặc biệt là khi làm việc với các mẫu có cấu trúc phức tạp hoặc vùng tổn thương lớn. Cụ thể, mô hình Student vẫn chưa bảo toàn tốt các đặc trưng ngữ nghĩa và đặc trưng biên quan trọng sau quá trình pruning, dẫn đến giảm hiệu suất trong các trường hợp như polyp có texture phức tạp hoặc có sự phản chiếu specular (Image 15, Image 25).

Điều này cho thấy rằng trong giai đoạn pruning, mô hình Student có thể mất đi những đặc trưng quan trọng, ảnh hưởng đến khả năng phân đoạn chính xác, đặc biệt là đối với vùng biên và hình dạng của các đối tượng trong ảnh. Từ đó, một hướng phát triển tiếp theo là thử nghiệm các hàm loss có khả năng ràng buộc mạnh hơn lên thông tin biên và hình dạng, nhằm cải thiện chất lượng phân đoạn trong các trường hợp khó.

Một số loss function có thể giúp tăng cường khả năng phân đoạn vùng biên và cải thiện accuracy, bao gồm:

- **Dice Loss với vùng biên:** Bổ sung một trọng số cho vùng biên trong Dice Loss, giúp mô hình chú ý nhiều hơn vào các cạnh của đối tượng, vốn thường dễ bị mất trong quá trình pruning.
- **Boundary Loss:** Hàm loss này có thể được sử dụng để cải thiện độ chính xác của mô hình trong việc phân đoạn các biên, giúp mô hình học được các đặc trưng biên tốt hơn.
- **Tversky Loss:** Tversky Loss có thể được sử dụng để cải thiện các mẫu với imbalance giữa foreground và background, và có thể đặc biệt hữu ích trong việc phân đoạn polyp có cấu trúc phức tạp.
- **Focus Loss:** Hàm loss này làm cho mô hình tập trung vào các vùng khó phân đoạn hơn, bao gồm các vùng biên và các chi tiết nhỏ mà mô hình dễ bỏ qua.

5 So sánh PGD-UNet với các Baseline

Bảng 2: Hiệu quả phân đoạn trên tập dữ liệu thử nghiệm CVC

Model	Encoder	Dice $\uparrow$	IoU $\uparrow$	HD95 $\downarrow$	Params (M) $\downarrow$	FLOPs (G) $\downarrow$	FPS $\uparrow$	Inf. (s) $\downarrow$
vnet	VNet	0.7803	0.6836	41.2463	3.2688	3.7602	<u>117.3666</u>	<u>0.0085</u>
unetr	ViT	0.7493	0.6417	63.7157	46.9020	67.1036	16.2551	0.0615
unet	2-block conv	<u>0.8355</u>	<u>0.7590</u>	<u>33.2968</u>	7.2404	12.2238	111.8670	0.0089
resunet	Residual + 1×1 skip	0.8148	0.7195	50.3967	32.4364	57.5029	66.3961	0.0151
unet_resnet152 (teacher)	ResNet152	0.9092	0.8452	15.4636	151.0614	33.6251	66.0311	0.0151
PGD_Unet (student) - ours	gated + pruning	0.7341	0.6350	41.0482	1.9458	<u>5.2800</u>	210.6800	0.0047

Nhận xét

Kết quả cho thấy *PGD-Unet (Student) - ours* có lợi thế lớn về độ gọn nhẹ và tốc độ suy luận, khi đạt số tham số thấp nhất và FPS cao nhất trong các mô hình được so sánh. Tuy nhiên, hiệu năng phân đoạn của mô hình hiện vẫn còn khá thấp. Một nguyên nhân khả dĩ là cơ chế *pruning* tại bước 3 ở phần sau của mạng chưa được thiết kế đủ hiệu quả và chưa tận dụng tốt kiến thức của **teacher - unet_resnet152**, khiến một số đặc trưng quan trọng bị loại bỏ trong quá trình nén mô hình. Vì vậy, trong các hướng phát triển tiếp theo, cần có cơ chế kiểm soát *pruning* chặt chẽ hơn và tận dụng tốt thông tin hơn để cải thiện khả năng giữ lại thông tin hữu ích, từ đó nâng cao chất lượng phân đoạn mà vẫn duy trì được ưu thế về hiệu quả tính toán.