

# Bài tập Computer Vision Lab-02

Phân tích thống kê bộ dữ liệu MNIST Handwritten, Fashion và Medical

Báo cáo này trình bày phân tích thống kê chi tiết của ba bộ dữ liệu MNIST: chữ viết tay, thời trang và y khoa. Đối với mỗi bộ dữ liệu, báo cáo làm rõ bài toán được giải quyết, cấu trúc dữ liệu, phân bố lớp, các đặc trưng thống kê về pixel, và các tính chất đặc biệt. Phần cuối so sánh ba bộ dữ liệu theo nhiều tiêu chí.

## I. Phân tích MNIST Handwritten

**Bài toán:** Nhận dạng chữ số viết tay (Optical Character Recognition – OCR). Ứng dụng thực tế bao gồm đọc số tài khoản ngân hàng, mã bưu chính, số hoá biểu mẫu. MNIST là benchmark kinh điển của thị giác máy tính, hiện được coi là đã "giải quyết" với độ chính xác SotA > 99.7%.

**Nguồn gốc:** Được tạo ra năm 1998 bởi Yann LeCun, Corinna Cortes và Christopher J.C. Burges dựa trên dữ liệu viết tay của NIST. Khoảng 250 người viết (nhân viên cục điều tra dân số và học sinh trung học) đóng góp mẫu.

### 1.1 Thông tin tổng quan

| Thuộc tính                 | Thông tin chi tiết                          |
|----------------------------|---------------------------------------------|
| Số mẫu                     | 70.000 ảnh (Train: 60.000   Test: 10.000)   |
| Số lớp                     | 10 lớp (các chữ số 0–9)                     |
| Kích thước ảnh             | 28 × 28 pixels (784 pixels/ảnh)             |
| Loại ảnh                   | Grayscale (1 kênh màu)                      |
| Pixel trung bình           | 33,39 / 255                                 |
| Độ lệch chuẩn pixel        | 78,65                                       |
| Độ thưa (% = 0)            | 80,9% — tỉ lệ pixel nền cao nhất trong 3 bộ |
| Độ lệch phân bố (Skewness) | 2,20 — phân bố lệch phải mạnh               |
| Tỉ lệ mất cân bằng         | 1,25× (Digit 1: 7.877 ↔ Digit 5: 6.313)     |
| Độ chính xác SotA          | > 99,7%                                     |


### 1.2 Phân bố lớp

Phân bố tương đối đều với tỉ lệ mất cân bằng 1,25×. Chữ số 1 xuất hiện nhiều nhất (7.877 mẫu), chữ số 5 ít nhất (6.313 mẫu). Do các chữ số được thu thập từ nhiều người viết khác nhau, hình dạng trong cùng một lớp có thể biến thiên đáng kể về kích thước, góc nghiêng và độ dày nét.




Hình 1: Phân bố số lượng mẫu theo lớp — MNIST Handwritten (tỉ lệ mất cân bằng 1,25×)

### 1.3 Ảnh mẫu theo lớp (Prototype & Random Samples)



Hình 3: Ảnh prototype (trung bình pixel theo lớp) — topology của từng chữ số hiện rõ




Hình 4: 8 mẫu ngẫu nhiên mỗi lớp — biến thiên nội lớp do ~250 phong cách viết khác nhau

### 1.4 Phương sai nội lớp & Điểm khó (CoV)

**Chỉ số Coefficient of Variation (CoV = std/mean)** đo mức độ biến thiên của phân bố pixel trong cùng một lớp. CoV càng cao → lớp đó càng khó học.

**Khó nhất — Digit 1 (CoV ≈ 3,2):** Dù hình học đơn giản, "1" được viết theo nhiều kiểu: đứng thẳng, nghiêng, có/không có chân, độ dày khác nhau.

**Dễ nhất — Digit 0 (CoV ≈ 2,0):** Hình bầu dục nhất quán cao; ảnh độ lệch chuẩn (std image) cho thấy đường viền sáng đều — biến thiên tập trung ở viền ngoài.




Hình 5: Điểm khó theo lớp (CoV) — Digit 1 khó nhất dù hình học đơn giản nhất

### 1.5 Độ tương đồng giữa các lớp (Cosine Similarity)

Ma trận cosine similarity giữa các prototype lớp cho thấy các cặp dễ nhầm lẫn nhất. Đây là proxy đo nguy cơ nhầm lẫn của bộ phân loại tại cấp độ không gian pixel.

| Cặp lớp dễ nhầm | Cosine Sim. | Lý do                                 |
|-----------------|-------------|---------------------------------------|
| 4 ↔ 9           | 0,93        | Cùng có vòng trên và nét xuống dưới   |
| 3 ↔ 5           | 0,91        | Cấu trúc đường cong đối xứng tương tự |
| 8 ↔ 9           | 0,86        | Cùng có vòng trên, khác phần dưới     |



Hình 6: Ma trận cosine similarity giữa prototype các lớp — MNIST Handwritten (trái)

## II. Phân tích MNIST Fashion

**Bài toán:** Phân loại loại quần áo/phụ kiện từ ảnh sản phẩm (Clothing Classification). Ứng dụng thực tế: gắn tag tự động cho catalog thương mại điện tử, tìm kiếm sản phẩm theo hình ảnh, gợi ý thời trang. Fashion MNIST được thiết kế là bộ thay thế trực tiếp (drop-in replacement) cho MNIST Handwritten.


**Nguồn gốc:** Được tạo năm 2017 bởi Han Xiao, Kashif Rasul và Roland Vollgraf tại Zalando Research — công ty thương mại điện tử thời trang lớn nhất châu Âu. Ảnh lấy từ sản phẩm thực trên Zalando.com, được cắt, resize và chuyển thành grayscale.

### 2.1 Thông tin tổng quan

| Thuộc tính                 | Thông tin chi tiết                                                                            |
|----------------------------|-----------------------------------------------------------------------------------------------|
| Số mẫu                     | 70.000 ảnh (Train: 60.000   Test: 10.000)                                                     |
| Số lớp                     | 10 lớp (T-shirt/top, Trouser, Pullover, Dress, Coat, Sandal, Shirt, Sneaker, Bag, Ankle boot) |
| Kích thước ảnh             | 28 × 28 pixels (784 pixels/ảnh)                                                               |
| Loại ảnh                   | Grayscale (1 kênh màu)                                                                        |
| Pixel trung bình           | 72,97 / 255                                                                                   |
| Độ lệch chuẩn pixel        | 90,00 — cao nhất trong 3 bộ                                                                   |
| Độ thừa (% = 0)            | 50,2%                                                                                         |
| Độ lệch phân bố (Skewness) | 0,69 — phân bố đối xứng nhất trong 3 bộ                                                       |
| Tỉ lệ mất cân bằng         | 1,00× — hoàn toàn cân bằng (mỗi lớp đúng 7.000 mẫu)                                           |
| Độ chính xác SotA          | ~96,7% (Human accuracy: ~83,5%)                                                               |

## 2.2 Phân bố lớp

Fashion MNIST là bộ dữ liệu duy nhất trong ba bộ có phân bố hoàn toàn cân bằng (1,00×): mỗi lớp có đúng 6.000 mẫu train và 1.000 mẫu test. Đây là quyết định thiết kế có chủ ý của Zalando Research để loại bỏ yếu tố mất cân bằng ra khỏi kết quả benchmark.



Hình 8: Phân bố tỉ lệ lớp — Fashion MNIST cân bằng tuyệt đối 10,0% mỗi lớp

## 2.3 Phân bố pixel

So với MNIST Handwritten, định tại pixel = 0 nhỏ hơn nhiều (~50% sparsity). Giá trị pixel trải rộng đều hơn trên toàn dải 0–255, phản ánh texture vải, gradient bề mặt và nền ảnh đa dạng. Đây là lý do độ lệch (skewness = 0,69) thấp nhất và độ lệch chuẩn (90,00) cao nhất.

## 2.4 Ảnh mẫu theo lớp



Hình 9: Ảnh prototype các lớp — nhóm Tops (T-shirt, Pullover, Coat, Shirt) rất giống nhau về silhouette



Hình 10: 8 mẫu ngẫu nhiên mỗi lớp — cùng lớp "Shirt" có thể gồm ngắn tay, dài tay, kẻ sọc, trơn

## 2.5 Phương sai nội lớp & Điểm khó (CoV)

**Khó nhất — Sandal (CoV  $\approx 2,05$ ):** Bao gồm sandal bằng phẳng, cao gót, đế nền, quai mảnh — hình dạng rất đa dạng trong cùng nhãn.

**Dễ nhất — Trouser (CoV  $\approx 0,9$ ):** Silhouette chữ Y hai ống quần nhất quán cao qua các mẫu.

**Bag (phương sai nội lớp  $\sim 5.100$ ):** Cao nhất trong tất cả các lớp của 3 bộ — túi xách có hình dạng và texture cực kỳ đa dạng.

## 2.6 Tại sao Fashion MNIST khó hơn Handwritten?

**1. Phương sai nội lớp cao:** Cùng nhãn "Shirt" bao gồm áo ngắn tay, dài tay, kẻ sọc, trơn, oversized. Phương sai nội lớp trung bình của Shirt  $\approx 4.000$ .

**2. Độ tương đồng liên lớp cao:** Nhóm "Tops" (T-shirt/top, Pullover, Coat, Shirt) có cosine similarity 0,90–0,99 giữa các prototype. Sau khi chuyển grayscale và resize về  $28 \times 28$ , silhouette Pullover và Coat gần như không phân biệt được.

**3. Đặc trưng texture vs. cạnh:** CNN phải học đặc trưng texture bề mặt (vân vải, gradient bóng đổ) thay vì chỉ phát hiện cạnh và topo như với chữ số. Human accuracy chỉ đạt 83,5% phản ánh độ khó thực sự.

## 2.7 Độ tương đồng giữa các lớp (Cosine Similarity)

| Cặp lớp dễ nhầm                     | Cosine Sim. | Lý do                                      |
|-------------------------------------|-------------|--------------------------------------------|
| Coat $\leftrightarrow$ Shirt        | 0,99        | Silhouette rất giống, chỉ khác độ dày vải  |
| Pullover $\leftrightarrow$ Coat     | 0,98        | Cùng tay dài, khác độ phủ thân áo          |
| Shirt $\leftrightarrow$ T-shirt/top | 0,95        | Đường viền giống nhau, khác chi tiết cổ áo |

# III. Phân tích MNIST Medical

**Bài toán:** Phân loại ảnh y khoa theo vùng cơ thể và phương thức chụp (Medical Image Routing). Đây là bước đầu tiên trong pipeline AI y tế tự động: trước khi chạy mô hình phát hiện bệnh lý, hệ thống cần xác định loại ảnh đang xử lý. Ứng dụng: phân loại tự động ảnh tại khoa cấp cứu, định tuyến đến bác sĩ chuyên khoa phù hợp, kiểm soát chất lượng trong hệ thống PACS.

**Tính chất đặc biệt:** Khác với hai bộ trên, Medical MNIST mang rủi ro lâm sàng trực tiếp — kết quả âm tính giả (bỏ sót bệnh) nguy hiểm hơn nhiều so với dương tính giả. Mô hình cần tối ưu recall thay vì accuracy tổng thể.

## 3.1 Thông tin tổng quan

| Thuộc tính               | Thông tin chi tiết                                               |
|--------------------------|------------------------------------------------------------------|
| Số mẫu                   | 58.954 ảnh (ít hơn 2 bộ trên $\sim 11.000$ mẫu)                  |
| Số lớp                   | 6 lớp từ 3 phương thức chụp (CT, MRI, X-Ray)                     |
| Kích thước ảnh           | $28 \times 28$ pixels (chuẩn hoá từ ảnh gốc lớn hơn)             |
| Loại ảnh                 | Grayscale (1 kênh màu)                                           |
| Pixel trung bình         | 91,37 / 255 — cao nhất trong 3 bộ                                |
| Độ lệch chuẩn pixel      | 70,03                                                            |
| Độ thừa (% = 0)          | 9,7% — thấp nhất, gần như mọi pixel đều mang thông tin giải phẫu |
| Entropy pixel trung bình | 8,20 bits — thông tin phong phú nhất mỗi pixel                   |


|                    |                                                    |
|--------------------|----------------------------------------------------|
| Tỉ lệ mất cân bằng | 1,12× (BreastMRI: 8.954 ↔ các lớp còn lại: 10.000) |
| Độ chính xác SotA  | ~90–95%                                            |

### 3.2 Chi tiết các lớp


| Lớp       | Phương thức | Số mẫu | Mô tả                                           |
|-----------|-------------|--------|-------------------------------------------------|
| AbdomenCT | CT          | 10.000 | CT scan vùng bụng — mặt cắt ngang (axial slice) |
| BreastMRI | MRI         | 8.954  | MRI tuyến vú — mô mềm, contrast T1/T2           |
| ChestCT   | CT          | 10.000 | CT scan lồng ngực — mặt cắt ngang phổi          |
| CXR       | X-Ray       | 10.000 | X-quang ngực thẳng — xương sườn, phổi nổi bật   |
| Hand      | X-Ray       | 10.000 | X-quang bàn tay — cấu trúc xương ngón tay       |
| HeadCT    | CT          | 10.000 | CT scan não — mặt cắt ngang vòm đầu             |

Bảng: Chi tiết 6 lớp trong Medical MNIST — BreastMRI ít mẫu nhất và khó phân loại nhất

### 3.3 Ảnh mẫu theo lớp



Hình 12: Ảnh prototype 6 lớp — CT tạo mặt cắt tròn, MRI mô mềm, X-Ray nổi bật xương



Hình 13: 8 mẫu ngẫu nhiên mỗi lớp — cùng lớp AbdomenCT biến thiên theo bệnh nhân

3.4 Thách thức đa phương thức (Multi-Modality)

| Phương thức                     | Nguyên lý vật lý                         | Đặc trưng pixel                                    |
|---------------------------------|------------------------------------------|----------------------------------------------------|
| CT (AbdomenCT, ChestCT, HeadCT) | Tia X xoay 360°, tạo mặt cắt ngang       | Xương/gan sáng (HU cao), không khí tối             |
| MRI (BreastMRI)                 | Từ trường + sóng radio, không dùng tia X | Contrast mô mềm; mỡ và nước cho tín hiệu khác nhau |
| X-Ray (CXR, Hand)               | Chiếu tia X phẳng 2D                     | Xương sáng, không khí phổi tối, cấu trúc dẹt       |

**Vấn đề:** khi resize về 28×28, thông tin về tỉ lệ, đơn vị Hounsfield và hướng thu hình bị mất. ChestCT và CXR cùng chụp ngực nhưng trông hoàn toàn khác ở cấp độ pixel — mô hình phải học đặc trưng cấu trúc và texture thay vì vật lý ảnh y khoa.

3.5 Phương sai nội lớp & Điểm khó

**Khó nhất — BreastMRI (CoV ≈ 2,0):** Mật độ mô tuyến vú, phân bố và nền ảnh biến thiên lớn giữa bệnh nhân. Đồng thời đây là lớp có ít mẫu nhất (8.954).

**Dễ nhất — AbdomenCT & HeadCT (CoV ≈ 0,1):** Ảnh CT axial có khung tròn nhất quán rất cao qua các bệnh nhân.

**CXR (~2.600) và Hand (~2.300):** Phương sai nội lớp cao nhất — độ tương phản X-quang phụ thuộc mạnh vào giải phẫu bệnh nhân và thông số phơi sáng.

3.6 Độ tương đồng giữa các lớp

| Cặp lớp để nhằm     | Cosine Sim. | Lý do                                                      |
|---------------------|-------------|------------------------------------------------------------|
| AbdomenCT ↔ ChestCT | 1,00        | Cùng định dạng CT axial, prototype gần như pixel-identical |
| ChestCT ↔ CXR       | 0,94        | Cùng vùng ngực, khác phương thức chụp                      |
| AbdomenCT ↔ HeadCT  | ~0,90       | Cùng cấu trúc tròn của CT, khác chi tiết nội tạng          |

**Lưu ý:** AbdomenCT ↔ ChestCT đạt cosine sim=1,00 nghĩa là hai prototype gần như giống pixel-identical, nhưng chúng mô tả vùng giải phẫu hoàn toàn khác nhau. Đây là thách thức đặc trưng của Medical MNIST.

IV. Mở rộng — Giải Quyết Cả 3 Dataset Đồng Thời


4.1 Tính Khả Thi và Lợi Thế

Câu hỏi thầy kêu suy nghĩ: Có thể xây dựng **một model duy nhất** phân loại cả 3 dataset không? Câu trả lời là **có** và đôi khi có lợi hơn 3 model riêng biệt vì:

- Cùng input format: tất cả đều là 28×28 grayscale, pixel range 0–255 — không cần preprocessing pipeline khác nhau.
- Shared low-level features: edges, corners, gradients là chung cho cả 3 domain. Conv layers đầu không cần học lại từ đầu.
- Regularization effect: training trên nhiều domain giảm overfitting cho mỗi task riêng lẻ. Medical hưởng lợi nhiều nhất (+2–5%) nhờ được regularize bởi 2 dataset lớn hơn.
- Một model duy nhất cho production: inference nhanh hơn, memory footprint nhỏ hơn ensemble.

## 4.2 Chiến Lược Khuyến Nghị: Multi-Task Learning

Kiến trúc MTL với shared backbone và task-specific heads:



## 4.3 Các Chiến Lược Thay Thế

### Chiến lược 2: Domain-Adaptive Transfer Learning

Sequential curriculum: Pre-train MNIST → Fine-tune Fashion → Fine-tune Medical với Elastic Weight Consolidation (EWC). Mỗi stage giữ lại knowledge từ stage trước. Phù hợp khi có giới hạn memory và muốn interpretable training steps.

### Chiến lược 3: Mixture of Experts (MoE)

Gating network tự động routing input đến Expert phù hợp. Mỗi Expert là một specialist model. Giảm negative transfer tối đa nhưng phức tạp hơn để train và deploy.

## 4.4 So Sánh Chiến Lược

| Tiêu chí          | Multi-Task Learning | Transfer Learning       | Mixture of Experts     |
|-------------------|---------------------|-------------------------|------------------------|
| Training mode     | Joint (song song)   | Sequential (tuần tự)    | Joint với gating net   |
| Complexity        | Trung bình          | Thấp–Trung bình         | Cao                    |
| Negative Transfer | Có thể xảy ra       | Catastrophic forgetting | Tối thiểu              |
| Medical Benefit   | ~+3–5% accuracy     | ~+2–4% accuracy         | Trung bình             |
| Training time     | Trung bình          | Lâu (3 stages)          | Lâu (gating + experts) |
| Deploy complexity | Đơn giản (1 model)  | Trung bình (3 models)   | Phức tạp (router + N)  |
| Khuyến nghị       | RECOMMENDED         | Alternative             | Research only          |

Bảng 4: So sánh 3 chiến lược unified model. MTL được khuyến nghị nhất cho bài toán này.

## 4.5 Kỹ Thuật Hỗ Trợ Quan Trọng

- Dataset ID Embedding: one-hot vector  $[1,0,0]$ ,  $[0,1,0]$ ,  $[0,0,1]$  concat vào feature vector sau backbone. Giúp model tự biết đang xử lý domain nào mà không cần gating network riêng.
- GradNorm / PCGrad: normalize gradient từ mỗi task để tránh conflict. Đặc biệt quan trọng khi Medical loss có scale khác Handwritten/Fashion do số classes khác nhau (6 vs 10).
- Weighted Sampling: sample 1/3 từ mỗi dataset mỗi batch — không phải theo size (nếu theo size, Medical chỉ chiếm 30% iteration, có thể bị under-represented).
- Focal Loss cho Medical:  $\gamma=2$  tập trung vào hard examples và penalize easy examples ít hơn — đặc biệt hữu ích cho BreastMRI (class thiểu số và khó nhất).
- Task-specific Augmentation: MNIST: rotation  $\pm 15^\circ$ , elastic distortion; Fashion: horizontal flip + brightness  $\pm 20\%$ ; Medical: CLAHE, Gaussian noise, NO horizontal flip (ảnh y tế có orientation cố định).

---

— Kết thúc báo cáo —