

BÁO CÁO BÀI TẬP: THIẾT KẾ VÀ ĐÁNH GIÁ MẠNG NƠ-RON NHÂN TẠO (ANN) TRÊN CÁC TẬP DỮ LIỆU MNIST

Sinh viên: Nguyễn Hải Đăng

Mã số sinh viên: 23127165

Lớp: 23TGMT

Folder code: [Google Drive](#)

I. PHÂN TÍCH VÀ GIẢI THÍCH PHƯƠNG PHÁP TIẾP CẬN TRONG TỪNG NOTEBOOK

1. Tập dữ liệu MNIST Handwritten ([handwritten.ipynb](#))

- **Kỹ thuật Tăng cường dữ liệu (Data Augmentation):** Bộ dữ liệu này có phương sai nội lớp lớn ở một số chữ số, đặc biệt là chữ số "1" (được viết theo nhiều kiểu nghiêng, thẳng, có hoặc không gạch chân). Để giải quyết vấn đề này, em thiết kế cho ảnh được xoay ngẫu nhiên $\pm 15^\circ$ và áp dụng biến dạng đàn hồi (Elastic Transform) để mô phỏng sự đa dạng của nét viết tay.
- **Kiến trúc Mạng:** Do dữ liệu có độ thưa cao - 80,9% pixel là nền (em có phân tích trong báo cáo lần trước) và hình học topo đơn giản, nên em thiết kế mô hình sử dụng cấu trúc ANN cơ bản với 2 lớp ẩn (256 và 128 nơ-ron) kết hợp hàm kích hoạt ReLU. Hàm mất mát em sử dụng là Cross-Entropy.

2. Tập dữ liệu MNIST Fashion ([fashion.ipynb](#))

- **Kỹ thuật Tăng cường dữ liệu:** Phân loại quần áo đòi hỏi mạng nhận diện được texture bề mặt. Mô hình được thiết kế để áp dụng lật ngang ngẫu nhiên (Horizontal Flip) và thay đổi độ sáng ngẫu nhiên (Color Jitter $\pm 20\%$) giúp mô phỏng điều kiện ánh sáng và góc chụp thực tế.
- **Kiến trúc Mạng:** Phức tạp hơn Handwritten, mạng Fashion phải xử lý độ tương đồng liên lớp cao như nhóm Tops như Coat và Shirt có Cosine Similarity lên tới 0,99 (em có phân tích trong báo cáo lần trước). Do đó, kiến trúc được mở rộng

(512 và 256 nơ-ron) kết hợp với `BatchNorm1d` để hội tụ nhanh. Đặc biệt, lớp `Dropout(0.3)` được bổ sung để phạt mạng lưới, ngăn chặn tình trạng học thuộc lòng (overfitting) các điểm nhiễu vụn vặt.


3. Tập dữ liệu MNIST Medical (`medical.ipynb`)

- **Kiến trúc & Hàm mất mát (Focal Loss):** Bộ dữ liệu có tính rủi ro lâm sàng cao và mức độ mất cân bằng lớp (BreastMRI chỉ có 8.954 mẫu và có độ khó CoV cao nhất). Thay vì dùng Cross-Entropy, em thiết kế hàm **Focal Loss** ($\gamma = 2$) → lí do là để giảm trọng số của các ca dễ (như HeadCT, AbdomenCT) và dồn "hình phạt" vào các ca khó, giúp tối ưu hóa khả năng nhận diện (Recall) của lớp thiểu số.
- Ở đây, em **không áp dụng lật ngang (No Horizontal Flip)** nhằm bảo toàn cấu trúc giải phẫu không gian của ảnh


II. PHÂN TÍCH KẾT QUẢ HUẤN LUYỆN

Sau 25 epochs, kết quả thực nghiệm cho thấy mô hình hoạt động cực kỳ hiệu quả, phản ánh đúng đặc trưng của từng miền dữ liệu. Training Accuracy cao nhất của 3 tập dữ liệu MNIST lần lượt là:


- Handwritten với **97.56% (epoch 24/25)**;
- Fashion với **91.92% (epoch 25/25)**;
- Medical với **100% (epoch 19/25)**.



MNIST Handwritten



MNIST Fashion



MNIST Medical

Đánh giá chi tiết từng mô hình


- **MNIST Handwritten (Test Accuracy: 99.03%):** Kết quả gần mức hoàn hảo này cho thấy mạng ANN (256→128 nơ-ron) hoàn toàn đủ năng lực để trích xuất đặc trưng topo của các chữ số. Ta thấy Test Accuracy cao hơn tập Train gần 1.5% lí do là trong quá trình huấn luyện, tập dữ liệu đã bị làm khó một cách có chủ ý bằng kỹ thuật Data Augmentation (biến dạng đàn hồi và xoay góc ngẫu nhiên).

Kỹ thuật này đã thành công giúp model học được sự biến thiên cực kỳ đa dạng của các nét chữ, đặc biệt là chữ số "1". Khi đánh giá trên tập Test (dữ liệu sạch, không bị bóp méo), mô hình đã phát huy tối đa năng lực tổng quát hóa.

```

print(f"Kết quả kiểm thử:")
print(f"> Test Loss: {final_loss:.4f}")
print(f"> Test Accuracy: {final_acc:.2f}%")

--- ĐÁNH GIÁ CUỐI CÙNG TRÊN TẬP TEST ---
Kết quả kiểm thử:
> Test Loss: 0.0297
> Test Accuracy: 99.03%
  
```




- MNIST Fashion (Test Accuracy: 89.63%):** Mức chênh lệch ~2.3% so với Train Accuracy chứng tỏ lớp Dropout (0.3) đã làm rất tốt nhiệm vụ kiểm chế Overfitting. Sự bão hòa ở ngưỡng xấp xỉ 90% có thể là giới hạn trần của kiến trúc ANN truyền thống đối với ảnh thời trang. Khi duỗi phẳng ảnh thành vector 1D, mạng đã mất đi ngữ cảnh không gian 2D để nhận diện các vùng vân vải (texture) hay gradient bề mặt. Hơn nữa, độ tương đồng liên lớp cực cao như Coat và Shirt khiến ranh giới quyết định tuyến tính của ANN khó có thể phân tách rạch ròi.

```

print(f"Kết quả kiểm thử:")
print(f"> Test Loss: {final_loss:.4f}")
print(f"> Test Accuracy: {final_acc:.2f}%")

...

--- ĐÁNH GIÁ CUỐI CÙNG TRÊN TẬP TEST ---
Kết quả kiểm thử:
> Test Loss: 0.2893
> Test Accuracy: 89.63%
  
```



- MNIST Medical (Test Accuracy: 99.92%):** Việc đạt 100% Accuracy trên tập huấn luyện của cho thấy mô hình ANN có khả năng hội tụ cực tốt trên dữ liệu y tế nhờ vào sự khác biệt rõ rệt về cấu trúc cường độ pixel giữa các lớp (như HeadCT vs ChestCT). Tuy nhiên, đây cũng là dấu hiệu của sự quá khớp (Overfitting), em nghĩ có thể là do dữ liệu chưa nhiều và đa dạng. Bên cạnh đó, sự tốt tuyệt đối này đến từ hai quyết định thiết kế kiến trúc:

```


medical.ipynb
File Edit View Insert Runtime Tools Help

Q Commands + Code + Text ▶ Run all

[13] ✓ 5s
print(f" > Test Loss: {final_loss:.4f}")
print(f" > Test Accuracy: {final_acc:.2f}%")

--- ĐÁNH GIÁ CUỐI CÙNG TRÊN TẬP TEST ---
Kết quả kiểm thử:
> Test Loss: 0.0011
> Test Accuracy: 99.92%
  
```

- Thứ nhất, việc loại bỏ phép lật ngang (No Horizontal Flip) trong tiền xử lý đã bảo toàn nghiêm ngặt cấu trúc định hướng giải phẫu của ảnh X-quang và CT.
- Thứ hai, việc áp dụng Focal Loss ($\gamma = 2$) đã giải quyết triệt để vấn đề của BreastMRI. Đây là lớp thiểu số (chỉ 8.954 mẫu) và khó phân loại nhất ($CoV \approx 2, 0$). Hàm Focal Loss đã ép mô hình phạt nặng các mẫu dự đoán sai, giúp mạng ANN tự tin vượt qua sự giống nhau hoàn toàn về phân bố pixel xám giữa các lớp như AbdomenCT và ChestCT.



III. ĐỀ XUẤT CẢI TIẾN TĂNG HIỆU QUẢ MÔ HÌNH

Dựa trên những hạn chế được bộc lộ trong quá trình phân tích kết quả, đặc biệt là sự chững lại của tập Fashion MNIST, em đề xuất các phương pháp cải tiến như sau:

- **1. Chuyển dịch từ ANN sang Mạng nơ-ron Tích chập (CNN):**

Thao tác Flatten của ANN là một sự đánh đổi lớn về thông tin. Để mô hình có thể phân tách các lớp có độ tương đồng Cosine cao, em nghĩ mình có thể thay thế cấu trúc hiện tại bằng các khối CNN. Các bộ lọc tích chập (Convolutional filters) sẽ giữ nguyên cấu trúc ma trận 2D của ảnh, tự động trích xuất các đặc trưng phân cấp từ cạnh, góc cơ bản cho đến các vân vải bề mặt phức tạp.

- **2. Tối ưu hóa siêu tham số bằng Early Stopping:**

Thực nghiệm trên tập Fashion cho thấy việc huấn luyện đến 25 epochs là dư thừa tài nguyên. Em nghĩ mình có thể tích hợp cơ chế Early Stopping (Dừng sớm) vào vòng lặp huấn luyện. Cụ thể, thuật toán sẽ dùng một phần của tập Train để làm **Validation Set** (nếu nó đủ nhiều và đủ có tác động), và Early Stopping sẽ dựa trên **Validation Loss**; nếu chỉ số này không giảm trong khoảng 3-5 epochs liên tiếp, quá trình huấn luyện sẽ tự động ngắt và khôi phục bộ trọng số (weights) tối ưu nhất.

- **3. Áp dụng Kiến trúc Học Đa Tác Vụ (Multi-Task Learning - MTL):**

Thay vì huấn luyện ba mạng rời rạc, có thể hợp nhất chúng bằng kiến trúc MTL. Mô hình sẽ có một "Backbone" (xương sống) dùng chung để trích xuất đặc trưng (shared representation), sau đó phân nhánh thành ba "Heads" riêng cho từng bài toán. Cách tiếp cận này giúp mạng Medical hưởng lợi từ hiệu ứng điều chuẩn (+2-5% accuracy) khi được học chung các đặc trưng hình học cơ bản từ hai tập dữ liệu lớn hơn. Kỹ thuật *GradNorm* cũng cần được bổ sung để cân bằng thang đo gradient giữa hàm Focal Loss (6 lớp) và Cross-Entropy (10 lớp).