

BÁO CÁO BÀI TẬP: THIẾT KẾ VÀ ĐÁNH GIÁ MẠNG NƠ-RON TÍCH CHẬP (CNN) LeNet-5 TRÊN CÁC TẬP DỮ LIỆU MNIST

Sinh viên: Nguyễn Hải Đăng

Mã số sinh viên: 23127165

Lớp: 23TGMT

Folder code: [Google Drive](#)

I. PHÂN TÍCH VÀ GIẢI THÍCH PHƯƠNG PHÁP TIẾP CẬN TRONG TỪNG NOTEBOOK

1. Tập dữ liệu MNIST Handwritten ([handwritten.ipynb](#))

- **Kỹ thuật Tăng cường dữ liệu (Data Augmentation):** Bộ dữ liệu này có phương sai nội lớp lớn ở một số chữ số, đặc biệt là chữ số "1" (được viết theo nhiều kiểu nghiêng, thẳng, có hoặc không gạch chân). Để giải quyết vấn đề này, em thiết kế cho ảnh được xoay ngẫu nhiên $\pm 15^\circ$ và áp dụng biến dạng đàn hồi (Elastic Transform) để mô phỏng sự đa dạng của nét viết tay.
- **Kiến trúc Mạng:** Khác với ANN, với **LeNet-5** thì các bộ lọc (filters) của lớp **Conv2d** kết hợp cùng **MaxPool2d** giúp mạng đạt được tính *bất biến với phép dịch chuyển cục bộ* (Translation Invariance). Điều này cho phép mô hình dễ dàng nhận diện các nét chữ dù chúng bị uốn lệch hay đứt gãy do Augmentation mà không bị nhiễu loạn vị trí pixel.

2. Tập dữ liệu MNIST Fashion ([fashion.ipynb](#))

- **Kỹ thuật Tăng cường dữ liệu:** Phân loại quần áo đòi hỏi mạng nhận diện được texture bề mặt. Mô hình được thiết kế để áp dụng lật ngang ngẫu nhiên (Horizontal Flip) và thay đổi độ sáng ngẫu nhiên (Color Jitter $\pm 20\%$) giúp mô phỏng điều kiện ánh sáng và góc chụp thực tế.
- **Kiến trúc Mạng:** Khắc phục nhược điểm lớn nhất của mạng ANN (phải duỗi phẳng ảnh 1D làm mất không gian 2D), mạng **LeNet-5** giữ nguyên cấu trúc ma

trận ảnh. Các tầng tích chập tự động trích xuất đặc trưng theo phân cấp: phát hiện đường viền áo quần ở các lớp đầu và nhận diện vân vải (texture) ở các lớp sau. Qua đó, mô hình phân tách tốt hơn các lớp có độ tương đồng Cosine cao (như Coat và Shirt). Lớp **Dropout(0.25)** được sử dụng ở cụm Fully Connected để ngăn chặn overfitting.


3. Tập dữ liệu MNIST Medical (**medical.ipynb**)

- **Kiến trúc & Hàm mất mát (Focal Loss):** Bộ dữ liệu có tính rủi ro lâm sàng cao và mức độ mất cân bằng lớp (BreastMRI chỉ có 8.954 mẫu và có độ khó CoV cao nhất). Em kết hợp mạng **LeNet-5** với hàm **Focal Loss** ($\gamma = 2$). Sự kết hợp này giúp CNN vừa trích xuất được đặc trưng y khoa phức tạp, vừa dằn "hình phạt" vào các ca khó, tối ưu hóa khả năng nhận diện (Recall) cho lớp thiểu số.
- Ở đây, em **không áp dụng lật ngang (No Horizontal Flip)** nhằm bảo toàn cấu trúc giải phẫu không gian của ảnh


II. PHÂN TÍCH KẾT QUẢ HUẤN LUYỆN

Sau 25 epochs, kết quả thực nghiệm cho thấy mô hình hoạt động cực kỳ hiệu quả, phản ánh đúng đặc trưng của từng miền dữ liệu. Training Accuracy cao nhất của 3 tập dữ liệu MNIST lần lượt là:


- Handwritten với **97.92% (epoch 24/25)**;
- Fashion với **90.43% (epoch 25/25)**;
- Medical với **99.94% (epoch 22/25)**.



MNIST Handwritten



MNIST Fashion



MNIST Medical

Đánh giá chi tiết từng mô hình

- **MNIST Handwritten (Test Accuracy: 99.33%):** Mức độ chênh lệch giữa Train và Test chỉ xấp xỉ 1.4% cho thấy mô hình LeNet-5 có khả năng tổng quát hóa tốt bởi trong quá trình Training, tập dữ liệu đã bị làm khó có chủ ý bằng Data

Augmentation (biến dạng đàn hồi và xoay góc ngẫu nhiên) → thông qua mạng tích chập CNN mà mô hình học được sự biến thiên cực kỳ đa dạng của các nét chữ. Vì thế, khi đánh giá trên tập Test, mô hình đã phát huy tối đa năng lực nhận diện với kết quả gần mức hoàn hảo.

```


handwritten.ipynb
File Edit View Insert Runtime Tools Help

Commands + Code + Text Run all

[11] ✓ 1s
print(f"Kết quả kiểm thử:")
print(f"> Test Loss: {final_loss:.4f}")
print(f"> Test Accuracy: {final_acc:.2f}%")

--- ĐÁNH GIÁ CUỐI CÙNG TRÊN TẬP TEST ---
Kết quả kiểm thử:
> Test Loss: 0.0206
> Test Accuracy: 99.33%

```



- MNIST Fashion (Test Accuracy: 89.83%):** Mức chênh lệch chỉ ~0.6% so với Train Accuracy chứng tỏ lớp Dropout (0.25) đã làm rất tốt nhiệm vụ kiểm chế Overfitting. Việc đạt xấp xỉ 90% cho thấy LeNet5 đã khai thác tốt các vùng vân vải và gradient bề mặt nhờ giữ lại ngữ cảnh 2D. Sự bão hòa ở ngưỡng này là do LeNet-5 vẫn là một mạng CNN khá nông (shallow network), khiến ranh giới phân loại giữa các món đồ quá giống nhau (Coat/Shirt) vẫn còn đôi chút khó khăn.

```


fashion.ipynb
File Edit View Insert Runtime Tools Help

Commands + Code + Text Run all

[12] ✓ 1s
print(f"Kết quả kiểm thử:")
print(f"> Test Loss: {final_loss:.4f}")
print(f"> Test Accuracy: {final_acc:.2f}%")

--- ĐÁNH GIÁ CUỐI CÙNG TRÊN TẬP TEST ---
Kết quả kiểm thử:
> Test Loss: 0.2745
> Test Accuracy: 89.83%

```



- MNIST Medical (Test Accuracy: 99.91%):** Sự hội tụ gần như tuyệt đối trên cả Train và Test cho thấy các bộ lọc tích chập cực kỳ nhạy bén với sự khác biệt về cấu trúc cường độ pixel y khoa (như xương sọ trong HeadCT vs mô mềm AbdomenCT). Kết quả gần như hoàn hảo này là do việc giữ nguyên định hướng giải phẫu (không lật ngang) và hàm Focal Loss đã ép mô hình tự tin vượt qua sự giống nhau về phân bố pixel xám, giải quyết triệt để sự mất cân bằng của lớp BreastMRI.

```


medical.ipynb
File Edit View Insert Runtime Tools Help

Commands + Code + Text Run all

[12] ✓ 7s
print(f"Kết quả kiểm thử:")
print(f"> Test Loss: {final_loss:.4f}")
print(f"> Test Accuracy: {final_acc:.2f}%")

--- ĐÁNH GIÁ CUỐI CÙNG TRÊN TẬP TEST ---
Kết quả kiểm thử:
> Test Loss: 0.0006
> Test Accuracy: 99.91%

```



III. ĐỀ XUẤT CẢI TIẾN TĂNG HIỆU QUẢ MÔ HÌNH

Mặc dù việc chuyển đổi sang CNN LeNet-5 đã giải quyết được các hạn chế về không gian của ANN, nhưng để hệ thống đạt độ tin cậy cao hơn trong môi trường nghiên cứu thực tế (đặc biệt là để bứt phá giới hạn 90% của tập Fashion), em đề xuất các phương án sau:

- **1. Nâng cấp lên các kiến trúc CNN tiên tiến hơn:**

LeNet-5 là một cấu trúc kinh điển nhưng khá nông. Để mô hình phân tách được các vân vãi phức tạp của Fashion MNIST, em đề xuất thay thế bằng các kiến trúc sâu hơn như **ResNet-18** hoặc **MobileNetV2**. Các mạng này có cấu trúc Skip Connection giúp trích xuất các đặc trưng vi mô mà không bị Vanishing Gradient trong quá trình huấn luyện.

- **2. Tối ưu hóa bằng Bộ lên lịch Tốc độ học (Learning Rate Scheduler):**

Thực nghiệm cho thấy ở những epochs cuối, đồ thị Loss có dấu hiệu dao động nhẹ. Thay vì dùng học suất cố định ($lr = 0.001$), thì mình có thể tích hợp

`ReduceLROnPlateau` để tự động giảm tốc độ học khi Validation Loss chững lại, kết hợp với cơ chế Early Stopping sẽ giúp thuật toán hội tụ mượt mà vào điểm cực tiểu toàn cục và tiết kiệm tài nguyên tính toán.

- **3. Đánh giá chéo K-Fold (K-Fold Cross Validation) cho dữ liệu Medical:**

Tập dữ liệu MNIST Medical rất nhạy cảm và yêu cầu độ tin cậy lâm sàng khắt khe. Việc đạt 99.91% Accuracy là rất tích cực, nhưng để loại trừ khả năng phân chia dữ liệu Train/Test một cách ngẫu nhiên, thì em nghĩ mình có thể đánh giá chéo bằng K-Fold (ví dụ K=5) để cho mô hình có năng lực khái quát hóa thực sự trên toàn bộ phân phối dữ liệu bệnh lý.