

Prompt sử dụng:

Sử dụng kiến trúc hiện tại, thực hiện phân tích các tác động của biến gender, lunch, test_preparation_course tác động như thế nào đến math, reading và writing score.

Vẽ biểu đồ để xác định kiểu phân bố của từng biến và nhận xét

Do các biến gender, lunch, prepare là biến định tính, cần biến đổi thành biến định lượng tương ứng để phân tích.

Với mỗi biến, hãy thực hiện Hypothesis testing với $\alpha = 5\%$ để chuẩn đoán rằng các biến định tính trên có thực sự ảnh hưởng đến các score hay không?

Sau đó, tìm mô hình hồi quy dựa trên các biến có ảnh hưởng cho từng điểm (score) sử dụng regression, nhận xét mô hình được đưa ra.

Viết report đầy đủ dưới dạng bạn là 1 người researcher muốn tìm hiểu mối tương quan giữa các biến định tính và điểm số của sinh viên, sử dụng markdown, code hợp lý

Chỉ sử dụng các thư viện numpy, pandas, matplotlib, seaborn

Hãy viết kỹ hơn về các model, đồng thời chỉnh lại report để sử dụng chủ yếu tiếng việt cho các phần markdown và code

```
In [34]: import numpy as np
import pandas as pd

data = pd.read_csv('study_performance.csv')
data.head()
```

```
Out[34]:
```

	gender	race_ethnicity	parental_level_of_education	lur
0	female	group B	bachelor's degree	standard
1	female	group C	some college	standard
2	female	group B	master's degree	standard
3	male	group A	associate's degree	free/reduc
4	male	group C	some college	standard

```
In [27]: import matplotlib.pyplot as plt
import seaborn as sns

# Set style for plots
sns.set_style("whitegrid")
plt.rcParams['figure.figsize'] = (10, 6)
```

```
In [28]: # Data exploration
print("Dataset shape:", data.shape)
print("\nData info:")
print(data.info())
print("\nDescriptive statistics:")
print(data.describe())
print("\nUnique values for categorical variables:")
print("Gender:", data['gender'].unique())
print("Lunch:", data['lunch'].unique())
print("Test preparation course:",
data['test_preparation_course'].unique())
```

Dataset shape: (1000, 8)

Data info:

<class 'pandas.core.frame.DataFrame'>

RangeIndex: 1000 entries, 0 to 999

Data columns (total 8 columns):

#	Column	Non-Null Count	Dtype
0	gender	1000 non-null	object
1	race_ethnicity	1000 non-null	object
2	parental_level_of_education	1000 non-null	object
3	lunch	1000 non-null	object
4	test_preparation_course	1000 non-null	object
5	math_score	1000 non-null	int64
6	reading_score	1000 non-null	int64
7	writing_score	1000 non-null	int64

dtypes: int64(3), object(5)

memory usage: 62.6+ KB

None

Descriptive statistics:

	math_score	reading_score	writing_score
count	1000.00000	1000.000000	1000.000000
mean	66.08900	69.169000	68.054000
std	15.16308	14.600192	15.195657
min	0.00000	17.000000	10.000000
25%	57.00000	59.000000	57.750000
50%	66.00000	70.000000	69.000000
75%	77.00000	79.000000	79.000000
max	100.00000	100.000000	100.000000

Unique values for categorical variables:

Gender: ['female' 'male']

Lunch: ['standard' 'free/reduced']

Test preparation course: ['none' 'completed']

```

In [29]: # Transform categorical variables to quantitative
data_encoded = data.copy()

# Gender: female=0, male=1
data_encoded['gender_encoded'] =
data_encoded['gender'].map({'female': 0, 'male': 1})

# Lunch: free/reduced=0, standard=1
data_encoded['lunch_encoded'] =
data_encoded['lunch'].map({'free/reduced': 0, 'standard': 1})

# Test preparation course: none=0, completed=1
data_encoded['test_prep_encoded'] =
data_encoded['test_preparation_course'].map({'none': 0,
'completed': 1})

print("Encoded data head:")
print(data_encoded[['gender', 'gender_encoded', 'lunch',
'lunch_encoded', 'test_preparation_course',
'test_prep_encoded']].head())

```

Encoded data head:

	gender	gender_encoded	lunch	lunch_encoded	\
0	female	0	standard	1	
1	female	0	standard	1	
2	female	0	standard	1	
3	male	1	free/reduced	0	
4	male	1	standard	1	

	test_preparation_course	test_prep_encoded
0	none	0
1	completed	1
2	none	0
3	none	0
4	none	0

```

In [30]: # Distribution plots for scores
fig, axes = plt.subplots(1, 3, figsize=(18, 6))

# Math score distribution
sns.histplot(data['math_score'], kde=True, ax=axes[0])
axes[0].set_title('Math Score Distribution')
axes[0].set_xlabel('Math Score')
axes[0].set_ylabel('Frequency')


# Reading score distribution
sns.histplot(data['reading_score'], kde=True, ax=axes[1])
axes[1].set_title('Reading Score Distribution')
axes[1].set_xlabel('Reading Score')
axes[1].set_ylabel('Frequency')

# Writing score distribution
sns.histplot(data['writing_score'], kde=True, ax=axes[2])
axes[2].set_title('Writing Score Distribution')
axes[2].set_xlabel('Writing Score')
axes[2].set_ylabel('Frequency')

plt.tight_layout()
plt.show()

print("Observations on score distributions:")
print("- Math scores appear to be normally distributed with a slight left skew")
print("- Reading and writing scores show similar patterns, potentially normal distribution")
print("- All scores range from around 0 to 100")

```



Observations on score distributions:

- Math scores appear to be normally distributed with a slight left skew
- Reading and writing scores show similar patterns, potentially normal distribution
- All scores range from around 0 to 100


```
In [31]: # Distribution plots for categorical variables
fig, axes = plt.subplots(1, 3, figsize=(18, 6))

# Gender distribution
gender_counts = data['gender'].value_counts()
axes[0].pie(gender_counts, labels=gender_counts.index,
autopct='%1.1f%%', startangle=90)
axes[0].set_title('Gender Distribution')

# Lunch distribution
lunch_counts = data['lunch'].value_counts()
axes[1].pie(lunch_counts, labels=lunch_counts.index,
autopct='%1.1f%%', startangle=90)
axes[1].set_title('Lunch Type Distribution')

# Test preparation distribution
prep_counts = data['test_preparation_course'].value_counts()
axes[2].pie(prep_counts, labels=prep_counts.index,
autopct='%1.1f%%', startangle=90)
axes[2].set_title('Test Preparation Course Distribution')

plt.tight_layout()
plt.show()
```



```

In [32]: # Hypothesis testing with alpha = 5% (manual t-test calculation)
alpha = 0.05
scores = ['math_score', 'reading_score', 'writing_score']
categorical_vars = ['gender_encoded', 'lunch_encoded',
                    'test_prep_encoded']

def manual_ttest(group1, group2):
    mean1, mean2 = np.mean(group1), np.mean(group2)
    var1, var2 = np.var(group1, ddof=1), np.var(group2, ddof=1)
    n1, n2 = len(group1), len(group2)

    t_stat = (mean1 - mean2) / np.sqrt(var1/n1 + var2/n2)
    # Approximate p-value (rough estimate for large samples)
    # For simplicity, we'll use |t| > 2 as significant at 5%
    level
    significant = abs(t_stat) > 2

    return t_stat, significant

print("Hypothesis Testing Results (t-test approximation,
alpha=5%):")
print("=" * 60)

for score in scores:
    print(f"\n{score.upper()}:")
    for var in categorical_vars:
        group1 = data_encoded[data_encoded[var] == 0][score]
        group2 = data_encoded[data_encoded[var] == 1][score]

        t_stat, significant = manual_ttest(group1, group2)

        var_name = var.replace('_encoded', '')
        print(f" {var_name}: t-stat={t_stat:.3f}")
        if significant:
            print("    -> SIGNIFICANT: Variable affects the
score")
        else:
            print("    -> NOT SIGNIFICANT: No evidence of
effect")

```

```

Hypothesis Testing Results (t-test approximation, alpha=5%):
=====

```

```

MATH_SCORE:
gender: t-stat=-5.398
    -> SIGNIFICANT: Variable affects the score
lunch: t-stat=-11.484
    -> SIGNIFICANT: Variable affects the score
test_prep: t-stat=-5.787
    -> SIGNIFICANT: Variable affects the score

```

```

READING_SCORE:
gender: t-stat=7.968
    -> SIGNIFICANT: Variable affects the score
lunch: t-stat=-7.293
    -> SIGNIFICANT: Variable affects the score
test_prep: t-stat=-8.004

```

-> SIGNIFICANT: Variable affects the score

WRITING_SCORE:

gender: t-stat=9.998

-> SIGNIFICANT: Variable affects the score

lunch: t-stat=-7.841

-> SIGNIFICANT: Variable affects the score

test_prep: t-stat=-10.753

-> SIGNIFICANT: Variable affects the score

```

In [33]: # Regression models for each score
# Based on hypothesis testing, all variables seem significant, so
include all

def perform_regression(X, y, var_names):
    # Add intercept
    X = np.column_stack([np.ones(X.shape[0]), X])

    # Perform linear regression
    coeffs, residuals, rank, s = np.linalg.lstsq(X, y,
rcond=None)

    # Calculate R-squared
    ss_res = residuals[0] if len(residuals) > 0 else 0
    ss_tot = np.sum((y - np.mean(y))**2)
    r_squared = 1 - (ss_res / ss_tot) if ss_tot != 0 else 0

    # Calculate RMSE
    rmse = np.sqrt(ss_res / len(y)) if len(residuals) > 0 else 0

    print(f"Coefficients:")
    print(f"  Intercept: {coeffs[0]:.3f}")
    for i, name in enumerate(var_names):
        print(f"  {name}: {coeffs[i+1]:.3f}")
    print(f"R-squared: {r_squared:.3f}")
    print(f"RMSE: {rmse:.3f}")

    return coeffs, r_squared

print("Regression Models:")
print("=" * 40)

# Prepare features
features = ['gender_encoded', 'lunch_encoded',
'test_prep_encoded']
X = data_encoded[features].values

for score in scores:
    print(f"\n{score.upper()} Regression:")
    y = data_encoded[score].values
    coeffs, r2 = perform_regression(X, y, features)

    y_pred = np.dot(X, coeffs[1:]) + coeffs[0]
    mae = np.mean(np.abs(y - y_pred))

    print(f"Mean Absolute Error: {mae:.3f}")
    print("Interpretation:")
    print(f"  - Intercept: khi tất cả biến độc lập là 0, điểm dự
kiến bằng {coeffs[0]:.3f}.")
    print(f"  - gender_encoded = 1 nghĩa là nam, 0 là nữ.")
    print(f"  - lunch_encoded = 1 nghĩa là tiêu chuẩn, 0 là
free/reduced.")
    print(f"  - test_prep_encoded = 1 nghĩa là đã hoàn thành khóa
ôn tập.")
    for i, name in enumerate(features):
        direction = "tăng" if coeffs[i+1] > 0 else "giảm"
        print(f"  - Khi {name} tăng 1 đơn vị thì {score}

```

```
{direction} khoảng {abs(coeffs[i+1]):.3f} điểm.")
    print(f" - Mô hình giải thích được khoảng {r2*100:.1f}% biến
thiên của {score}.")
    print("'" + "-" * 40)
```

Regression Models:

=====

MATH_SCORE Regression:

Coefficients:

Intercept: 54.529
gender_encoded: 4.834
lunch_encoded: 11.104
test_prep_encoded: 5.776

R-squared: 0.182

RMSE: 13.705

Mean Absolute Error: 11.021

Interpretation:

- Intercept: khi tất cả biến độc lập là 0, điểm dự kiến bằng 54.529.
- gender_encoded = 1 nghĩa là nam, 0 là nữ.
- lunch_encoded = 1 nghĩa là tiêu chuẩn, 0 là free/reduced.
- test_prep_encoded = 1 nghĩa là đã hoàn thành khóa ôn tập.
- Khi gender_encoded tăng 1 đơn vị thì math_score tăng khoảng 4.834 điểm.
- Khi lunch_encoded tăng 1 đơn vị thì math_score tăng khoảng 11.104 điểm.
- Khi test_prep_encoded tăng 1 đơn vị thì math_score tăng khoảng 5.776 điểm.
- Mô hình giải thích được khoảng 18.2% biến thiên của math_score.

READING_SCORE Regression:

Coefficients:

Intercept: 65.302
gender_encoded: -7.328
lunch_encoded: 7.293
test_prep_encoded: 7.530

R-squared: 0.176

RMSE: 13.247

Mean Absolute Error: 10.616

Interpretation:

- Intercept: khi tất cả biến độc lập là 0, điểm dự kiến bằng 65.302.
- gender_encoded = 1 nghĩa là nam, 0 là nữ.
- lunch_encoded = 1 nghĩa là tiêu chuẩn, 0 là free/reduced.
- test_prep_encoded = 1 nghĩa là đã hoàn thành khóa ôn tập.
- Khi gender_encoded tăng 1 đơn vị thì reading_score giảm khoảng 7.328 điểm.
- Khi lunch_encoded tăng 1 đơn vị thì reading_score tăng khoảng 7.293 điểm.
- Khi test_prep_encoded tăng 1 đơn vị thì reading_score tăng khoảng 7.530 điểm.
- Mô hình giải thích được khoảng 17.6% biến thiên của reading_score.

WRITING_SCORE Regression:

Coefficients:

Intercept: 63.678

gender_encoded: -9.382

lunch_encoded: 8.183

test_prep_encoded: 10.112

R-squared: 0.256

RMSE: 13.099

Mean Absolute Error: 10.447

Interpretation:

- Intercept: khi tất cả biến độc lập là 0, điểm dự kiến bằng 63.678.
 - gender_encoded = 1 nghĩa là nam, 0 là nữ.
 - lunch_encoded = 1 nghĩa là tiêu chuẩn, 0 là free/reduced.
 - test_prep_encoded = 1 nghĩa là đã hoàn thành khóa ôn tập.
 - Khi gender_encoded tăng 1 đơn vị thì writing_score giảm khoảng 9.382 điểm.
 - Khi lunch_encoded tăng 1 đơn vị thì writing_score tăng khoảng 8.183 điểm.
 - Khi test_prep_encoded tăng 1 đơn vị thì writing_score tăng khoảng 10.112 điểm.
 - Mô hình giải thích được khoảng 25.6% biến thiên của writing_score.
-

Báo cáo nghiên cứu: Tác động của các biến định tính đến điểm số học sinh

Giới thiệu

Là một nhà nghiên cứu, mục tiêu của phân tích này là hiểu rõ mức độ ảnh hưởng của các biến định tính `gender`, `lunch` và `test_preparation_course` đối với ba loại điểm `math_score`, `reading_score`, `writing_score`. Phân tích dùng dữ liệu học sinh để xây dựng nhận định dựa trên thống kê và mô hình hồi quy.

Tổng quan dữ liệu

Dữ liệu gồm 1000 bản ghi học sinh với các biến chính:

- **Biến định tính:** `gender` (female/male), `lunch` (standard/free-reduced), `test_preparation_course` (none/completed)
- **Biến số:** `math_score`, `reading_score`, `writing_score` (thang điểm 0-100)

Phương pháp phân tích

1. **Mã hóa biến:** Biến định tính được chuyển sang giá trị số để phân tích định lượng.
2. **Phân tích phân bố:** Kiểm tra biểu đồ phân bố của các biến số và biến định tính.
3. **Kiểm định giả thuyết:** Dùng t-test xấp xỉ với $\alpha = 5\%$ để kiểm tra ảnh hưởng của biến định tính lên điểm số.
4. **Hồi quy tuyến tính:** Xây dựng mô hình dự báo điểm dựa trên các biến định tính quan trọng.

Kết quả chính

Phân bố dữ liệu

- Các điểm `math`, `reading`, `writing` đều có xu hướng phân bố gần với chuẩn,

không xuất hiện lệch quá mạnh.

- `gender` gần như cân bằng giữa nam và nữ.
- `lunch` phần lớn học sinh nhận lunch tiêu chuẩn (`standard`).
- `test_preparation_course` phần lớn học sinh chưa hoàn thành khóa ôn tập.

Kết quả kiểm định giả thuyết

Các kiểm định t-test xấp xỉ cho thấy tất cả các biến định tính đều có ảnh hưởng có ý nghĩa thống kê đến ba điểm số:

- `gender` : ảnh hưởng rõ rệt đến cả toán, đọc và viết.
- `lunch` : học sinh nhận lunch tiêu chuẩn có điểm số trung bình cao hơn.
- `test_preparation_course` : hoàn thành ôn tập giúp điểm số tăng lên.

Hệ số hồi quy và giải thích mô hình

Mỗi mô hình hồi quy tuyến tính được xây dựng với ba biến giải thích cùng lúc.

Mô hình Math

- $R^2 = 0.182$ (mô hình giải thích 18.2% biến thiên điểm toán)
- Hệ số:
 - `gender_encoded = 4.834` : học sinh nam có điểm toán trung bình cao hơn nữ khoảng 4.8 điểm khi giữ các yếu tố khác không đổi.
 - `lunch_encoded = 11.104` : học sinh nhận lunch tiêu chuẩn cao hơn khoảng 11.1 điểm so với nhóm free/reduced.
 - `test_prep_encoded = 5.776` : hoàn thành ôn tập tăng khoảng 5.8 điểm toán.

Mô hình Reading

- $R^2 = 0.176$ (giải thích 17.6% biến thiên điểm đọc)
- Hệ số:
 - `gender_encoded = -7.328` : học sinh nam có điểm đọc thấp hơn nữ khoảng 7.3 điểm nếu các biến khác không đổi.
 - `lunch_encoded = 7.293` : lunch tiêu chuẩn tăng điểm đọc khoảng 7.3.
 - `test_prep_encoded = 7.530` : hoàn thành ôn tập tăng điểm đọc khoảng 7.5.

Mô hình Writing

- $R^2 = 0.256$ (giải thích 25.6% biến thiên điểm viết)
- Hệ số:
 - `gender_encoded = -9.382` : học sinh nam thấp hơn nữ khoảng 9.4 điểm viết khi giữ các yếu tố khác không đổi.
 - `lunch_encoded = 8.183` : lunch tiêu chuẩn tăng điểm viết khoảng 8.2.
 - `test_prep_encoded = 10.112` : hoàn thành ôn tập tăng điểm viết khoảng 10.1.

Nhận xét mô hình

- Các hệ số cho thấy `lunch` và `test_preparation_course` có ảnh hưởng tích cực đến cả ba môn.
- Dấu hệ số `gender` khác nhau giữa toán và ngôn ngữ: nam nhỉnh hơn ở toán, nữ nhỉnh hơn ở đọc/viết.
- R^2 dưới 0.3 nghĩa là còn nhiều yếu tố khác chưa được đưa vào mô hình (ví dụ: trình độ cha mẹ, thời gian học, môi trường học tập).
- Mô hình hồi quy tuyến tính đơn giản phù hợp để xác định xu hướng chung nhưng chưa đủ mạnh để dự báo chính xác cho từng cá nhân.

Kết luận

1. `lunch` và `test_preparation_course` là hai biến định tính có ảnh hưởng rõ rệt đến điểm số.
2. `gender` tồn tại khác biệt trong hiệu suất giữa các môn học.
3. Mô hình hồi quy hiện tại mới giải thích được một phần biến thiên điểm số, nên cần bổ sung thêm các yếu tố khác để cải thiện độ chính xác.