

ĐÁNH GIÁ BÀI BÁO THEO TIÊU CHUẨN GOOD RESEARCH

FaceHunter: A multi-task convolutional neural network based face detector

STT	Tiêu chí đánh giá	Lý giải dựa vào nội dung bài báo	Đánh giá
1	Lựa chọn chủ đề hứa hẹn: những vấn đề thách thức và ít người làm trong lĩnh vực nghiên cứu của bạn	- Bài báo tập trung vào thách thức phát hiện khuôn mặt trong môi trường tự nhiên (in the wild) với các biến thể lớn về ngoại hình, che khuất và lộn xộn. Điểm đặc biệt và ít người chú ý mà tác giả khai thác là vấn đề về độ ổn định và tin cậy của khung bao (bounding box), điều mà hầu hết các bộ phát hiện trước đó thường bỏ qua, dẫn đến ảnh hưởng tiêu cực cho các bước phân tích khuôn mặt tiếp theo. <i>“However, most detectors ignore the issue about the stability and reliability of the bounding box, which has a significant impact on the precision as well as the subsequent analysis.”</i> (page 1/6).	5
2	Đọc những khảo sát liên quan đến lĩnh vực nghiên cứu	❖ Tác giả đã dành phần giới thiệu để khảo sát một cách hệ thống và toàn diện các phương pháp hiện có trong hai thập kỷ qua - Họ phân tích các phương pháp truyền thống như Adaboost của Viola và Jones (dựa trên các bộ phân loại yếu và đặc trưng Haar) và Part-based deformable model (mô hình biến dạng dựa trên các bộ phận) giúp xử lý các biến thể hình dáng. <i>“The Adaboost-based method is first proposed by Viola and Jones, in which Adaboost learning is adopted to learn a cascade of weak classifiers with the simple Haar like features for discriminating face and non-face.”</i> (page 1/8), <i>“The part-based deformable model benefits from the fact that the part of an object often presents less visual variations, and the global variation of the object can be modeled by the flexible configuration of different parts.”</i> (page 1/6). - Tác giả cũng đi sâu vào Deep Learning (CNN) hiện đại, so sánh sự khác biệt giữa việc học đặc trưng tự động của CNN so với đặc trưng thủ công (hand-crafted features) của các phương pháp cũ. <i>“In recent years, convolutional neural network (CNN) based deep learning attracted much attentions in the communities of computer vision and pattern recognition. Its main advantage is that it can learn visual features automatically. CNN has also been successfully applied in face detection. Compared with previous works, the CNN-based detectors are directly to learn the features from the images instead of relying on the hand-crafted features.”</i> (page 1/6). - Đặc biệt, bài báo phân tích hạn chế của các phương pháp R-CNN trước đó, chỉ	5

		ra rằng việc coi hồi quy khung bao là một giai đoạn độc lập là một thiếu sót lớn cần khắc phục. “ <i>A few works take this issue into account, such as the R-CNN-based object detectors, but they regard the bounding box regression as an independent stage in the networks.</i> ” (page 1/6).	
3	Tốn nhiều thời gian cho tham khảo	- Danh mục tài liệu tham khảo của bài báo rất phong phú (28 tài liệu), bao gồm các công trình nền tảng và kinh điển trong lĩnh vực thị giác máy tính. Tác giả không chỉ tham khảo các bài báo lý thuyết về mạng nơ-ron từ những năm 1980-1990 (như Rumelhart, Le Cun) mà còn cập nhật các công trình tiên tiến nhất tại thời điểm viết bài (năm 2014-2015) như Faster R-CNN , Fast R-CNN và ImageNet. Sự đầu tư thời gian vào việc nghiên cứu các kỹ thuật như Truncated SVD để nén mạng và Adaptive Pooling cho thấy tác giả đã tìm hiểu rất kỹ các kỹ thuật tối ưu hóa deep neuron network.	5
4	Phát biểu bài toán thiết lập các cơ sở dữ liệu chuẩn và tiến hành thực nghiệm	- Bài toán được định nghĩa rõ ràng là xây dựng mạng FaceHunter - một mạng CNN đa nhiệm kết hợp với Mạng đề xuất vùng (RPN) để giải quyết đồng thời hai nhiệm vụ: phân loại khuôn mặt và tính chỉnh tọa độ khung bao. “<i>In this paper, we propose a new multi-task Convolutional Neural Network (CNN) based face detector, which is named FaceHunter for simplicity. The main idea is to make the face detector achieve a high detection accuracy and obtain much reliable face boxes. Reliable face boxes output will be much helpful for further face image analysis. To reach this goal, we design a deep CNN network with a multi-task loss, i.e., one is for discriminating face and non-face, and another is for face box regression.</i>” (page 1/6). - Tác giả sử dụng một tập hợp dữ liệu lớn và chuẩn hóa. Để huấn luyện, họ dùng 183.200 ảnh mặt từ bộ dữ liệu tự thu thập và dùng bộ dữ liệu AFLW để kiểm tra chéo (validation). “<i>In the training phase, we select 183,200 face images from our own dataset to train FaceHunter, and we use the AFLW dataset for validation.</i>” (page 4/6). - Hệ thống được đánh giá trên 3 bộ dữ liệu chuẩn (benchmark) nổi tiếng là AFW (205 ảnh), FDDB (2845 ảnh), và Pascal Faces (851 ảnh). Quy trình huấn luyện được thiết lập khoa học qua 4 bước (Algorithm 1), luân phiên cố định các lớp tích chập để huấn luyện riêng lẻ RPN và mạng CNN đa nhiệm nhằm tối ưu hóa trọng số chia sẻ. “<i>We conduct the experiments on five datasets: AFW (205 images with bounding boxes), FDDB (2845 images with ellipses annotations), Pascal Faces dataset (851 Pascal VOC Fig. 2. The deep structure which is used for generating feature maps. One GPU runs the layer-parts at the top of the figure while the other runs the layer-parts at the bottom. The GPUs communicate only at certain layers. Fig. 3. Use truncated SVD to compress fully connected layers.</i> 478 D. Wang et al. / Signal Processing: Image	5

		<i>Communication 47 (2016) 476–481 images with bounding boxes), AFLW (26,000 annotated faces), and the dataset collected by ourselves, which has a total of 980,354 annotated faces.” (page 3/6), “The both networks share the same convolutional layers. Thus, we develop a 4-step training algorithm to learn the shared features via alternating optimization” (page 3/6).</i> Algorithm 1. The whole optimization algorithm. Input: Face image, face rect. Initialization: ImageNet pre-trained model. 1. Train the RPN network. 2. Use the proposals generated by the RPN to train the multi-task CNN. 3. Use the CNN network to initialize the RPN. 4. Fine-tune the <i>fc</i> layers of the multi-task CNN. Output: Multi-task CNN based face detection model.	
5	Phân tích sâu kết quả thực nghiệm	Tác giả không chỉ dừng lại ở việc đưa ra con số mà còn so sánh đối chiếu rất sâu.	
5.1	Bài báo có phân tích đủ chi tiết với các trường hợp thực nghiệm chưa ?	❖ Bài báo cung cấp các phân tích định lượng rất chi tiết thông qua các biểu đồ tiêu chuẩn trong ngành: - Sử dụng chỉ số IoU (Intersection-over-Union) với ngưỡng 0.5 làm tiêu chuẩn đánh giá thành công. “<i>We evaluate our face detector on the AFW, FDDB and Pascal Faces datasets respectively. As in the previous work, we use the intersection-over-union (IoU) ratio to measure the detection results, and IoU 0. ≥ 5 is regarded as an efficient detection.</i>” (page 4/6). - Vẽ biểu đồ Precision-Recall (PR curve) cho bộ dữ liệu AFW (Hình 4) và Pascal Faces (Hình 6) để người đọc thấy rõ sự đánh đổi giữa độ chính xác và độ phủ.	5




Fig. 6. PR curve on Pascal Faces. (For interpretation of the references to color in this figure, the reader is referred to the web version of this paper.)

- Vẽ biểu đồ ROC rời rạc (Discrete ROC) cho bộ dữ liệu FDDB (Hình 5) để so sánh tỷ lệ dương tính thật (True Positive Rate) so với số lượng dương tính giả (False Positives). Những biểu đồ này cho thấy sự vượt trội của FaceHunter ở hầu hết các ngưỡng so với các phương pháp khác.




Fig. 5. Discrete ROC on FDDB. (For interpretation of the references to color in this figure, the reader is referred to the web version of this paper.)

5.2

a) Những lựa chọn nào đã xem xét ở những điểm khác nhau của thí nghiệm là gì?

a.) Tác giả đã thiết kế các kịch bản thí nghiệm (ablation study) để kiểm chứng hiệu quả của từng thành phần:

- Tác giả so sánh mô hình đầy đủ FaceHunter với mô hình Ours multi-task network without RPN (đường màu xanh lá cây trong các biểu đồ). Điều này để xem xét đóng góp thực sự của mạng đề xuất vùng. “*For further investigating*

5

b) Làm thế nào lựa chọn thí nghiệm ? Tại sao và làm thế nào mà bạn chọn cái thực nghiệm này?	<i>the proposed FaceHunter detector, we particularly evaluate it without using RPN, i.e. “Ours multi-task network without RPN” (expressed using the green curve in Figs. 4– 6). “Ours multi-task network without RPN” is similar to a FastRCNN, but it is not the same as Fast-RCNN.” (page 4/6).</i> - Tác giả so sánh mô hình của mình với "Hierarchical Deep Detector" (đường màu xanh dương), vốn sử dụng các mạng riêng biệt, để chứng minh lợi ích của việc học đa nhiệm. <i>“We compare the performance of “Ours multi-task network without RPN” with hierarchical deep detector (expressed using the blue curve in Figs. 4–6), which trains a separate CNN network for the bounding box regression to refine another CNN network for face detector.” (page 4/6).</i> Fig. 4. PR curve on AFW. (For interpretation of the references to color in this figure, the reader is referred to the web version of this paper.)
---	---




Fig. 5. Discrete ROC on Fddb. (For interpretation of the references to color in this figure, the reader is referred to the web version of this paper.)




Fig. 6. PR curve on Pascal Faces. (For interpretation of the references to color in this figure, the reader is referred to the web version of this paper.)

- Thí nghiệm được lặp lại trên 3 tập dữ liệu khác nhau (AFW, Fddb, Pascal Faces) để đảm bảo tính tổng quát hóa của thuật toán, không bị phụ thuộc vào đặc thù của một bộ dữ liệu duy nhất. “We evaluate our face detector on the AFW, Fddb and Pascal Faces datasets respectively.” (page 4/6).

b.) Tác giả chọn thực nghiệm này vì phương pháp tạo đề xuất vùng phổ biến Selective Search tốn tới 2 giây mỗi ảnh (quá chậm cho thực tế). Bằng cách chọn RPN chia sẻ đặc trưng tích chập, họ muốn chứng minh có thể giảm thời gian này xuống mức gần như bằng 0 (chỉ 4ms) mà vẫn giữ được độ chính xác. “Selective Search used in Fast-RCNN is one of the most popular proposal

		<i>methods, which costs about 2 s per image in a CPU implementation.” (page 2/6), “The GPU time of computing NMS, fc, softmax and others is about 0.034 s per image. It takes only 0.004 s per image for proposal on top of the conv map.” (page 6/6).</i> - Tác giả chọn so sánh với phương pháp phân tầng (hierarchical) cũ để chứng minh giả thuyết rằng việc tối ưu hóa đồng thời cả phân loại và hồi quy khung bao trong một mạng duy nhất sẽ giúp các tác vụ hỗ trợ lẫn nhau, từ đó học được các đặc trưng mạnh mẽ hơn so với việc huấn luyện riêng lẻ. <i>“In addition, the comparison between our “multi-task network without RPN” and hierarchical deep detector shows that the multi-task mode have stronger learning ability than the single-task mode.” (page 6/6).</i>  Fig. 7. Examples of our detection results.	
5.3	Kết quả thực nghiệm có tính nhất quán với kết luận không?	- Kết luận của bài báo khẳng định rằng FaceHunter đạt được độ chính xác phát hiện cao và khung bao ổn định. Điều này hoàn toàn khớp với kết quả thực nghiệm khi FaceHunter luôn nằm ở vị trí dẫn đầu (top performance) trên cả 3 bộ dữ liệu thử nghiệm. <i>“We focus on obtaining stable bounding boxes and achieving high detection accuracies” (page 6/6), “On all the three datasets, we can see the proposed FaceHunter detector achieves a good performance against the state of the art methods. It also indicates that, RPN can not only speed up the detector, but also increase the detecting precision.” (page 5/6).</i> - Kết luận cũng nhấn mạnh RPN giúp tăng tốc và tăng độ chính xác. Thực nghiệm đã chứng minh FaceHunter (có RPN) đạt AP cao hơn khoảng 1% so với	5

		phiên bản không có RPN và cao hơn 3% so với Hierarchical Deep Detector trên Pascal Faces , đồng thời tốc độ xử lý nhanh hơn rất nhiều so với các phương pháp dùng Selective Search. <i>“To further make the detector faster, we perform the Region Proposal Network (RPN) directly on the convolutional feature maps to generate the proposal candidates.”</i> (page 6/6)	
5.4	Có thể tinh chỉnh một số thông số chính để có kết quả tốt hoặc tệ hơn không? Nếu có thì dùng hình minh họa hoặc bảng hiển thị hiệu suất hệ thống	- Trong hàm mất mát đa nhiệm $L(p,p^*,t,t^*) = L_{cls} + \lambda L_{reg}$, tác giả đặt $\lambda=1$ theo kinh nghiệm. Nếu tăng hoặc giảm λ, mạng sẽ ưu tiên việc chỉnh khung bao hơn việc phân loại hoặc ngược lại, dẫn đến kết quả khác nhau. <i>“The hyper-parameter λ is set to 1 empirically. We set the size of the adaptive pooling layer L to be compatible with the first fully connected layer (i.e. $L/46$). We use dropout, as [20], in the two fully connected layers after the adaptive pooling layer. To compress the fully connected layers, we use the top 1024 singular values from the 9216×4096 matrix in the fc6 layer and the top 256 singular values from the 4096×4096 fc7 layer. For training the RPN, we use the same loss function with the hyper-parameter λ changing from 1 to 10. That means we bias towards better box locations.”</i> (page 4/6). - Tác giả cố định ngưỡng Non-Maximum Suppression là 0.7. Tinh chỉnh số này sẽ ảnh hưởng trực tiếp đến số lượng khuôn mặt được phát hiện (Recall) và độ chính xác (Precision). <i>“We fix the IoU threshold for NMS at 0.7. After NMS, we use the top-300 ranked proposal regions for detection”</i> (page 4/6). - Tác giả dùng cửa sổ 3×3 ($n=3$) và 3 tỷ lệ kích thước ($k=3$) là $128^2, 256^2, 512^2$. Thay đổi các kích thước này sẽ giúp mạng phát hiện tốt hơn các khuôn mặt quá nhỏ hoặc quá lớn tùy thuộc vào dữ liệu đầu vào. <i>“We use $n=3$ for the size of the sliding window in the RPN. For each sliding position, we define $k=3$ proposal regions associated with 3 scales (i.e. $128^2, 256^2$ and 512^2 pixels)”</i> (page 4/6). - Tác giả chọn Top-300 vùng đề xuất sau NMS để đưa vào mạng phát hiện. Tăng số lượng này có thể tăng Recall nhưng giảm tốc độ; giảm số lượng này sẽ tăng tốc độ nhưng có thể bỏ sót khuôn mặt. <i>“After NMS, we use the top-300 ranked proposal regions for detection.”</i> (page 4/6).	5
5.5	Kết quả thực nghiệm có tương ứng với mục tiêu bài báo hay không ?	❖ Có, tương ứng hoàn toàn. - Mục tiêu 1: Độ chính xác cao. Kết quả thực nghiệm cho thấy FaceHunter đạt 98.1% trên AFW và AP 85.16% trên Pascal Faces, chứng tỏ mục tiêu này đã đạt được.	5




Fig. 4. PR curve on AFW. (For interpretation of the references to color in this figure, the reader is referred to the web version of this paper.)

- Mục tiêu 2: Khung bao tin cậy: Việc sử dụng hàm mất mát hồi quy khung bao trong kiến trúc đa nhiệm đã giúp cải thiện độ chính xác định vị, thể hiện qua việc mô hình vượt trội hơn các phương pháp cũ vốn tách rời bước này. *“In addition, the comparison between our “multi-task network without RPN” and hierarchical deep detector shows that the multi-task mode have stronger learning ability than the single-task mode.”* (page 6/6).

- Mục tiêu 3: Tốc độ nhanh. Với việc tích hợp RPN và Adaptive Pooling, thời gian xử lý chỉ còn khoảng 0.08s/ảnh, đạt được mục tiêu về hiệu suất tính toán. *“Our detector takes only 0.041 s per image for convolutions. The GPU time of computing NMS, fc, softmax and others is about 0.034 s per image. It takes only 0.004 s per image for proposal on top of the conv map.”* (page 6/6)

- Tránh Selective Search: Thực nghiệm chỉ ra sự bất hợp lý khi dùng phương pháp Selective Search vì nó tốn tới 2 giây chỉ để tạo đề xuất, tạo ra nút thắt cổ chai (bottleneck) về hiệu suất cho toàn bộ hệ thống. Đây là điều cần tránh trong các hệ thống thời gian thực. *“Additionally, generating proposal is another computational bottleneck in detection systems. Selective Search used in Fast-RCNN is one of the most popular proposal methods, which costs about 2 s per image in a CPU implementation.”* (page 2/6).

- Tránh ràng buộc kích thước cố định: Các mạng CNN truyền thống yêu cầu ảnh đầu vào cố định (ví dụ 224x224), buộc phải cắt hoặc co giãn ảnh gây mất thông tin. Tác giả tránh điều này bằng cách dùng Adaptive Pooling Layer, cho phép mạng xử lý ảnh ở kích thước bất kỳ mà vẫn tạo ra vector đặc trưng có độ dài cố định. *“Considering the high computational expense of the CNN, we introduce an “adaptive pooling layer” to avoid repeatedly computing the*

		<i>convolutional features. Moreover, it removes the fixed-size constraint of the network, as it can generate a fixed-length representation regardless of image size and makes the network more flexible during parameter fine-tuning.” (page 2/6).</i> - Tránh dư thừa mẫu âm (Negative samples): Trong quá trình huấn luyện, để tránh việc mạng học các thông tin trùng lặp, tác giả đã loại bỏ các mẫu âm nếu chúng có độ chồng lấn (IoU) lớn hơn 75% với các mẫu âm khác. <i>“To reduce redundant information resulting from overlapping negative samples, the overlaps between two negative windows are more less than 75%.” (page 4/6).</i>	
6	Tìm ra trường hợp thuyết phục		
6.1	Vấn đề cần giải quyết chính xác là gì?	- Vấn đề cốt lõi cần giải quyết là sự thiếu hiệu quả của các bộ phát hiện khuôn mặt hiện tại khi đối mặt với hai rào cản: (1) Độ chính xác vị trí khung bao kém do tách rời quá trình tinh chỉnh tọa độ khỏi quá trình phân loại, và (2) Tốc độ chậm do phụ thuộc vào các thuật toán tạo đề xuất vùng tồn kém chi phí tính toán như Selective Search. FaceHunter giải quyết chính xác hai vấn đề này bằng kiến trúc đa nhiệm tích hợp RPN. <i>“However, most detectors ignore the issue about the stability and reliability of the bounding box, which has a significant impact on the precision as well as the subsequent analysis.” (page 1/6), “Additionally, generating proposal is another computational bottleneck in detection systems.” (page 2/6).</i>	5
6.2	Ý tưởng đang xem xét có hiệu quả đáng kể ko ?	❖ Có, hiệu quả rất đáng kể. - Về mặt tốc độ: Ý tưởng dùng RPN chia sẻ đặc trưng tích chập (shared convolutional features) đã giảm thời gian tạo đề xuất xuống mức không tưởng, chỉ 0.004 giây cho một bức ảnh 1000x600, nhanh gấp hàng trăm lần so với 2 giây của phương pháp cũ. <i>“With this strategy of sharing convolutions, the marginal cost for computing the proposals becomes very small (i.e. 4 ms for a typical 1000 600 image) enabling nearly cost-free proposals.” (page 2/6), “The GPU time of computing NMS, fc, softmax and others is about 0.034 s per image. It takes only 0.004 s per image for proposal on top of the conv map.” (page 6/6).</i> - Về mặt chất lượng: Ý tưởng học đa nhiệm (multi-task learning) đã giúp mô hình học được các đặc trưng tốt hơn. So sánh giữa phiên bản có RPN và không có RPN cho thấy RPN không chỉ tăng tốc độ mà còn đóng góp trực tiếp vào việc tăng độ chính xác phát hiện. <i>“It also indicates that, RPN can not only speed up the detector, but also increase the detecting precision.” (page 5/6).</i>	5

6.3	Chất lượng của những bài báo nghiên cứu tham chiếu thế nào ?	❖ Các tài liệu tham khảo được trích dẫn đều đến từ các nguồn cực kỳ uy tín trong cộng đồng khoa học máy tính: - Các hội nghị hàng đầu thế giới (Top-tier conferences): CVPR (IEEE Conference on Computer Vision and Pattern Recognition) , ICCV (International Conference on Computer Vision) , NIPS (Advances in Neural Information Processing Systems). - Các tác giả là những người định hình ngành: Bài báo trích dẫn R. Girshick (tác giả chuỗi R-CNN) , Krizhevsky (tác giả AlexNet) , và Viola & Jones. Việc dựa trên nền tảng tri thức vững chắc này đảm bảo độ tin cậy khoa học cao cho bài báo.	5
6.4	Việc so sánh với các nghiên cứu của tác giả với các trường hợp trước đây có tốt hay không có hiệu quả hay không?	- Việc so sánh được thực hiện rất công bằng và khoa học. Tác giả chọn đối thủ so sánh là “Hierarchical Deep Detector” - một phương pháp sử dụng mạng CNN riêng biệt cho việc hồi quy khung bao. Bằng cách so sánh FaceHunter (màu đỏ) với Hierarchical Deep Detector (màu xanh dương) trên cùng các biểu đồ (Hình 4, 5, 6), tác giả chỉ ra rõ ràng sự vượt trội của phương pháp mới. Cụ thể, FaceHunter cải thiện độ chính xác trung bình (AP) khoảng 3% so với Hierarchical Deep Detector trên Pascal Faces, chứng minh hiệu quả thực tế của phương pháp đề xuất. <i>“We compare the performance of “Ours multi-task network without RPN” with hierarchical deep detector [10](expressed using the blue curve in Figs. 4–6), which trains a separate CNN network for the bounding box regression to refine another CNN network for face detector.”</i> (page 4/6), <i>“Our “multi-task network without RPN” can improve the average precision of hierarchical deep detector by about 1%, and FaceHunter even can improve it by about 3%”</i> (page 5/6).	5
6.5	Hệ thống đã lập trình sử dụng có qua kiểm tra hay chưa có phổ biến thành ứng dụng thực tế đc không?	- Hệ thống đã được lập trình và hiện thực hóa dựa trên mã nguồn mở Caffe và cuda-convnet, cho thấy tính khả thi về mặt kỹ thuật. <i>“Our implementation is based on the publicly available code of cuda-convnet and Caffe.”</i> (page 4/6).	5

=> **Điểm trung bình: 5 điểm**