

ĐÁNH GIÁ BÀI BÁO THEO TIÊU CHUẨN GOOD RESEARCH
A survey of deep neural network architectures and their applications

STT	Tiêu chí đánh giá	Lý giải dựa vào nội dung của bài báo	Đánh giá
1	Lựa chọn chủ đề hứa hẹn: những vấn đề thách thức và ít người làm trong lĩnh vực nghiên cứu của bạn	❖ Chủ đề rất hứa hẹn và mang tính thời sự cao (tại thời điểm 2017): - Bài báo tập trung vào "Deep Neural Network Architectures" (Các kiến trúc mạng nơ-ron sâu), giải quyết hạn chế của các thuật toán truyền thống phụ thuộc vào đặc trưng thủ công (hand-designed features). - Thách thức: Xử lý dữ liệu lớn (Big Data) và đạt hiệu suất cao trong các tác vụ AI phức tạp mà Backpropagation truyền thống gặp khó khăn (kẹt ở cực tiểu địa phương, overfitting). <i>"The past decade has seen rapid developments of deep learning techniques with significant impacts on signal and information processing... specific applications to computer vision, pattern recognition, speech recognition..."</i> (Abstract). - Tác giả nhấn mạnh tiềm năng vượt trội so với SVM hay KNN trong việc <i>"acting without being explicitly programmed"</i> (Introduction)	5
2	Đọc những khảo sát liên quan đến lĩnh vực nghiên cứu	❖ Bài báo thể hiện sự bao quát kiến thức rất rộng: - Tác giả đã đọc và tổng hợp lịch sử phát triển từ những năm 1980 (Backpropagation) đến cú hích năm 2006 của Hinton về Deep Belief Networks (DBN). - Khảo sát so sánh giữa Machine Learning truyền thống và Deep Learning. - Trích dẫn các khảo sát nền tảng khác: [101, 137, 165] để thảo luận thêm về AI mức độ con người (human-level AI) (Introduction). - Phân loại rõ ràng 4 kiến trúc chính: Autoencoder (AE), Convolutional Neural Network (CNN), Deep Belief Network (DBN), và Restricted Boltzmann Machine (RBM)	5
3	Tốn nhiều thời gian cho tham khảo	❖ Đầu tư rất lớn cho tài liệu tham khảo: - Bài báo có tới 177 tài liệu tham khảo (References), bao phủ từ các bài báo kinh điển của Hinton [59], LeCun [90, 91], Bengio [10] đến các nghiên cứu ứng dụng mới nhất năm 2015-2016 - Tác giả không chỉ liệt kê mà còn tóm tắt nội dung chính của các tham khảo quan trọng trong từng mục. Ví dụ: Tại mục 2.3 Variations of RBMs, tác giả phân tích chi tiết các biến thể như DRBMs (Larochelle & Bengio 2008), CRBMs (Mnih et al. 2012), RoBM (Tang et al. 2012). - Điều này chứng tỏ tác giả đã dành rất nhiều thời gian để đọc hiểu và phân loại tài liệu	5
4	Phát biểu bài toán thiết lập các cơ sở dữ liệu chuẩn và tiến hành thực nghiệm	❖ Mô tả thuật toán chi tiết: - Tác giả trình bày mã giả (Pseudo-code) cho các thuật toán cốt lõi, giúp người đọc dễ hình dung cách "thực thi": + Algorithm 1: k-step contrastive divergence for RBMs (Trang 13). + Algorithm 2: Greedy layer-by-layer algorithm for DBN (Trang 14). ❖ Cơ sở dữ liệu chuẩn (Benchmarks): - Bài báo điếm qua các bộ dữ liệu chuẩn mà các nghiên cứu trong lĩnh vực này thường dùng: MNIST (chữ viết tay), ImageNet (phân loại ảnh - trích dẫn sự kiện Hinton thắng giải 2012), TIMIT (nhận dạng tiếng nói). - <i>"Since 2009, the ImageNet's competition has attracted a great many computer vision research groups... In 2012, the research group led by Hinton won... 10% better than the second place."</i> (Mục 2.1) <i>Đây là bài báo Survey nên không có thực nghiệm riêng, tiêu chí này đánh giá dựa trên việc mô tả thuật toán và cơ sở dữ liệu của các nghiên cứu được trích dẫn</i>	4

5	Phân tích sâu kết quả thực nghiệm	(Đánh giá dựa trên khả năng tổng hợp và so sánh kết quả của bài Survey) ❖ Tác giả phân tích sâu thông qua việc so sánh kết quả thực nghiệm giữa các kiến trúc khác nhau: 1. So sánh hiệu suất trong nhận dạng hình ảnh (ImageNet): - Tác giả trích dẫn kết quả thực nghiệm mang tính bước ngoặt để chứng minh sức mạnh của Deep Learning so với các phương pháp cũ: <i>"In 2012, the research group led by Hinton won the competition... their results were 10% better than that in the second place."</i> 2. So sánh CNN và DNN trong nhận dạng tiếng nói (LVCSR): - Tác giả không chỉ nêu lý thuyết mà còn trích dẫn kết quả thực nghiệm để khẳng định ưu thế của CNN <i>"Experiment results in [134] showed that CNNs can achieve relatively better performance than DNNs for LVCSR tasks."</i> 3. So sánh các biến thể Autoencoder (k-sparse AE vs DAEs/RBMs): - Tác giả phân tích kết quả của các biến thể mới: <i>"The results obtained show that the k-sparse AEs perform better than the DAEs and RBMs. They claimed that the k-sparse AEs can be easily trained..."</i> 4. So sánh Deep Learning (DNN) với GMM truyền thống: <i>"Through some well-known datasets including the large vocabulary datasets, researchers have shown that DNNs could achieve better performance than GMMs on acoustic modeling for speech recognition."</i>	4
5.1	Bài báo có phân tích đủ chi tiết với các trường hợp thực nghiệm chưa ?	❖ Tác giả không chỉ liệt kê mà còn giải thích rõ động lực (motivation) ra đời của từng biến thể để khắc phục hạn chế của mô hình gốc: 1. Biến thể của RBM (Mục 2.3): - Vấn đề: RBM gốc chủ yếu dùng cho học không giám sát (unsupervised), đặc trưng trích xuất được có thể không hữu ích cho phân loại (supervised learning). - Giải pháp: <i>Discriminative RBMs (DRBMs)</i> ra đời. <i>"To handle these problems, discriminative restricted Boltzmann machines (DRBMs) was proposed... for classification tasks."</i> (Trang 13). 2. Biến thể của DBN (Mục 3.3): - Vấn đề: Khả năng mở rộng (scalability) khi huấn luyện với dữ liệu lớn là một thách thức. - Giải pháp: <i>Deep Convex Networks (DCNs)</i> được đề xuất. <i>"Deng and Yu [35] proposed a novel deep architecture, referred to as deep convex networks (DCNs), to overcome the shortcomings in learning scalability."</i> (Trang 14) 3. Biến thể của Autoencoder (AE) (Mục 4.3): - Vấn đề: AE truyền thống đơn thuần chỉ học cách nén và giải nén dữ liệu, dễ học các đặc trưng tầm thường (trivial solutions). - Giải pháp 1 (Denoising AE - DAE): Thêm nhiễu để tăng tính bền vững (robustness). <i>"The DAE intentionally adds noises into the training data... implies an enhanced robustness."</i> (Trang 15). - Giải pháp 2 (Contractive AE - CAE): Thêm thành phần phạt (penalty term) vào hàm mất mát để giảm độ nhạy của đặc trưng với đầu vào. <i>"This penalty term is employed to penalize the sensitivity of the features with respect to the inputs."</i> (Trang 16). 4. Biến thể của CNN (Mục 5.3): - Vấn đề: Cần xử lý các cấu trúc đệ quy hoặc tăng cường khả năng biểu diễn. - Giải pháp: <i>Recursive Convolutional Networks (RCNs)</i>. <i>"Eigen et al. [40] introduced a novel model called recursive convolutional networks (RCNs)." (Trang 17)</i>	5
5.2	a) Những lựa chọn nào đc xem xét ở những điểm khác nhau của thí nghiệm là gì? b) Làm thế nào lựa chọn thí nghiệm ? Tại sao và làm thế nào mà bạn chọn cái thực nghiệm này	a) Bài báo đã xem xét và so sánh các lựa chọn cấu hình (configurations) và phương pháp (methods) khác nhau trong các thí nghiệm được khảo sát: 1. Trong kiến trúc CNN (Mục 5.2 & 5.3): Lựa chọn phương pháp Pooling: Tác giả xem xét 3 loại pooling khác nhau để so sánh hiệu quả giảm chiều dữ liệu và bất biến dịch chuyển: + <i>Max pooling</i>: Lấy giá trị lớn nhất trong vùng lân cận (LeCun et al. [10]). + <i>Lp pooling</i>: Mô hình hóa sinh học lấy cảm hứng từ tế bào phức hợp (Sermanet et al. [138]). + <i>Stochastic pooling</i>: Chọn ngẫu nhiên activation dựa trên phân phối đa thức để điều chuẩn mạng lớn (Zeiler and Fergus [171]). Lựa chọn hàm kích hoạt: Xem xét hàm <i>Sigmoid</i> và so sánh với các hàm khác, chỉ ra lý do chọn Sigmoid trong CNN truyền thống là do ảnh hưởng nhẹ lên hạt nhân hàm (Trang 17). 2. Trong kiến trúc RBM (Mục 2.2 & 2.3): Lựa chọn thuật toán huấn luyện: Xem xét giữa <i>Contrastive Divergence (CD)</i> (Algorithm 1) và <i>Persistent Contrastive Divergence (PCD)</i>. Tác giả chỉ ra lựa chọn PCD tốt hơn khi learning rate nhỏ để xấp xỉ gradient chính xác hơn (Trang 13). Lựa chọn mô hình: So sánh giữa RBM cơ bản (Generative) và DRBM (Discriminative) cho các tác vụ phân loại. 3. Trong kiến trúc Autoencoder (Mục 4.3): Lựa chọn cơ chế ràng buộc: Xem xét các biến thể dựa trên cách ràng buộc khác nhau: + <i>Denoising AE (DAE)</i>: Thêm nhiễu vào đầu vào. + <i>Sparse AE</i>: Thêm ràng buộc thưa thớt (sparsity penalty term) vào hàm mất mát (Eq. 3). + <i>Contractive AE (CAE)</i>: Thêm thành phần phạt độ nhạy (penalty term on sensitivity) (Eq. 4). 4. Trong Ứng dụng Nhận dạng tiếng nói (Mục 6.1): Lựa chọn mô hình lai: Xem xét so sánh giữa <i>GMM-HMM</i> (truyền thống) và <i>DBN-HMM</i> hoặc <i>DNN-HMM</i> (hiện đại). Lựa chọn đầu vào: Xem xét việc sử dụng <i>triphone senones</i> làm nhãn huấn luyện so với <i>context-independent phones</i> (Trang 19) b) Cách thức và Lý do lựa chọn các thực nghiệm để đưa vào bài khảo sát: 1. Dựa trên các bộ dữ liệu chuẩn (Standard Benchmarks): - Tác giả chọn các thực nghiệm được thực hiện trên các bộ dữ liệu công khai uy tín nhất để đảm bảo tính khách quan và so sánh được: + MNIST: Cho nhận dạng chữ viết tay (được nhắc đến trong mục 2.1 và Abstract). + ImageNet: Cho phân loại ảnh quy mô lớn (Trang 12, mục 2.1). + TIMIT: Cho nhận dạng tiếng nói (Trang 14, mục 3.3). Lý do: Đây là thước đo chung của cộng đồng nghiên cứu, giúp minh chứng rõ ràng nhất sự vượt trội của Deep Learning so với các phương pháp cũ 2. Dựa trên các cuộc thi quốc tế (Competitions):	5

		- Tác giả chọn kết quả từ các cuộc thi lớn như ImageNet Large Scale Visual Recognition Challenge (ILSVRC) và trận đấu Google DeepMind AlphaGo. Đây là những mốc lịch sử (milestones) đánh dấu sự thay đổi mô hình (paradigm shift) từ Shallow sang Deep Learning. Dựa trên khả năng giải quyết vấn đề cụ thể: - Chọn thực nghiệm về <i>LVCSR (Large Vocabulary Continuous Speech Recognition)</i> trong mục 6.1.2. Để chứng minh khả năng mở rộng (scalability) của Deep Learning trên dữ liệu lớn mà GMM không làm được	
5.3	- Kết quả thực nghiệm có tính nhất quán với kết luận không?	❖ Hoàn toàn nhất quán: Thực nghiệm: Mục 6.1.2 chỉ ra DNN/CNN cải thiện nhận dạng tiếng nói <i>"The DNN-HMM system can be greatly improved by using triphone senones..."</i> (Trang 19). Kết luận: Tương ứng với tuyên bố trong Section 7 <i>"Applications of unsupervised... learning approaches to DNNs... With the development of deep unsupervised learning... we have more alternatives to train the DNNs for complex systems."</i> (Trang 22) ⇒ Về phần cứng: Thực nghiệm nhắc đến GPU (Trang 14), Kết luận nhắc đến Mobile devices (Trang 22) như một bước tiến tiếp theo cần thiết	5
5.4	Có thể tinh chỉnh một số thông số chính để có kết quả tốt hoặc tệ hơn không? Nếu có thì dùng hình minh hoạ hoặc bảng hiển thị hiệu suất hệ thống	❖ Có. Bài báo trình bày chi tiết các thông số cần tinh chỉnh và tác động của chúng: Learning & Momentum - Trong <i>Algorithm 1</i> (Trang 13) và <i>Algorithm 2</i> (Trang 14), ϵ là tham số quyết định tốc độ hội tụ. Tác giả lưu ý nếu chọn không khéo sẽ bị kẹt ở cực tiểu địa phương. Sparsity Parameter và Weight: - Trong <i>Sparse Autoencoder</i> (Eq. 3, Trang 16), tác giả chỉ rõ: ρ (sparsity parameter) thường là số nhỏ gần 0, và β kiểm soát trọng số của thành phần phạt. Việc tinh chỉnh β quyết định mức độ thừa thớt của đặc trưng. Temperature: - Trong <i>TRBMs</i> (Mục 2.3), nhiệt độ là tham số chính kiểm soát độ chọn lọc (selectivity) của nơ-ron ẩn. Tác giả khẳng định: "The performance of the proposed TRBMs can be enhanced by properly setting the sharpness parameter." (Trang 13) Regularization: Trong <i>Contractive Autoencoders</i> (Eq. 4, Trang 16), λ kiểm soát sự cân bằng giữa độ chính xác tái tạo và tính ổn định (robustness). Tinh chỉnh λ là bắt buộc để đạt kết quả tối ưu.	5
5.5	Kết quả thực nghiệm có tương ứng với mục tiêu bài báo hay không ?	Tương ứng hoàn toàn: Mục tiêu bài báo (Abstract): <i>"An up-to-date overview is provided on four deep learning architectures... Applications... are highlighted."</i> (Cung cấp cái nhìn tổng quan cập nhật về 4 kiến trúc và ứng dụng). Kết quả đạt được: + Bài báo đã trình bày đủ 4 kiến trúc: RBM (Sec 2), DBN (Sec 3), AE (Sec 4), CNN (Sec 5) với cấu trúc và thuật toán cụ thể. + Bài báo đã làm nổi bật ứng dụng trong 3 lĩnh vực chính: Speech (Sec 6.1), Vision (Sec 6.2), Pattern Recognition (highlighted throughout). + Các tài liệu tham khảo được cập nhật đến năm 2016 (ngay trước thời điểm đăng bài 2017), đáp ứng tiêu chí "Up-to-date"	5
5.6	Cái gì được tìm thấy là bất thường nên tránh trong thực nghiệm	❖ Bài báo chỉ ra các hiện tượng bất thường (Anomalies) và cạm bẫy (Pitfalls) cụ thể cần tránh: Hiện tượng "Fooling Images" (Ảnh đánh lừa): <i>Hiện tượng:</i> DNN có thể phân loại sai hoàn toàn các hình ảnh bị nhiễu mà mắt người không nhận ra sự khác biệt. <i>"DNNs can be easily fooled by unrecognizable images [124]."</i> (Trang 20). <i>Lời khuyên:</i> Cần thận trọng khi đánh giá độ tin cậy của DNN trong các ứng dụng an toàn cao. Vấn đề Gradient biến mất/bùng nổ và Cực tiểu địa phương: <i>Hiện tượng:</i> Backpropagation với khởi tạo ngẫu nhiên thường bị kẹt ở tối ưu cục bộ (local optima). <i>"The algorithm often gets trapped in local optima... causal chains of computational stages."</i> (Trang 11). <i>Lời khuyên:</i> Sử dụng Pre-training (DBN) hoặc các hàm kích hoạt mới. Ảnh hưởng của nhiễu đến RBM: <i>Hiện tượng:</i> Hiệu suất RBM giảm nghiêm trọng khi dữ liệu đầu vào có nhiễu (noise) hoặc bị che khuất (occlusions). <i>"Their performance may be severely degraded by the noises in the data [55]."</i> (Trang 13). <i>Lời khuyên:</i> Sử dụng Robust Boltzmann Machine (RoBM)	5
6	Tìm ra trường hợp thuyết phục		

6.1	Vấn đề cần giải quyết chính xác là gì?	❖ Vấn đề cốt lõi: - Sự hạn chế của các thuật toán Machine Learning truyền thống (Support Vector Machine, KNN) khi xử lý dữ liệu lớn (Big Data) và dữ liệu phi cấu trúc (ảnh, giọng nói) do phụ thuộc vào việc trích chọn đặc trưng thủ công (hand-designed features). "...overcoming the drawback of traditional algorithms dependent on hand-designed features. Deep learning approaches have also been found to be suitable for big data analysis..." (Abstract). - Vấn đề kẹt ở cực tiểu địa phương (local optima) của mạng nơ-ron truyền thống khi dùng Backpropagation (Introduction, trang 11)	5
6.2	Ý tưởng đang xem xét có hiệu quả đáng kể ko ?	❖ Hiệu quả rất đáng kể, được minh chứng bằng các sự kiện lịch sử: - Vượt trội trong ImageNet: Hinton thắng giải 2012 với kết quả tốt hơn 10% so với á quân (Trang 12). - Chiến thắng con người: AlphaGo đánh bại Lee Se-dol tỷ số 4:1 (Trang 12). - Cải thiện Speech Recognition: Trong bảng xếp hạng ngữ âm TIMIT, DBNs đạt được thành công lớn, thúc đẩy việc thay thế mô hình GMM truyền thống.
 + <i>Trích dẫn:</i> "...deep learning architectures are now replacing the GMMs in speech recognition [33,58]." (Trang 19, cột 1)	5
6.3	Chất lượng của những bài báo nghiên cứu tham chiếu thế nào ?	❖ Chất lượng tham chiếu cực kỳ cao (Top-tier): - Tác giả tham chiếu đến các nguồn uy tín nhất trong lịch sử AI: + Geoffrey Hinton: [59] bài báo năm 2006 về DBN trên <i>Neural Computation</i> (khởi đầu kỷ nguyên Deep Learning). + Yann LeCun: [90, 91] bài báo trên <i>Nature</i> (2015) và <i>Proceedings of the IEEE</i> (1998) về CNN.
+ Yoshua Bengio: [10] bài báo năm 2009 về Learning Deep Architectures. - Các hội nghị trích dẫn đều là A/A*: NIPS (nay là NeurIPS), ICML, CVPR, ICCV, AAAI. - Việc sử dụng các tài liệu "gốc" (seminal papers) đảm bảo độ tin cậy tuyệt đối cho bài Survey	5
6.4	Việc so sánh với các nghiên cứu của tác giả với các trường hợp trước đây có tốt hay ko có hiệu quả hay không	❖ So sánh rất tốt và đa chiều: - So sánh Deep vs Shallow: Tác giả so sánh DBN với SVM, Boosting, KNN. Chỉ ra rằng DBNs đạt "global optimum with lower power consumption" nhờ pre-training (Trang 12). - So sánh CNN vs Neocognitron: Phân tích sự khác biệt kỹ thuật (CNN dùng shared weights còn Neocognitron thì không) để thấy sự tiên bộ (Trang 16). - So sánh AE vs PCA: Tác giả liên hệ Autoencoder với các phương pháp giảm chiều dữ liệu truyền thống (Dimensionality Reduction) để người đọc dễ hình dung. "Essentially, the AE tries to approximate the identity function... transform into a lower dimensional representation..." (Trang 15)	5
6.5	Hệ thống đã lập trình sử dụng có qua kiểm tra hay chưa có phổ biến thành ứng dụng thực tế đc không?	❖ Hệ thống đã được kiểm chứng và phổ biến rộng rãi: - Triển khai công nghiệp: Bài báo nêu rõ: "Both Google and Baidu have updated their image search engines based on Hinton's deep learning architecture" (Trang 12). - Thư viện/Framework: Dù bài báo tập trung vào lý thuyết, nhưng các tài liệu tham khảo [42] (Theano), [86] (Caffe/AlexNet implementation) cho thấy các hệ thống này đã được cộng đồng mã nguồn mở kiểm tra và sử dụng. - Ứng dụng y tế: DBNs được dùng trong hệ thống chẩn đoán ung thư vú (CAD), CNNs dùng cho phát hiện Glaucoma (Trang 21). "Many high-tech enterprises such as Google, Facebook and Microsoft... attracted by deep learning." (Trang 18).	5

⇒ Điểm trung bình: 4.87

