

ĐÁNH GIÁ BÀI BÁO THEO TIÊU CHUẨN GOOD RESEARCH

Bounded activation functions for enhanced training stability of deep neural networks on visual pattern recognition problems

STT	Tiêu chí đánh giá	Lý giải dựa vào nội dung của bài báo	Đánh giá
1	Lựa chọn chủ đề hứa hẹn: những vấn đề thách thức và ít người làm trong lĩnh vực nghiên cứu của bạn	❖ Vấn đề cốt lõi ít được chú trọng: Tác giả chỉ ra rằng trong khi cộng đồng tập trung nhiều vào kiến trúc mạng (architecture) hay thuật toán học (learning algorithm), thì tác động của hàm kích hoạt (activation function) đối với độ ổn định khi huấn luyện (training stability) thường bị bỏ qua. Đây là một vấn đề tiềm ẩn nhưng rất quan trọng. <i>"However, the impact of an activation function on the generalization performance and training stability of a DNN is often ignored. There is a lack of consensus on how to select a good activation function for an NN model..."</i> ❖ Thách thức thực tế về tính toán số học: Bài báo giải quyết vấn đề cụ thể là sự mất ổn định số học (numerical instability) và lỗi tràn số (overflow/underflow) khi sử dụng các hàm không bị chặn (như ReLU) trên các hệ thống phần cứng giới hạn hoặc khi mạng quá sâu. <i>"The numerical stability during a training process is also crucial to avoid numerical underflow or overflow problem that can render the whole training useless [4]."</i>, <i>"However, the output boundary issue is very important, especially in embedded system applications or dedicated hardware design where the number representation is limited..."</i> ❖ Chủ đề hứa hẹn: Việc đề xuất các hàm kích hoạt mới giúp mạng hội tụ nhanh hơn và ổn định hơn mà không cần các kỹ thuật phức tạp (như weight regularization) là một hướng đi rất hứa hẹn để tối ưu hóa Deep Learning.	5
2	Đọc những khảo sát liên quan đến lĩnh vực nghiên cứu	❖ Hệ thống hóa các nghiên cứu trước: Trong Section 2. Activation functions, tác giả đã khảo sát và phân loại rất rõ ràng các nhóm hàm kích hoạt hiện có thành hai loại chính: ❖ Sigmoidal functions (Hàm hình S): Phân tích rõ các biến thể như Logistic (logsig), Hyperbolic tangent (tanh). Tác giả chỉ ra nhược điểm lớn nhất là "gradient diffusion" (hay vanishing gradient) do vùng bão hòa lớn. <i>"Despite their popularity... sigmoidal functions can suffer badly from gradient diffusion problem... Small gradients can hurt overall training performance..."</i> ❖ Non-sigmoidal functions (Hàm không hình S): Khảo sát các hàm hiện đại như ReLU, Leaky ReLU [40], Bi-firing [10]. Tác giả chỉ ra ưu điểm là hiệu quả tính toán nhưng nhược điểm là đầu ra không giới hạn (unbounded outputs) gây mất ổn định. <i>"Overall, all variants of the ReLU function are susceptible to training instability due to their unbounded outputs..."</i> ❖ Cơ sở lý thuyết vững chắc: Tác giả dựa trên Định lý xấp xỉ vạn năng (Universal Approximation Theorem - UAT) [25] để liệt kê 5 tính chất cần có của một hàm kích hoạt 1. The output is non-constant for all ranges of inputs; 2. Bounded within a range of values, where there exists a real number P such that $f(x) \leq P$; 3. Continuous over all values of point c of its domain, where $\lim_{x \rightarrow c} f(x) = f(c)$; 4. Monotonically increasing, where $x \leq y$ and $f(x) \leq f(y)$; and 5. Differentiable everywhere, i.e. the slope of the tangent line of points from the left is approaching the same value as another slope of the tangent of points from the right. , từ đó làm cơ sở để đánh giá các nghiên cứu liên quan.	5
3	Tốn nhiều thời gian cho tham khảo	❖ Phân tích sâu và cải tiến tham khảo số [29] (LeCun et al.): Tác giả không chỉ trích dẫn mà còn tính toán lại toán học của tài liệu tham khảo. Cụ thể, đối với hàm <i>scaled hyperbolic tangent (stanh)</i> trong [29], tác giả phát hiện các hệ số cũ được chọn "chỉ vì sự thuận tiện" và đề xuất bộ hệ số mới tối ưu hơn dựa trên đạo hàm bậc hai. <i>"The authors in [29] stated that the function is more suitable... However, the authors did mention that the particular choice of parameters is merely a convenience... This work aims to determine the exact parameter values (coefficients)..."</i> ❖ Tác giả thực hiện chứng minh toán học từ phương trình (15) đến (20) tại mục 3.5 để tìm ra hệ số $A=1.7321$ và $B=0.6585$ tối ưu hơn ❖ Mở xẻ hạn chế của tham khảo số [10] (Bi-firing): Tác giả hiểu rất rõ cơ chế của hàm Bi-firing và chỉ ra rằng dù nó giảm bão hòa nhưng tính chất "unbounded" buộc nó phải dùng thêm cơ chế phạt trọng số (weight penalty), làm tăng chi phí tính toán. <i>"However, the authors stated that it can cause numerical problems due to its unbounded nature, thus it requires a weight penalty mechanism... This induces more computational complexity..."</i>	5
4	Phát biểu bài toán thiết lập các cơ sở dữ liệu chuẩn và tiến hành thực nghiệm	❖ Phát biểu bài toán: Bài báo phát biểu rõ ràng bài toán cần giải quyết là cải thiện độ ổn định và khả năng tổng quát hóa của DNN bằng cách giới hạn đầu ra của hàm kích hoạt. ❖ Thiết lập cơ sở dữ liệu chuẩn (Benchmark Databases): Tác giả sử dụng 3 bộ dữ liệu chuẩn mục để đánh giá toàn diện (Mục 4.1): ▪ MNIST: Bộ dữ liệu kinh điển cho nhận dạng chữ viết tay để làm cơ sở so sánh chuẩn (Benchmarking). ▪ mnist-rot-bg-img: Một biến thể phức tạp của MNIST (có xoay, nền nhiễu) để kiểm tra khả năng xử lý các biến đổi phức tạp. ▪ AR Purdue face database: Bộ dữ liệu khuôn mặt thực tế để kiểm chứng trên bài toán nhận dạng khuôn mặt (Face recognition) với các biến đổi ánh sáng và biểu cảm. ❖ Tiến hành thực nghiệm (Implementation): Tác giả xây dựng hệ thống rất công phu. Thay vì dùng các thư viện có sẵn (như Caffe, Theano - vốn có cơ chế tự động xử lý lỗi số học), tác giả đã tự code từ đầu bằng C++ để kiểm soát hoàn toàn các vấn đề tràn số, đảm bảo kết quả đánh giá về độ ổn định là chính xác nhất. <i>"In this work, all training procedures, learning algorithms and NN models are developed from scratch. All codes are written in C/C++."</i>, <i>"No weight regularization techniques are applied... hence evaluating the sole effect of bounding an activation function..." (4.4</i>	5

		<i>Implementation details).</i>	
--	--	---------------------------------	--

		❖ Quá trình tiền xử lý ảnh (Preprocessing): ▪ Đối với MNIST và mnist-rot-bg-img: Ảnh xám 28x28 pixel. ▪ Đối với AR Purdue: Ảnh màu RGB được chuyển sang ảnh xám (grayscale) và thay đổi kích thước (resize) về 56x46 pixel. ▪ Áp dụng phương pháp chuẩn hóa Z-score (z-score normalization) cho tất cả các ảnh đầu vào để đưa giá trị pixel về phân phối chuẩn (Mục 4.1, Công thức 21-23). Không sử dụng các kỹ thuật tăng cường dữ liệu (data augmentation) khác để đảm bảo tính công bằng. ❖ Các mô hình mạng nơ-ron (Neural Network Models): ▪ MLP (Multi-layer Perceptron): Mạng 7 lớp (Table 1) dùng để so sánh chuẩn (benchmarking) trên tập mnist-rot-bg-img. ▪ CNN1: Mạng tích chập 7 lớp (Table 2) với các lớp Convolution và Max-pooling xen kẽ, dùng cho tập dữ liệu chữ viết tay. ▪ CNN2: Mạng tích chập sâu hơn (Table 3), được thiết kế dựa trên nghiên cứu trước đó [55] để phù hợp với bài toán nhận diện khuôn mặt trên tập AR Purdue. ❖ Phương pháp huấn luyện và Cài đặt hệ thống (Implementation Details): ▪ Toàn bộ mã nguồn được viết từ đầu (from scratch) bằng ngôn ngữ C/C++ để kiểm soát hoàn toàn các vấn đề số học, không sử dụng thư viện có sẵn. ▪ Sử dụng trình biên dịch G++ (tối ưu hóa O3) trên hệ điều hành Ubuntu 14.04 LTS. ▪ Phần cứng thực nghiệm: CPU Intel Core i7 4790K xung nhịp 4.5 GHz. ▪ Đặc biệt: Không áp dụng bất kỳ kỹ thuật điều chuẩn trọng số nào (No weight regularization) trong tất cả thí nghiệm để đánh giá tác động thuần túy của hàm kích hoạt. ▪ Khởi tạo trọng số theo phương pháp chuẩn hóa (Normalized weight initialization [58]) và xáo trộn mẫu (shuffling) đầu mỗi epoch. ❖ Các chỉ số đánh giá hiệu suất: Bao gồm tỷ lệ lỗi phân loại (Testing Misclassification Error Rates - MCR), xác suất mất ổn định số học (Probability of numerical instability - NaN/Inf), thời gian thực thi (Time), và giá trị hàm mất mát (Loss value).																							
5	Phân tích sâu kết quả thực nghiệm	• Phân tích đa chiều: Tác giả không chỉ báo cáo độ chính xác (Accuracy/MCR) mà còn phân tích sâu về Hiệu quả huấn luyện (Training efficiency) và Độ ổn định (Training stability). • So sánh chi tiết: Kết quả được so sánh trên cả hai hàm mất mát MSE và Cross-Entropy (CE), chứng minh sự vượt trội nhất quán của phương pháp đề xuất	5																						
5.1	Bài báo có phân tích đủ chi tiết với các trường hợp thực nghiệm chưa ?	❖ Bài báo đã phân tích đủ chi tiết với các trường hợp thực nghiệm cụ thể: ❖ Trường hợp so sánh chuẩn (Benchmarking) với các nghiên cứu trước (Mục 5.1): ▪ So sánh ReLU: Hàm đề xuất brelu đạt MCR 50.09% so với relu gốc là 51.98%. ▪ So sánh Leaky ReLU: Hàm đề xuất blrelu đạt MCR 49.88% so với lrelu gốc là 50.52%. ▪ So sánh Bi-firing: Hàm đề xuất bbifire (48.97%) so với bifire gốc (48.75%). Tác giả phân tích chi tiết rằng sự chênh lệch nhỏ 0.22% này là chấp nhận được vì bbifire ổn định hơn. ▪ So sánh Tanh: Hàm stanh với tham số mới đề xuất đạt MCR 49.89%, vượt trội so với tanh gốc (53.17%) và stanh tham số cũ (50.12%). ▪ Tác giả phân tích rõ ràng sự khác biệt về điều kiện thí nghiệm so với nghiên cứu [10]: Nghiên cứu này chỉ train 100 epochs và không dùng regularization, trong khi nghiên cứu cũ train >= 200 epochs và có dùng regularization. Dù điều kiện khắc nghiệt hơn, các hàm đề xuất vẫn cho kết quả tương đương hoặc tốt hơn, chứng minh tính ưu việt về khả năng tổng quát hóa. Table 5 Testing MCRs of the MLPs with different activation functions on the <i>mnist-rot-bg-img</i> dataset. The bolded functions denote the proposed functions. <table><tr><th>Activation function</th><th>Testing MCR (%)</th></tr><tr><td>logsig [10]</td><td>62.64</td></tr><tr><td>relu [10]</td><td>51.98</td></tr><tr><td>brelu</td><td>50.09</td></tr><tr><td>lrelu</td><td>50.52</td></tr><tr><td>blrelu</td><td>49.88</td></tr><tr><td>bifire [10]</td><td>48.75</td></tr><tr><td>bbifire</td><td>48.97</td></tr><tr><td>tanh [10]</td><td>53.17</td></tr><tr><td>stanh</td><td>50.12</td></tr><tr><td>stanh</td><td>49.89</td></tr></table> ❖ Trường hợp phân tích hiệu quả huấn luyện (Training efficiency - Mục 5.2): ▪ Chỉ ra rằng hàm brelu có giá trị loss khởi tạo thấp hơn hẳn relu (0.0068 so với 0.1634). ▪ Tốc độ giảm loss của brelu nhanh hơn và đạt mức loss cuối cùng thấp hơn (0.0019 so với 0.0033). ▪ Kết luận rằng việc giới hạn biên giúp kiểm soát phân phối đầu ra tốt hơn, thúc đẩy mạng hội tụ nhanh hơn.	Activation function	Testing MCR (%)	logsig [10]	62.64	relu [10]	51.98	brelu	50.09	lrelu	50.52	blrelu	49.88	bifire [10]	48.75	bbifire	48.97	tanh [10]	53.17	stanh	50.12	stanh	49.89	5
Activation function	Testing MCR (%)																								
logsig [10]	62.64																								
relu [10]	51.98																								
brelu	50.09																								
lrelu	50.52																								
blrelu	49.88																								
bifire [10]	48.75																								
bbifire	48.97																								
tanh [10]	53.17																								
stanh	50.12																								
stanh	49.89																								




Fig. 12. Training efficiencies of the CNNs with the *relu* and *brelu* functions: (a) training losses and (b) testing MCRs using the MSE loss function; and (c) training losses and (d) testing MCRs using the CE loss function.

- ❖ Trường hợp phân tích trên các hàm mất mát khác nhau:
- Bài báo không chỉ dừng lại ở một trường hợp mà phân tích trên cả hai hàm mất mát phổ biến nhất là MSE và Softmax + Cross Entropy (CE).
 - Kết quả cho thấy sự nhất quán: Dù dùng hàm loss nào, các hàm kích hoạt bị chặn (bounded) vẫn cho kết quả MCR thấp hơn và ổn định hơn

Table 6
Results of the CNN models using different activation functions on MNIST dataset.
The bolded functions denote the proposed functions.

Activation function	WTA + MSE			Softmax + CE		
	MCR (%)		Time (s)	MCR (%)		Time (s)
	Training	Testing		Training	Testing	
<i>relu</i>	0.14	0.97	49.97	0.00	1.02	24.58
<i>brelu</i>	0.18	0.94	32.60	0.10	0.92	40.61
<i>lrelu</i>	0.07	0.95	52.48	0.01	1.06	26.50
<i>blrelu</i>	0.11	0.96	44.08	0.01	0.96	48.48
<i>bifire</i>	0.71	0.89	58.10	0.79	1.04	33.14
<i>bbifire</i>	0.81	0.90	57.17	0.01	0.86	52.04
<i>tanh</i>	0.19	1.01	62.01	0.57	1.09	58.80
<i>stanh</i>	0.87	1.19	62.84	0.29	1.07	59.19
<i>stanh</i>	0.56	0.99	63.33	0.29	0.99	61.86

5.2	a) Những lựa chọn nào đc xem xét ở những điểm khác nhau của thí nghiệm là gì? b) Làm thế nào lựa chọn thí nghiệm ? Tại sao và làm thế nào mà bạn chọn cái thực nghiệm này	a) ▪ Các loại hàm kích hoạt: Tác giả xem xét đối chiếu từng cặp: ReLU vs Bounded ReLU, Leaky ReLU vs Bounded Leaky ReLU, Bi-firing vs Bounded Bi-firing, Tanh vs Scaled Tanh. ▪ Hàm mất mát (Loss Functions): Thí nghiệm được thực hiện trên cả Mean Squared Error (MSE) và Cross-Entropy (CE) để xem xét tính hiệu quả của hàm kích hoạt trên các cơ chế tối ưu lỗi khác nhau. ▪ Kiến trúc mạng: Thí nghiệm trên cả mạng MLP (Table 1) và mạng CNN (CNN1, CNN2 - Table 2, 3) để đảm bảo giải pháp hiệu quả trên các độ sâu mạng khác nhau. ▪ Tham số biên (Boundary parameters): Trong Table 4, tác giả xem xét các giá trị biên trên (Upper boundary A) khác nhau (1, 2, 4, 8, 16, 32, 64) để tìm ra giá trị tối ưu. b) ▪ Lựa chọn tập dữ liệu: Tác giả chọn MNIST vì đây là chuẩn mực, chọn mnist-rot-bg-img để tăng độ khó (complexity) và AR Purdue để kiểm chứng tính thực tế (real-world applicability). ▪ Cách thiết lập môi trường (Why "from scratch"?): Tác giả chọn tự viết code C++ (không dùng thư viện) để loại bỏ các cơ chế bảo vệ ngầm ("safeguards") của các thư viện Deep Learning hiện đại. Điều này giúp phơi bày rõ ràng nhất sự mất ổn định của các hàm không bị chặn (unbounded).<i>"Many NN libraries automatically detect and stabilize common numerically unstable expressions... thus this issue is not of the concern in these cases. However... in embedded system applications... it can bring significant impact..." (Mục 2.2).</i> ▪ Cách chọn tham số: Các tham số A và B cho hàm stanh được chọn dựa trên tính toán toán học (đạo hàm bậc 2) ở mục 3.5 thay vì chọn ngẫu nhiên, sau đó được kiểm chứng lại bằng thực nghiệm.	5																																																																																																												
5.3	Kết quả thực nghiệm có tính nhất quán với kết luận không?	• Hoàn toàn nhất quán: ○ Kết luận 1: Hàm bị chặn giúp tăng độ ổn định. ▪ <i>Minh chứng thực nghiệm:</i> Bảng 11 cho thấy xác suất lỗi (Numerical instability) giảm từ 100% (bifire) xuống 0% (bbifire) trên tập AR Purdue. Điều này khớp với tuyên bố trong Abstract: "the problem is completely eliminated". Table 11 Probability of numerical instability for the CNN models using different activation functions on the AR Purdue dataset. The bolded functions denote the proposed functions. <table><tr><th>Activation</th><th colspan="2">Probability of numerical instability (%)</th></tr><tr><th>function</th><th>WTA+MSE</th><th>Softmax+CE</th></tr><tr><td>relu</td><td>0.00</td><td>0.00</td></tr><tr><td>brelu</td><td>0.00</td><td>0.00</td></tr><tr><td>lrelu</td><td>80.00</td><td>0.00</td></tr><tr><td>blrelu</td><td>31.43</td><td>0.00</td></tr><tr><td>bifire</td><td>100.00</td><td>45.00</td></tr><tr><td>bbifire</td><td>0.00</td><td>0.00</td></tr></table> ○ Kết luận 2: Hàm bị chặn cải thiện độ chính xác (Generalization performance). ▪ <i>Minh chứng thực nghiệm:</i> Bảng 8 cho thấy MCR của blrelu (0.90%) tốt hơn nhiều so với lrelu (5.50%) trên tập AR Purdue (WTA+MSE). Con số cải thiện 74.99% nhắc đến trong Abstract được tính toán chính xác từ các bảng kết quả này. Table 8 Results of the CNN models using different activation functions on the AR Purdue dataset. The bolded functions denote the proposed functions. <table><tr><th>Activation</th><th colspan="3">WTA+MSE</th><th colspan="3">Softmax+CE</th></tr><tr><th>function</th><th colspan="2">MCR (%)</th><th>Time</th><th colspan="2">MCR (%)</th><th>Time</th></tr><tr><th></th><th>Training</th><th>Testing</th><th>(s)</th><th>Training</th><th>Testing</th><th>(s)</th></tr><tr><td>relu</td><td>16.50</td><td>20.50</td><td>8.93</td><td>11.85</td><td>19.67</td><td>8.47</td></tr><tr><td>brelu</td><td>12.90</td><td>17.33</td><td>7.84</td><td>8.95</td><td>16.50</td><td>8.19</td></tr><tr><td>lrelu</td><td>5.50</td><td>16.67</td><td>9.06</td><td>0.05</td><td>7.67</td><td>8.65</td></tr><tr><td>blrelu</td><td>0.90</td><td>4.17</td><td>8.90</td><td>0.15</td><td>7.00</td><td>8.40</td></tr><tr><td>bifire</td><td>OF</td><td></td><td>N/A</td><td>0.00</td><td>7.33</td><td>8.85</td></tr><tr><td>bbifire</td><td>3.70</td><td>7.17</td><td>9.22</td><td>0.10</td><td>6.67</td><td>9.45</td></tr><tr><td>tanh</td><td>1.45</td><td>10.00</td><td>10.38</td><td>0.25</td><td>10.83</td><td>10.36</td></tr><tr><td>stanh</td><td>0.25</td><td>4.83</td><td>9.85</td><td>0.00</td><td>8.33</td><td>10.25</td></tr><tr><td>stanh</td><td>0.00</td><td>2.67</td><td>9.87</td><td>0.00</td><td>7.00</td><td>10.27</td></tr></table>	Activation	Probability of numerical instability (%)		function	WTA+MSE	Softmax+CE	relu	0.00	0.00	brelu	0.00	0.00	lrelu	80.00	0.00	blrelu	31.43	0.00	bifire	100.00	45.00	bbifire	0.00	0.00	Activation	WTA+MSE			Softmax+CE			function	MCR (%)		Time	MCR (%)		Time		Training	Testing	(s)	Training	Testing	(s)	relu	16.50	20.50	8.93	11.85	19.67	8.47	brelu	12.90	17.33	7.84	8.95	16.50	8.19	lrelu	5.50	16.67	9.06	0.05	7.67	8.65	blrelu	0.90	4.17	8.90	0.15	7.00	8.40	bifire	OF		N/A	0.00	7.33	8.85	bbifire	3.70	7.17	9.22	0.10	6.67	9.45	tanh	1.45	10.00	10.38	0.25	10.83	10.36	stanh	0.25	4.83	9.85	0.00	8.33	10.25	stanh	0.00	2.67	9.87	0.00	7.00	10.27	5
Activation	Probability of numerical instability (%)																																																																																																														
function	WTA+MSE	Softmax+CE																																																																																																													
relu	0.00	0.00																																																																																																													
brelu	0.00	0.00																																																																																																													
lrelu	80.00	0.00																																																																																																													
blrelu	31.43	0.00																																																																																																													
bifire	100.00	45.00																																																																																																													
bbifire	0.00	0.00																																																																																																													
Activation	WTA+MSE			Softmax+CE																																																																																																											
function	MCR (%)		Time	MCR (%)		Time																																																																																																									
	Training	Testing	(s)	Training	Testing	(s)																																																																																																									
relu	16.50	20.50	8.93	11.85	19.67	8.47																																																																																																									
brelu	12.90	17.33	7.84	8.95	16.50	8.19																																																																																																									
lrelu	5.50	16.67	9.06	0.05	7.67	8.65																																																																																																									
blrelu	0.90	4.17	8.90	0.15	7.00	8.40																																																																																																									
bifire	OF		N/A	0.00	7.33	8.85																																																																																																									
bbifire	3.70	7.17	9.22	0.10	6.67	9.45																																																																																																									
tanh	1.45	10.00	10.38	0.25	10.83	10.36																																																																																																									
stanh	0.25	4.83	9.85	0.00	8.33	10.25																																																																																																									
stanh	0.00	2.67	9.87	0.00	7.00	10.27																																																																																																									

- **Kết luận 3:** Bộ tham số mới cho hàm Tanh tốt hơn bộ cũ.
 - *Minh chứng thực nghiệm:* Hình 15 và Bảng 6 cho thấy đường cong loss của *stanh* (tham số mới) thấp hơn và MCR tốt hơn so với *tanh* gốc.





Fig. 15. Training efficiencies of the CNNs with the *tanh* function with different sets of coefficient values: (a) training losses and (b) testing MCRs using the MSE loss function; and (c) training losses and (d) testing MCRs using the CE loss function.

Table 6
Results of the CNN models using different activation functions on MNIST dataset.
The bolded functions denote the proposed functions.

Activation function	WTA + MSE			Softmax + CE		
	MCR (%)		Time (s)	MCR (%)		Time (s)
	Training	Testing		Training	Testing	
<i>relu</i>	0.14	0.97	49.97	0.00	1.02	24.58
<i>brelu</i>	0.18	0.94	32.60	0.10	0.92	40.61
<i>lrelu</i>	0.07	0.95	52.48	0.01	1.06	26.50
<i>blrelu</i>	0.11	0.96	44.08	0.01	0.96	48.48
<i>bifire</i>	0.71	0.89	58.10	0.79	1.04	33.14
<i>bbifire</i>	0.81	0.90	57.17	0.01	0.86	52.04
<i>tanh</i>	0.19	1.01	62.01	0.57	1.09	58.80
<i>stanh</i>	0.87	1.19	62.84	0.29	1.07	59.19
<i>stanh</i>	0.56	0.99	63.33	0.29	0.99	61.86

	• Có thể tinh chỉnh và tác giả đã thực hiện rất kỹ: Bài báo dành riêng mục 3.5. Better coefficient values for the scaled hyperbolic tangent function và Table 4 để thảo luận về việc tinh chỉnh tham số. • Minh chứng về dải tham số: Trong Table 4, tác giả liệt kê các tham số siêu hình (hyperparameters) A và B cho các hàm giới hạn (bounded functions). Ví dụ, với hàm <i>bbifire</i>, tác giả thử nghiệm A trong khoảng $\{0.01, 0.1, 0.3, 0.5\}$ và B trong $\{1, 4, 16\}$. • Minh chứng về hiệu quả của việc tinh chỉnh (Trường hợp hàm Tanh): ○ Tác giả so sánh 3 biến thể: (1) <i>tanh</i> gốc, (2) <i>stanh</i> với hệ số cũ (LeCun et al. [29]), và (3) <i>stanh</i> với hệ số mới do tác giả đề xuất (được tính toán toán học tại mục 3.5). ○ Hình minh họa: Fig. 15 (Training efficiencies of CNNs with tanh function) cho thấy đường cong loss (hình a, c) và lỗi phân loại (hình b, d) của <i>stanh</i> (hệ số mới - màu xanh dương) thấp hơn và ổn định hơn so với hai loại còn lại.  Fig. 15. Training efficiencies of the CNNs with the <i>tanh</i> function with different sets of coefficient values: (a) training losses and (b) testing MCRs using the MSE loss function; and (c) training losses and (d) testing MCRs using the CE loss function. ○ Bảng hiển thị hiệu suất: Table 6 (Results on MNIST) minh chứng rõ ràng: Table 6 Results of the CNN models using different activation functions on MNIST dataset. The bolded functions denote the proposed functions. <table><tr><th rowspan="3">Activation function</th><th colspan="3">WTA + MSE</th><th colspan="3">Softmax + CE</th></tr><tr><th colspan="2">MCR (%)</th><th rowspan="2">Time (s)</th><th colspan="2">MCR (%)</th><th rowspan="2">Time (s)</th></tr><tr><th>Training</th><th>Testing</th><th>Training</th><th>Testing</th></tr><tr><td><i>relu</i></td><td>0.14</td><td>0.97</td><td>49.97</td><td>0.00</td><td>1.02</td><td>24.58</td></tr><tr><td><i>brelu</i></td><td>0.18</td><td>0.94</td><td>32.60</td><td>0.10</td><td>0.92</td><td>40.61</td></tr><tr><td><i>lrelu</i></td><td>0.07</td><td>0.95</td><td>52.48</td><td>0.01</td><td>1.06</td><td>26.50</td></tr><tr><td><i>blrelu</i></td><td>0.11</td><td>0.96</td><td>44.08</td><td>0.01</td><td>0.96</td><td>48.48</td></tr><tr><td><i>bifire</i></td><td>0.71</td><td>0.89</td><td>58.10</td><td>0.79</td><td>1.04</td><td>33.14</td></tr><tr><td><i>bbifire</i></td><td>0.81</td><td>0.90</td><td>57.17</td><td>0.01</td><td>0.86</td><td>52.04</td></tr><tr><td><i>tanh</i></td><td>0.19</td><td>1.01</td><td>62.01</td><td>0.57</td><td>1.09</td><td>58.80</td></tr><tr><td><i>stanh</i></td><td>0.87</td><td>1.19</td><td>62.84</td><td>0.29</td><td>1.07</td><td>59.19</td></tr><tr><td><i>stanh</i></td><td>0.56</td><td>0.99</td><td>63.33</td><td>0.29</td><td>0.99</td><td>61.86</td></tr></table> Ở bảng 5: (MLP), <i>stanh</i> mới đạt 49.89% tốt hơn <i>stanh</i> cũ 50.12%. Table 5 Testing MCRs of the MLPs with different activation functions on the <i>mnist-rot-bg-img</i> dataset. The bolded functions denote the proposed functions. <table><tr><th>Activation function</th><th>Testing MCR (%)</th></tr><tr><td><i>logsig</i> [10]</td><td>62.64</td></tr><tr><td><i>relu</i> [10]</td><td>51.98</td></tr><tr><td><i>brelu</i></td><td>50.09</td></tr><tr><td><i>lrelu</i></td><td>50.52</td></tr><tr><td><i>blrelu</i></td><td>49.88</td></tr><tr><td><i>bifire</i> [10]</td><td>48.75</td></tr><tr><td><i>bbifire</i></td><td>48.97</td></tr><tr><td><i>tanh</i> [10]</td><td>53.17</td></tr><tr><td><i>stanh</i></td><td>50.12</td></tr><tr><td><i>stanh</i></td><td>49.89</td></tr></table> <i>"Applying the proposed coefficient values to the stanh function manages to achieve an even lower MCR of 49.89% only."</i> (Mục 5.1).	Activation function	WTA + MSE			Softmax + CE			MCR (%)		Time (s)	MCR (%)		Time (s)	Training	Testing	Training	Testing	<i>relu</i>	0.14	0.97	49.97	0.00	1.02	24.58	<i>brelu</i>	0.18	0.94	32.60	0.10	0.92	40.61	<i>lrelu</i>	0.07	0.95	52.48	0.01	1.06	26.50	<i>blrelu</i>	0.11	0.96	44.08	0.01	0.96	48.48	<i>bifire</i>	0.71	0.89	58.10	0.79	1.04	33.14	<i>bbifire</i>	0.81	0.90	57.17	0.01	0.86	52.04	<i>tanh</i>	0.19	1.01	62.01	0.57	1.09	58.80	<i>stanh</i>	0.87	1.19	62.84	0.29	1.07	59.19	<i>stanh</i>	0.56	0.99	63.33	0.29	0.99	61.86	Activation function	Testing MCR (%)	<i>logsig</i> [10]	62.64	<i>relu</i> [10]	51.98	<i>brelu</i>	50.09	<i>lrelu</i>	50.52	<i>blrelu</i>	49.88	<i>bifire</i> [10]	48.75	<i>bbifire</i>	48.97	<i>tanh</i> [10]	53.17	<i>stanh</i>	50.12	<i>stanh</i>	49.89	
Activation function	WTA + MSE			Softmax + CE																																																																																																				
	MCR (%)		Time (s)	MCR (%)		Time (s)																																																																																																		
	Training	Testing		Training	Testing																																																																																																			
<i>relu</i>	0.14	0.97	49.97	0.00	1.02	24.58																																																																																																		
<i>brelu</i>	0.18	0.94	32.60	0.10	0.92	40.61																																																																																																		
<i>lrelu</i>	0.07	0.95	52.48	0.01	1.06	26.50																																																																																																		
<i>blrelu</i>	0.11	0.96	44.08	0.01	0.96	48.48																																																																																																		
<i>bifire</i>	0.71	0.89	58.10	0.79	1.04	33.14																																																																																																		
<i>bbifire</i>	0.81	0.90	57.17	0.01	0.86	52.04																																																																																																		
<i>tanh</i>	0.19	1.01	62.01	0.57	1.09	58.80																																																																																																		
<i>stanh</i>	0.87	1.19	62.84	0.29	1.07	59.19																																																																																																		
<i>stanh</i>	0.56	0.99	63.33	0.29	0.99	61.86																																																																																																		
Activation function	Testing MCR (%)																																																																																																							
<i>logsig</i> [10]	62.64																																																																																																							
<i>relu</i> [10]	51.98																																																																																																							
<i>brelu</i>	50.09																																																																																																							
<i>lrelu</i>	50.52																																																																																																							
<i>blrelu</i>	49.88																																																																																																							
<i>bifire</i> [10]	48.75																																																																																																							
<i>bbifire</i>	48.97																																																																																																							
<i>tanh</i> [10]	53.17																																																																																																							
<i>stanh</i>	50.12																																																																																																							
<i>stanh</i>	49.89																																																																																																							

5.5	Kết quả thực nghiệm có tương ứng với mục tiêu bài báo hay không ?	• Mục tiêu bài báo (Abstract): "Enhancement of the generalization ability and training stability of deep neural networks (DNNs)." (Tăng cường khả năng tổng quát hóa và độ ổn định huấn luyện). • Kết quả thực nghiệm hoàn toàn tương ứng: ○ Về khả năng tổng quát hóa (Generalization): Tác giả chứng minh MCR (tỷ lệ lỗi) giảm đáng kể trên cả 3 tập dữ liệu. ▪ <i>Minh chứng:</i> Table 8 trên tập AR Purdue cho thấy sự cải thiện không lồ: Hàm <i>lrelu</i> có lỗi 16.67%, trong khi hàm đề xuất <i>blrelu</i> chỉ còn 4.17% (giảm ~75%). Table 8 Results of the CNN models using different activation functions on the AR Purdue dataset. The bolded functions denote the proposed functions. <table><tr><th rowspan="3">Activation function</th><th colspan="3">WTA+MSE</th><th colspan="3">Softmax+CE</th></tr><tr><th colspan="2">MCR (%)</th><th rowspan="2">Time (s)</th><th colspan="2">MCR (%)</th><th rowspan="2">Time (s)</th></tr><tr><th>Training</th><th>Testing</th><th>Training</th><th>Testing</th></tr><tr><td><i>relu</i></td><td>16.50</td><td>20.50</td><td>8.93</td><td>11.85</td><td>19.67</td><td>8.47</td></tr><tr><td><i>brelu</i></td><td>12.90</td><td>17.33</td><td>7.84</td><td>8.95</td><td>16.50</td><td>8.19</td></tr><tr><td><i>lrelu</i></td><td>5.50</td><td>16.67</td><td>9.06</td><td>0.05</td><td>7.67</td><td>8.65</td></tr><tr><td><i>blrelu</i></td><td>0.90</td><td>4.17</td><td>8.90</td><td>0.15</td><td>7.00</td><td>8.40</td></tr><tr><td><i>bifire</i></td><td>OF</td><td></td><td>N/A</td><td>0.00</td><td>7.33</td><td>8.85</td></tr><tr><td><i>bbifire</i></td><td>3.70</td><td>7.17</td><td>9.22</td><td>0.10</td><td>6.67</td><td>9.45</td></tr><tr><td><i>tanh</i></td><td>1.45</td><td>10.00</td><td>10.38</td><td>0.25</td><td>10.83</td><td>10.36</td></tr><tr><td><i>stanh</i></td><td>0.25</td><td>4.83</td><td>9.85</td><td>0.00</td><td>8.33</td><td>10.25</td></tr><tr><td><i>stanh</i></td><td>0.00</td><td>2.67</td><td>9.87</td><td>0.00</td><td>7.00</td><td>10.27</td></tr></table> ○ Về độ ổn định (Stability): Tác giả chứng minh xác suất xảy ra lỗi số học (Numerical Instability) giảm mạnh. ▪ <i>Minh chứng:</i> Table 11 cho thấy hàm <i>bifire</i> gốc có xác suất lỗi là 100.00% (luôn thất bại), nhưng hàm đề xuất <i>bbifire</i> có xác suất lỗi là 0.00%. Table 11 Probability of numerical instability for the CNN models using different activation functions on the AR Purdue dataset. The bolded functions denote the proposed functions. <table><tr><th rowspan="2">Activation function</th><th colspan="2">Probability of numerical instability (%)</th></tr><tr><th>WTA+MSE</th><th>Softmax+CE</th></tr><tr><td><i>relu</i></td><td>0.00</td><td>0.00</td></tr><tr><td><i>brelu</i></td><td>0.00</td><td>0.00</td></tr><tr><td><i>lrelu</i></td><td>80.00</td><td>0.00</td></tr><tr><td><i>blrelu</i></td><td>31.43</td><td>0.00</td></tr><tr><td><i>bifire</i></td><td>100.00</td><td>45.00</td></tr><tr><td><i>bbifire</i></td><td>0.00</td><td>0.00</td></tr></table> ○ <i>"Experimental results demonstrate the superiority of all the proposed activation functions, with significant improvements up to 17.31%, 9.19%, and 74.99%... justifiable the importance of manipulating the output boundary values for a more stable training process."</i> (Mục 6. Conclusions).	Activation function	WTA+MSE			Softmax+CE			MCR (%)		Time (s)	MCR (%)		Time (s)	Training	Testing	Training	Testing	<i>relu</i>	16.50	20.50	8.93	11.85	19.67	8.47	<i>brelu</i>	12.90	17.33	7.84	8.95	16.50	8.19	<i>lrelu</i>	5.50	16.67	9.06	0.05	7.67	8.65	<i>blrelu</i>	0.90	4.17	8.90	0.15	7.00	8.40	<i>bifire</i>	OF		N/A	0.00	7.33	8.85	<i>bbifire</i>	3.70	7.17	9.22	0.10	6.67	9.45	<i>tanh</i>	1.45	10.00	10.38	0.25	10.83	10.36	<i>stanh</i>	0.25	4.83	9.85	0.00	8.33	10.25	<i>stanh</i>	0.00	2.67	9.87	0.00	7.00	10.27	Activation function	Probability of numerical instability (%)		WTA+MSE	Softmax+CE	<i>relu</i>	0.00	0.00	<i>brelu</i>	0.00	0.00	<i>lrelu</i>	80.00	0.00	<i>blrelu</i>	31.43	0.00	<i>bifire</i>	100.00	45.00	<i>bbifire</i>	0.00	0.00	5
Activation function	WTA+MSE			Softmax+CE																																																																																																						
	MCR (%)			Time (s)	MCR (%)		Time (s)																																																																																																			
	Training	Testing	Training		Testing																																																																																																					
<i>relu</i>	16.50	20.50	8.93	11.85	19.67	8.47																																																																																																				
<i>brelu</i>	12.90	17.33	7.84	8.95	16.50	8.19																																																																																																				
<i>lrelu</i>	5.50	16.67	9.06	0.05	7.67	8.65																																																																																																				
<i>blrelu</i>	0.90	4.17	8.90	0.15	7.00	8.40																																																																																																				
<i>bifire</i>	OF		N/A	0.00	7.33	8.85																																																																																																				
<i>bbifire</i>	3.70	7.17	9.22	0.10	6.67	9.45																																																																																																				
<i>tanh</i>	1.45	10.00	10.38	0.25	10.83	10.36																																																																																																				
<i>stanh</i>	0.25	4.83	9.85	0.00	8.33	10.25																																																																																																				
<i>stanh</i>	0.00	2.67	9.87	0.00	7.00	10.27																																																																																																				
Activation function	Probability of numerical instability (%)																																																																																																									
	WTA+MSE	Softmax+CE																																																																																																								
<i>relu</i>	0.00	0.00																																																																																																								
<i>brelu</i>	0.00	0.00																																																																																																								
<i>lrelu</i>	80.00	0.00																																																																																																								
<i>blrelu</i>	31.43	0.00																																																																																																								
<i>bifire</i>	100.00	45.00																																																																																																								
<i>bbifire</i>	0.00	0.00																																																																																																								
5.6	Cái gì được tìm thấy là bất thường nên tránh trong thực nghiệm	• Điều bất thường cần tránh: Đó là "Numerical Instability" (Sự mất ổn định số học) dẫn đến giá trị NaN (Not a Number) hoặc Infinity (Vô cực) và hiện tượng Overflow (Tràn số). • Nguyên nhân: Do sử dụng các hàm kích hoạt không bị chặn (unbounded) như ReLU, Bi-firing trong các mạng sâu hoặc khi không có cơ chế kiểm soát trọng số (weight regularization). • Minh chứng từ bài báo: ○ Tại Table 8, dòng <i>bifire</i> có ghi chú là "OF" (Overflow) và "N/A" tại cột kết quả, cho thấy thí nghiệm thất bại hoàn toàn do lỗi này. ○ Tại Table 11, cột "Probability of numerical instability" cho thấy <i>bifire</i> bị lỗi 100%, <i>lrelu</i> bị lỗi 80%. ○ <i>"A numerical instability problem occurs whenever a “not a number” (NaN) or infinity value is detected... or a sudden drastic increase in the instantaneous training loss... to a very large value is observed."</i> (Mục 5.4). Đây chính là hiện tượng "bất thường" mà các nhà thực nghiệm cần tránh bằng cách dùng hàm bị chặn (bounded).	5																																																																																																							
6	Tìm ra trường hợp thuyết phục																																																																																																									
6.1	Vấn đề cần giải quyết chính xác là gì?	• Vấn đề chính xác là: Các hàm kích hoạt phổ biến hiện nay (như ReLU) có tính chất không giới hạn đầu ra (unbounded outputs). Điều này gây ra hai hệ quả nghiêm trọng: 1. Mất ổn định số học (Numerical Instability): Dễ gây tràn số (overflow) trên phần cứng giới hạn hoặc khi mạng sâu, dẫn đến quá trình huấn luyện thất bại (divergence). 2. Khó triển khai trên phần cứng nhúng: Các hệ thống nhúng (FPGA, Mobile) thường yêu cầu biểu diễn số giới hạn (fixed-point), hàm không chặn sẽ tiêu tốn tài nguyên hoặc gây sai số lớn. <i>"However, the output boundary issue is very important, especially in embedded system applications or dedicated hardware design where the number representation is limited..."</i>	5																																																																																																							

		<i>Also, there are some previous works reported on the numerical instability issue due to the unbounded nature of the ReLU function."</i>	
6.2	Ý tưởng đang xem xét có hiệu quả đáng kể ko ?	• Hiệu quả rất đáng kể (Significant Effectiveness): Ý tưởng "giới hạn đầu ra" (Bounding output) tuy đơn giản nhưng mang lại hiệu quả vượt trội, được lượng hóa bằng các con số ấn tượng trong phần Abstract và Conclusions. • Minh chứng số liệu: ○ Cải thiện độ chính xác phân loại lên tới 74.99% trên cơ sở dữ liệu khuôn mặt AR Purdue (So sánh giữa <i>blrelu</i> và <i>lrelu</i> trong Table 8). ○ Giảm 78.58% xác suất lỗi mất ổn định (numerical instability) trên tập MNIST (Mục 6. Conclusions). ○ Loại bỏ hoàn toàn (completely eliminated) vấn đề mất ổn định trên các tập <i>mnist-rot-bg-img</i> và <i>AR Purdue</i> khi dùng hàm <i>bbifire</i> (Table 10, 11). • Hiệu quả về chi phí: Đạt được kết quả trên mà không làm tăng chi phí tính toán (computational efficiency) và không cần dùng các kỹ thuật phức tạp như Batch Normalization (tại thời điểm bài báo viết).	5
6.3	Chất lượng của những bài báo nghiên cứu tham chiếu thế nào ?	• Tham chiếu đến các nghiên cứu nền tảng (Seminal Works): Tác giả xây dựng cơ sở lý thuyết dựa trên các công trình kinh điển và uy tín nhất trong lĩnh vực Mạng nơ-ron: ○ Tham chiếu số [25] K. Hornik et al. (Neural Networks 1989): Đây là bài báo gốc về <i>Định lý xấp xỉ vạn năng (Universal Approximation Theorem - UAT)</i>, cơ sở toán học quan trọng nhất để tác giả đề xuất các mệnh đề trong Section 3.4. ○ Tham chiếu số [29] Y. LeCun et al. (IEEE 1998): Một trong những bài báo nền tảng về Backpropagation và CNN, nơi tác giả lấy cảm hứng để cải tiến hàm Tanh. • Tham chiếu đến các phương pháp SOTA (State-of-the-art) tại thời điểm đó: ○ Tham chiếu số [39] A. Krizhevsky et al. (NIPS 2012): Bài báo về AlexNet, đánh dấu sự bùng nổ của Deep Learning. ○ Tham chiếu số [40] Maas et al. (ICML 2013) và [26] Glorot et al. (AISTATS 2011): Các bài báo gốc đề xuất <i>Leaky ReLU</i> và <i>Deep Sparse Rectifier</i>, là đối tượng so sánh trực tiếp. • Đa dạng nguồn tham khảo: Danh sách tài liệu tham khảo (References) bao gồm các tạp chí hàng đầu (IEEE TPAMI, Neurocomputing) và các hội nghị top đầu (ICML, CVPR, NIPS), cho thấy tác giả nắm rất vững tình hình nghiên cứu.	5
6.4	Việc so sánh với các nghiên cứu của tác giả với các trường hợp trước đây có tốt hay ko có hiệu quả hay không	• So sánh công bằng (Fair Comparison): Tác giả thiết lập môi trường so sánh cực kỳ chặt chẽ để đảm bảo tính khách quan. ○ <i>"All experiments are carried out using the identical MLP and CNN models for fair comparisons..."</i> (Mục 4. Experimental design). Nghĩa là cùng một kiến trúc mạng, cùng thuật toán học, chỉ thay đổi duy nhất hàm kích hoạt. • So sánh toàn diện: Tác giả so sánh hàm đề xuất với đầy đủ các đối thủ cạnh tranh mạnh nhất: ○ So sánh với ReLU (hàm phổ biến nhất). ○ So sánh với Leaky ReLU (biến thể cải tiến của ReLU). ○ So sánh với Bi-firing (một hàm non-sigmoidal khác được đề xuất trong tham khảo [10]). ○ So sánh với Tanh (đại diện nhóm sigmoidal). • Hiệu quả so sánh: Việc so sánh rất hiệu quả vì nó làm nổi bật được ưu điểm của hàm đề xuất trên mọi phương diện: ○ Về độ chính xác (Accuracy): Table 5 và Table 7 cho thấy hàm đề xuất (<i>brelu</i>, <i>blrelu</i>, <i>bbifire</i>) luôn có MCR thấp hơn hoặc tương đương hàm gốc. ○ Về tốc độ hội tụ: Fig. 12, 13, 14 cho thấy đường cong loss của hàm đề xuất giảm nhanh hơn. ○ Về độ ổn định: Table 9, 10, 11 là minh chứng "chí mạng" khi hàm đề xuất loại bỏ hoàn toàn lỗi NaN/Inf mà các nghiên cứu trước đây gặp phải.	5
6.5	Hệ thống đã lập trình sử dụng có qua kiểm tra hay chưa có phổ biến thành ứng dụng thực tế đc không?	• Hệ thống đã qua kiểm tra nghiêm ngặt (Rigorously Tested): ○ Hệ thống được viết bằng C/C++ from scratch (Mục 4.4). Việc tự viết code thay vì dùng thư viện đòi hỏi tác giả phải kiểm tra (debug) cực kỳ kỹ lưỡng các phép toán ma trận và lan truyền ngược. ○ Hệ thống đã được kiểm tra (validate) trên 3 tập dữ liệu khác nhau (MNIST, <i>mnist-rot-bg-img</i>, <i>AR Purdue</i>) với hàng trăm lần chạy thí nghiệm (mỗi thí nghiệm lặp lại 3 lần - Mục 4.3). • Khả năng phổ biến thành ứng dụng thực tế cao: ○ Tính ứng dụng cho hệ thống nhúng (Embedded/Hardware): Đây là điểm mạnh nhất của bài báo. Tác giả nhấn mạnh rằng các hàm bị chặn (bounded) là cực kỳ cần thiết cho thiết kế phần cứng (FPGA, ASIC) nơi tài nguyên và biểu diễn số bị giới hạn. ○ <i>Trích dẫn:</i> "However, the output boundary issue is very important, especially in embedded system applications or dedicated hardware design... since it can bring significant impact on the computational complexity and resource consumption." (Mục 2.2). ○ Dễ dàng tích hợp: Các hàm đề xuất (ví dụ công thức 7: $f(x) = \min(\max(0, x), A)$) chỉ sử dụng các phép toán đơn giản (min, max, so sánh), rất dễ lập trình trên bất kỳ ngôn ngữ nào	5

		hoặc hiện thực hóa trên mạch điện tử, không yêu cầu hàm mũ phức tạp như Sigmoid (ngoại trừ tanh).	
--	--	---	--

⇒ Điểm trung bình: 5

