

ĐÁNH GIÁ BÀI BÁO THEO TIÊU CHUẨN GOOD RESEARCH

FaceHunter: A multi-task convolutional neural network based face detector

STT	Tiêu chí / Câu hỏi đánh giá	Lý giải dựa trên bài báo (kèm trích dẫn)	Điểm (1-5)
I	I. Quan trọng và liên quan		
1	Vấn đề nghiên cứu có giải quyết một thách thức thực tế cấp bách không?	- Bài toán phát hiện khuôn mặt “in the wild” được mô tả là vẫn còn “thách thức”, đặc biệt khi gặp biến thiên lớn về ngoại hình, che khuất (occlusion), nền nhiễu (clutter). Dẫn chứng: <i>“Although they achieved significant progress in practical applications, detecting face “in the wild” is still to be a challenge, especially when the faces are suffered from large variations in facial appearances, occlusions, and clutters, ...” (page 1/6)</i> - Tác giả nhấn mạnh đây là bước đầu của hệ thống phân tích mặt và ảnh hưởng mạnh đến các bước sau. Dẫn chứng: <i>“Face detection is generally the first step in automatic face analysis system, and it has much effect on the performance of face analysis.” (page 1/6)</i> - Ngoài ra, tác giả còn chỉ ra một điểm rất “thực dụng”: nhiều detector bỏ qua độ ổn định/độ tin cậy của bounding box, trong khi điều này ảnh hưởng trực tiếp đến precision và các tác vụ phân tích tiếp theo; tiêu chuẩn IoU (thường ngưỡng 0.5) làm cho việc “box không ổn” dẫn tới bị loại kết quả. Dẫn chứng: <i>“However, most detectors ignore the issue about the stability and reliability of the bounding box, which has a significant impact on the precision as well as the subsequent analysis” (page 1/6)</i> <i>“For example, the most common used standard for evaluating a face detector is based on the intersection-over-union (IoU) ratio. The threshold is usually set to be 0.5, and it means all the possible results will be discarded if the IoU is less than 0.5” (page 1/6)</i> - Vấn đề bài toán đặt ra khá rõ ràng và gắn chặt ứng dụng thực tế (face analysis pipeline) và nêu đúng “điểm đau” ngoài đời (wild conditions + box reliability)	5

2	Nghiên cứu có khắc phục được hạn chế của các phương pháp hiện hành không?	• Bài nêu hạn chế của hướng truyền thống dựa trên hand-crafted features: không đủ diễn tả biến thiên phức tạp trong môi trường không kiểm soát; CNN có lợi thế học đặc trưng tự động và phân biệt tốt hơn. Dẫn chứng: <i>“Although they achieved significant progress in practical applications, detecting face 'in the wild' is still to be a challenge... because they are based on low-level handcraft features, which are insufficient for describing complex variation of face appearance in uncontrolled environments.” (page 1/6)</i> ⇒ CNN "can better differentiate faces from uncontrolled environments." (page 1/6) => Tác giả chỉ rõ rằng handcrafted features không đủ mạnh, và CNN có lợi thế vì học đặc trưng tự động. • Quan trọng hơn, tác giả nhắm vào hạn chế “ít ai xử lý tốt”: stability/reliability của bounding box. Thay vì tách riêng regression như vài hệ trước, họ dùng multi-task loss để vừa phân loại mặt/không mặt vừa hồi quy box trong cùng mạng. Dẫn chứng: <i>“Most detectors ignore the issue about the stability and reliability of the bounding box, which has a significant impact on the precision as well as the subsequent analysis” (page 1/6)</i> <i>“A few works take this issue into account, such as the R-CNN-based object detectors [11,12], but they regard the bounding box regression as an independent stage...” (page 1/6)</i> <i>“we consider training our detection network using a multi-task loss...” (page 1/6)</i> • Về hiệu năng hệ thống, bài cũng nhắm vào “nút thắt cổ chai” về proposal: Selective Search có thể tốn ~2s/ảnh CPU, nên họ đưa RPN chạy trực tiếp trên feature map để giảm chi phí proposal (marginal cost nhỏ). Dẫn chứng: <i>“Selective Search [14] used in Fast-RCNN [13] is one of the most popular proposal methods, which costs about 2 s per image in a CPU implementation” (page 2/6)</i> <i>“we directly use the convolutional feature map to generate the candidate windows” (page 2/6)</i> <i>“With this strategy of sharing convolutions, the marginal cost for computing the proposals becomes very small (i.e. 4 ms for a typical 1000x600 image) enabling nearly cost-free proposals.” (page 2/6)</i> • Họ còn thêm adaptive pooling để xử lý proposal kích thước biến đổi và truncated SVD để nén fully-connected nhằm tăng tốc. Dẫn chứng:	4
---	---	--	---

		<i>“An adaptive pooling layer is added before full connection to make the network adaptive to variable candidate proposals” (page 1/6)</i> - Khắc phục hạn chế khá rõ (box reliability + tốc độ proposal + tính linh hoạt input). Dẫn chứng: <i>“In this paper, we propose a multi-task convolutional neural network (CNN) based face detector named FaceHunter. We focus on obtaining stable bounding boxes and achieving high detection accuracies” (page 6/6)</i> - Tuy nhiên, bài chủ yếu là “tích hợp/điều chỉnh” các ý tưởng mạnh thời điểm đó (multi-task, RPN, SVD, pooling) hơn là mở ra một hướng hoàn toàn mới.	
3	Kết quả nghiên cứu có đóng góp gì cho cộng đồng học thuật?	- Bài báo nêu rõ 2 đóng góp chính: - Áp dụng multi-task CNN cho face detection và chứng minh hiệu quả; thêm adaptive pooling để linh hoạt/fine-tune, và dùng truncated SVD để giảm chi phí fully-connected. Dẫn chứng: <i>“The multi-task CNN is applied in the face detection task, and it is validated to be very efficient. An adaptive pooling layer is integrated into the network to make it more flexible during parameter fine-tuning, and also the truncated SVD is introduced to compress the fully connected layers for reducing the computation cost of them.” (page 2/6)</i> - Dùng RPN để tạo proposal trực tiếp trên feature map, chia sẻ conv features với detector nên chi phí proposal rất nhỏ, giúp tăng tốc. Dẫn chứng: <i>“To further speedup the network, the RPN network is introduced to generate the proposals, which is directly performed on the convolutional feature maps. The RPN and multi-task CNN share the same convolutional features, so the proposal generating cost is very small.” (page 2/6)</i> - Về mặt thực nghiệm, họ đánh giá trên AFW, FDDB, Pascal Faces và báo cáo “state-of-the-art performance”, đồng thời cho thấy RPN vừa tăng tốc vừa tăng precision. Dẫn chứng: <i>“We test the proposed detector on AFW [17], FDDB [18] and Pascal Faces [19] datasets” (page 2/6)</i> <i>“Our FaceHunter outperforms the baseline TSM by 10%, and outperforms the Shen-Retrieval by 8%. It even outperforms the commercial systems face.com, FacePP and Google Picasa” (page 5/6)</i>	4

“It also indicates that, RPN can not only speed up the detector, but also increase the detecting precision.” (page 5/6)

- Bài báo đóng góp tốt ở mức “cộng đồng có thể dùng/so sánh”: kiến trúc rõ ràng, pipeline huấn luyện 4 bước, benchmark trên dataset phổ biến. Dẫn chứng:

“As shown in Fig. 1, the proposed face detection framework includes two networks, i.e.,” (page 3/6). Và kiến trúc bài báo đề xuất:




Fig. 1. The overview of our multi-task CNN based face detector FaceHunter.

+ Dẫn chứng cho pipeline huấn luyện rõ ràng:

“Thus, we develop a 4-step training algorithm to learn the shared features via alternating optimization. Firstly, we train the RPN, which is initialized by an ImageNet pretrained model. Secondly, based on the proposals generated by the trained RPN, we train the multi-task CNN. Thirdly, we use the trained CNN network to initialize the RPN. We keep the shared conv layers fixed and only fine-tune the layers of the RPN. Finally, keeping the shared conv layers fixed, we fine-tune the fc layers of the multi-task CNN” (page 3/6)

Algorithm 1. The whole optimization algorithm.

Input: Face image, face rect.

Initialization: ImageNet pre-trained model.

1. Train the RPN network.
2. Use the proposals generated by the RPN to train the multi-task CNN.
3. Use the CNN network to initialize the RPN.
4. Fine-tune the fc layers of the multi-task CNN.


Output: Multi-task CNN based face detection model.


- Nhưng vì bài ngắn và thiên về engineering + kết hợp module nên tính “đột phá lý thuyết” theo đánh giá nhóm là không quá mạnh.
- Phần lớn các kỹ thuật đều dựa trên hoặc cải tiến nhẹ từ công trình trước:

		• Multi-task loss → từ [13] Fast R-CNN • RPN → từ [15] Faster R-CNN • Truncated SVD → từ [13] • Adaptive pooling → lấy cảm hứng từ spatial pyramid pooling <i>“Inspired by [13], we consider training our detection network using a multi-task loss in a single training stage by modifying the networks.” (page 1/6)</i> <i>“To reduce the computation cost of fully connected layers, we use the truncated SVD [13] to compress them” (page 2/6)</i>	
II	Tính Logic (Logical)		
1	Mạch lập luận từ vấn đề đến giải pháp có chặt chẽ và theo chuỗi nguyên nhân - hệ quả không?	• Bài này đi theo pipeline khá rõ: • Vấn đề thực tế: face detection “in the wild” khó vì biến thiên lớn (pose, occlusion, clutter), và các phương pháp dựa hand-crafted features “insufficient” trong môi trường không kiểm soát. Dẫn chứng: <i>“detecting face “in the wild” is still to be a challenge, especially when the faces are suffered from large variations in facial appearances, occlusions, and clutters, because they are based on low-level handcraft features, which are insufficient for describing complex variation of face appearance in uncontrolled environments” (page 1/6)</i> • Khoảng trống cụ thể: nhiều detector “ignore” độ ổn định/reliability của bounding box, trong khi IoU threshold (ví dụ 0.5) có ảnh hưởng trực tiếp đến precision và downstream analysis. Dẫn chứng: <i>“However, most detectors ignore the issue about the stability and reliability of the bounding box, which has a significant impact on the precision as well as the subsequent analysis. For example, the most common used standard for evaluating a face detector is based on the intersection-over-union (IoU) ratio. The threshold is usually set to be 0.5” (page 1/6)</i> • Giải pháp tương ứng: • Dùng multi-task loss để đồng thời phân loại face/non-face và regression bbox “simultaneously” nhằm tăng “reliable face boxes”. <i>“...we consider training our detection network using a multi-task loss in a single training stage...” (page 1/6)</i> <i>“so we can classify the proposals and refine the bounding box simultaneously” (page 2/6)</i>	4

		<i>“The main idea is to make the face detector achieve a high detection accuracy and obtain much reliable face boxes.” (page 1/6)</i> • Nhận diện các nút thắt tính toán (proposal generation, FC layers) rồi đưa biện pháp tương ứng: RPN để giảm chi phí proposal (nêu cả con số ms), truncated SVD để giảm chi phí FC, adaptive pooling để tránh tính conv lặp lại và bỏ ràng buộc fixed-size. Dẫn chứng: + Multi-task loss → tăng reliability của box: <i>“Selective Search [14] used in Fast-RCNN [13] is one of the most popular proposal methods, which costs about 2 s per image in a CPU implementation” (page 2/6)</i> + Giảm chi phí proposal: dùng RPN thay vì Selective Search: <i>“With this strategy of sharing convolutions, the marginal cost for computing the proposals becomes very small (i.e. 4 ms for a typical 1000x600 image) enabling nearly cost-free proposals” (page 2/6)</i> + Giảm chi phí, tiết kiệm tài nguyên tính toán mà vẫn giữ hiệu năng bằng phép tách ma trận SVD: <i>“To reduce the computation cost of fully connected layers, we use the truncated SVD [13] to compress them” (page 2/6)</i> + Linh hoạt hoá mạng với adaptive pooling: <i>“Moreover, it removes the fixed-size constraint of the network, as it can generate a fixed-length representation regardless of image size and makes the network more flexible during parameter fine-tuning” (page 2/6)</i> <i>“An adaptive pooling layer is added before full connection to make the network adaptive to variable candidate proposals” (page 1/6)</i> • Nhận xét logic: Lập luận “vấn đề → khoảng trống → thiết kế” khá mạch lạc, và mỗi module giải quyết một pain point rõ. • Điểm trừ là bài ngắn nên phần “tại sao chọn đúng cấu hình/thiết kế này thay vì lựa chọn khác” không đào sâu (logic đúng nhưng chưa <i>giàu lập luận</i>).	
2	Các giả thuyết/động cơ thiết kế có dựa trên cơ sở lý thuyết	• Bài dựa nhiều vào cơ sở phương pháp đã được chuẩn hóa hơn là một lý thuyết mới: • Multi-task learning: họ nói “Inspired by [13]” (Fast R-CNN) và dùng multi-task loss để huấn luyện chung classification + bbox regression. Dẫn chứng:	3.5

	vững chắc không?	“Inspired by [13], we consider training our detection network using a multi-task loss in a single training stage by modifying the networks” (page 1/6) - Loss cho bbox regression dùng smooth L1 (chuẩn trong R-CNN family) và giải thích λ để cân bằng hai nhiệm vụ. Dẫn chứng: “Then, we use a multi-task loss L to train the network jointly for classification and bounding-box regression:”(page 3/6). Cụ thể về λ và Loss: $L(p, p^*, t, t^*) = L_c(p, p^*) + \lambda L_r(t, t^*) \tag{1}$ where p^* is a true class label and $L_c(p, p^*) = -\log pp^*$ is the standard cross-entropy/log loss. For the second task loss, the true bounding-box regression target is $t^* = (t_x^*, t_y^*, t_w^*, t_h^*)$ and the prediction is $t = (t_x, t_y, t_w, t_h)$. We use the loss $L_r(t, t^*) = \sum_{i \in \{x, y, w, h\}} \text{smooth}_{L_1}(t_i, t_i^*) \tag{2}$ where $\text{smooth}_{L_1}(x) = \begin{cases} 0.5x^2 & \text{if } x < 1 \\ x - 0.5 & \text{otherwise,} \end{cases} \tag{3}$ is a smoothed L_1 loss. The hyper-parameter λ in Eq. (1) is used to control the balance between the two task losses - Adaptive pooling: lấy cảm hứng từ SPP, nhưng đổi thành single-level để “allow all network layers to be updated during fine-tuning” và chỉ cần scan conv một lần. “we adopt an adaptive pooling layer after conv5, which is inspired by the spatial pyramid pooling layer used in [10]. Different from the spatial pyramid pooling layer in [10], the adaptive pooling layer has only a single level, which allows all the network layers to be updated during fine-tuning. Using the adaptive pooling layer, the network only needs to scan the convolutional layers one time on the entire image” (page 3/6) - Tăng tốc proposal: lập luận dựa trên bottleneck Selective Search (nêu “about 2s per image CPU”) và dùng RPN chia sẻ conv features để marginal cost nhỏ. “Selective Search [14] used in Fast-RCNN [13] is one of the most popular proposal methods, which costs about 2 s per image in a CPU implementation” (page 2/6) “We apply the Region Proposal Network (RPN) [15] to generate the proposals based on the convolutional features...” (page 2/6) Đánh giá: “Cơ sở lý thuyết” ở đây chủ yếu là lý do thực nghiệm + kế thừa thiết kế đã được cộng đồng chấp nhận (Fast R-CNN/Faster R-CNN/SPP). Tuy nhiên, nhóm
--	-------------------------	---

		tác giả không đưa ra phân tích lý thuyết mới (ví dụ chứng minh/định lý), nhưng động cơ thiết kế được neo vào các khung phương pháp mạnh và lý do chi phí-tốc độ hợp lý.	
3	Thiết kế phương pháp/kiến trúc mô hình có hợp lý không?	- Thiết kế tổng thể tương đối “đúng bài” với mục tiêu <i>accuracy + reliable boxes + speed</i>: Multi-task CNN: hai “sibling layers” dùng chung conv features để vừa phân loại vừa tinh chỉnh bbox; loss tổng hợp gồm cross-entropy + smooth L1. <i>“We make it terminated at two sibling layers (a fully connected layer and softmax over 2 categories and bounding-box regressor) sharing convolutional features, so we can classify the proposals and refine the bounding box simultaneously” (page 1-2/6)</i> Adaptive pooling đặt sau conv5 để xử lý proposals kích thước khác nhau, bỏ fixed-size constraint và giảm tính toán lặp. <i>“We adopt an adaptive pooling layer after conv5... it removes the fixed-size constraint of the network, and avoids repeatedly computing the convolutional features.” (page 3/6)</i> Truncated SVD nén FC: có mô tả rõ cách factorize ma trận trọng số để giảm tham số/chi phí.  Fig. 3. Use truncated SVD to compress fully connected layers. (page 3/6) RPN chạy trực tiếp trên conv feature map và chia sẻ conv với detector để proposal gần như “cost-free” (họ nêu ví dụ 4ms). <i>“With this strategy of sharing convolutions, the marginal cost for computing the proposals becomes very small (i.e. 4 ms for a typical 1000 600 image) enabling nearly cost-free proposals” (page 2/6)</i> Quy trình huấn luyện 4 bước (alternating optimization) để học shared features giữa RPN và detector và logic phù hợp với họ Faster R-CNN thời kỳ đầu.	4

		Algorithm 1. The whole optimization algorithm. Input: Face image, face rect. Initialization: ImageNet pre-trained model. 1. Train the RPN network. 2. Use the proposals generated by the RPN to train the multi-task CNN. 3. Use the CNN network to initialize the RPN. 4. Fine-tune the <i>fc</i> layers of the multi-task CNN. Output: Multi-task CNN based face detection model. • Tuy nhiên logic thiết kế vẫn còn một vài hướng mở rộng thêm: • λ được nói “set empirically” cho multi-task CNN. Việc này hợp thực tế, nhưng nếu xét “good research” thì nên có ablation để thuyết phục hơn. “The hyper-parameter λ is set to 1 empirically.” (page 4/6) - thiếu ablation • Kiến trúc backbone là biến thể AlexNet/ImageNet pretrained; mô tả có, nhưng không có so sánh backbone/ablation để chứng minh “thiết kế kiến trúc” là tối ưu, nên phần “hợp lý” mạnh ở mức engineering. “We consider a variant of the network in [20] to generate the feature maps, which removes the last pooling layer (i.e. pool5)” (page 2/6). Reference [20] là AlexNet, bài mô tả nhưng không có so sánh backbone hay ablation để chứng minh => thiếu sót.	
III	Tính nghiêm túc (Rigorous)		
1	Phương pháp (mô hình/thuật toán/công thức) có được mô tả đủ chi tiết để người đọc hiểu và triển khai lại không?	- Điểm mạnh của bài báo: • Bài mô tả khá rõ kiến trúc backbone (5 conv layers, kích thước kernel/stride/số kênh, có ReLU sau mỗi conv/FC, bỏ pool5).  Fig. 2. The deep structure which is used for generating feature maps. One GPU runs the layer-parts at the top of the figure while the other runs the layer-parts at the bottom. The GPUs communicate only at certain layers. • Mô tả đầy đủ multi-task loss (CE cho phân loại + smooth L1 cho bbox regression, có λ cân bằng), có công thức và định nghĩa biến.	4

$t = (t_x, t_y, t_w, t_h)$. Then, we use a multi-task loss L to train the network jointly for classification and bounding-box regression:

$$L(p, p^*, t, t^*) = L_c(p, p^*) + \lambda L_r(t, t^*) \quad (1)$$

where p^* is a true class label and $L_c(p, p^*) = -\log pp^*$ is the standard cross-entropy/log loss. For the second task loss, the true bounding-box regression target is $t^* = (t_x^*, t_y^*, t_w^*, t_h^*)$ and the prediction is $t = (t_x, t_y, t_w, t_h)$. We use the loss

$$L_r(t, t^*) = \sum_{i \in \{x, y, w, h\}} \text{smooth}_{L_1}(t_i, t_i^*) \quad (2)$$

where

$$\text{smooth}_{L_1}(x) = \begin{cases} 0.5x^2 & \text{if } |x| < 1 \\ |x| - 0.5 & \text{otherwise,} \end{cases} \quad (3)$$

is a smoothed L_1 loss. The hyper-parameter λ in Eq. (1) is used to control the balance between the two task losses.

- Mô tả **RPN** (của số trượt $n \times n = 3 \times 3$, vector 256-d, dự đoán k proposals theo nhiều scale).




Fig. 1. The overview of our multi-task CNN based face detector FaceHunter.

- Mô tả **thuật toán huấn luyện 4 bước** (train RPN → train detector → dùng detector init RPN → fine-tune FC detector, có “keep shared conv fixed”).

Algorithm 1. The whole optimization algorithm.

Input: Face image, face rect.

Initialization: ImageNet pre-trained model.

1. Train the RPN network.
2. Use the proposals generated by the RPN to train the multi-task CNN.
3. Use the CNN network to initialize the RPN.
4. Fine-tune the fc layers of the multi-task CNN.

Output: Multi-task CNN based face detection model.

		- Mô tả khá chi tiết thiết lập thực nghiệm/tiền xử lý: resize (shorter side s=600), chuẩn hoá target regression, dropout, NMS threshold 0.7, top-300 proposals, scale của anchor, SVD rank (fc6 top 1024 singular values, fc7 top 256),.. Dẫn chứng : 3.1. <i>Experimental setting</i> (page 3 - 4/6) - Điểm yếu (khó “reproduce (tái tạo)” đúng chuẩn): - Thiếu các thông tin hay cần để tái lập kết quả sát (ví dụ: optimizer, learning rate schedule, batch size, số epoch/iterations, cách sampling mini-batch, chi tiết anchor aspect ratios, weight decay, momentum...). Trong bài không thấy nêu trực tiếp ở phần setting; chỉ nói dựa trên cuda-convnet/Caffe. - Đánh giá: để có thể tái lập như đúng số liệu thì còn thiếu một vài “hyperparam” then chốt như: lr, epoch,...	
2	Thiết kế thực nghiệm có nghiêm ngặt (đa bộ dữ liệu, giao thức đánh giá rõ, so sánh baseline/state-of-the-art) không?	- Điểm mạnh: - Có đa bộ dữ liệu: AFW, FDDB, Pascal Faces (test), và còn nhắc AFLW + dataset tự thu thập cho train/val. Dẫn chứng: (page 3-4/6) <i>“We train our face detector on a private face dataset, which contains 980,354 face boxes... we select 183,200 of them for training and 10,000 for validation.”</i> <i>“We test the proposed detector on AFW [17], FDDB [18] and Pascal Faces [19] datasets.”</i> <i>“The AFLW dataset is also used for data augmentation...”</i> • Giao thức đánh giá được nêu: dùng IoU để đo kết quả và lấy ngưỡng $\text{IoU} \geq 0.5$ là detection hợp lệ (theo work trước). <i>“the threshold is usually set to be 0.5, and it means all the possible results will be discarded if the IoU is less than 0.5.”</i> (page 1/6) • So sánh với nhiều baseline/SOTA và cả commercial systems, trình bày theo PR curve/ROC (AFW/FDDB/Pascal).	4




Fig. 4. PR curve on AFW. (For interpretation of the references to color in this figure, the reader is referred to the web version of this paper.)




Fig. 5. Discrete ROC on FDDB. (For interpretation of the references to color in this figure, the reader is referred to the web version of this paper.)




Fig. 6. PR curve on Pascal Faces. (For interpretation of the references to color in this figure, the reader is referred to the web version of this paper.)

- Có **ablation quan trọng**: đánh giá thêm biến thể “multi-task network without RPN” để tách đóng góp của RPN, và so với hierarchical deep detector (single-task style). Dẫn chứng:

“For further investigating the proposed FaceHunter detector, we particularly evaluate it without using RPN, i.e. “Ours multi-task network without RPN” (expressed using the green curve in Figs. 4 - 6). “Ours multi-task network without RPN” is similar to a FastRCNN [13], but it is not the same as Fast-RCNN.” (page 4/6)

- **Điểm hạn chế về “rigor (tính nghiêm ngặt)”**:
- Train chủ yếu dựa vào **dataset tự thu thập rất lớn** (980,354 faces, chọn 183,200 để train) - cộng đồng khó kiểm chứng trực tiếp nếu dataset không public.
- Bài ngắn nên không thấy kiểm thử chặt kiểu cross-dataset training/transfer, hoặc phân tách rõ các protocol đặc thù của từng benchmark (ví dụ FDDB dùng ellipse annotations - bài có nêu dataset này có ellipse, nhưng không nêu chi tiết cách convert/eval ngoài IoU).
- **Đánh giá**: benchmark + so sánh khá mạnh; điểm trừ chính là tái kiểm chứng bị hạn chế vì trainset private và mô tả protocol chưa thật “đóng” cho từng dataset.

3

Có phân tích bổ sung (training stability / numerical stability /

- **Bài báo đề cập runtime/complexity khá rõ**:
- Nêu bottleneck Selective Search “~2s/image CPU” và RPN có marginal cost rất nhỏ (ví dụ 4 ms cho ảnh 1000×600).
- Có phân tích thời gian theo module trên GPU K40: conv 0.041s/img, phần NMS+fc+softmax... ~0.034s/img, proposal ~0.004s/img.

3

	learning curves / runtime) để củng cố độ chắc chắn của kết quả không?	Fig. 2. The deep structure which is used for generating feature maps. One GPU runs the layer-parts at the top of the figure while the other runs the layer-parts at the bottom. The GPUs communicate only at certain layers. - Nhưng trong bài báo này thiếu các phân tích “độ chắc chắn” theo nghĩa research nghiêm ngặt: • Không thấy learning curves, không có std/variance qua nhiều lần chạy, không phân tích sensitivity của λ/hyperparams, không bàn numerical stability/training stability. (Trong setting chỉ nói λ “set empirically” và các con số cấu hình, nhưng không có kiểm tra độ nhạy.) - Đánh giá: có runtime/complexity tốt, nhưng thiếu các phân tích ổn định/độ tin cậy thống kê.	
IV	Tính hệ thống (Systematic)		
1	Nghiên cứu có đi theo chuỗi bước hệ thống (nêu vấn đề → tổng quan/tiêu chí → phương pháp → thực nghiệm → kết luận) không?	- Bài viết trình bày theo trình tự logic: • Nêu vấn đề: Hạn chế của các phương pháp cũ (Adaboost, DPM) trong điều kiện tự nhiên (in-the-wild) và sự thiếu ổn định của bounding box. • Tổng quan: Giới thiệu CNN, multi-task loss, RPN, adaptive pooling như giải pháp thay thế. • Phương pháp: Giải thích kiến trúc mạng, loss function, mô hình RPN và thuật toán huấn luyện 4 bước. • Thực nghiệm: Trình bày cài đặt chi tiết, cấu hình training/test, đánh giá trên nhiều dataset. • Kết luận: Tóm tắt đóng góp và xác nhận hiệu quả mô hình.	5
2	Pipeline thực nghiệm (tiền xử lý → huấn luyện → đánh giá) có được mô tả theo	- Rất rõ ràng, có trình bày tuần tự: • Tiền xử lý: Crop ảnh positive và negative dựa trên IoU; resize về chiều ngắn nhất 600px; chuẩn hóa giá trị regression target về zero mean và unit variance. • Huấn luyện: Thuật toán gồm 4 bước rõ ràng: train RPN → train CNN → re-init RPN từ CNN → fine-tune CNN.	5

	bước cụ thể, tránh “nhảy cóc” không?	● Đánh giá: Trên 3 dataset chuẩn (AFW, FDDB, Pascal Faces), dùng PR/ROC curves và so sánh SOTA.	
3	Tiền xử lý và giao thức dữ liệu có được chuẩn hóa và trình bày rõ không (kích thước ảnh, chuẩn hóa, chia train/test)?	- Các bước tiền xử lý và chuẩn hóa trình bày rất rõ: ● Resize ảnh: “we rescale the images such that their shorter side is $s = 600$ pixels”. ● Chuẩn hóa giá trị: “The ground-truth regression targets t^* is normalized with zero mean and unit variance”. ● Chia train/test: Dùng 183,200 ảnh để train từ tập riêng, validate bằng tập AFLW, test trên AFW, FDDB, Pascal Faces. ● Chống trùng lặp: đảm bảo $IoU < 25\%$ giữa các mẫu âm, và NMS với IoU threshold = 0.7 khi test. - Cụ thể được trình bày rõ ràng trong phần 3.1 và 3.2. (page 3 – 4/6)	5
V	Valid and verifiable		
1	Kết quả có tính hợp lệ (valid) nhờ dùng dữ liệu chuẩn, metric phù hợp và so sánh công bằng không?	- Dữ liệu: Sử dụng 3 benchmark datasets phổ biến và được công nhận rộng rãi: AFW, FDDB, Pascal Faces. - Metric đánh giá: Sử dụng PR curve, ROC curve, và $IoU \geq 0.5$ – là chuẩn mực trong đánh giá object/face detection. - So sánh công bằng: Đặt kết quả cạnh tranh trực tiếp với nhiều mô hình SOTA khác như Fast-RCNN, DPM, Hierarchical Deep Detector, Viola-Jones, Picasa, v.v. ⇒ Thiết kế này giúp đảm bảo độ valid của kết luận.	5
2	Bài báo có cung cấp đủ thông tin (tham số, thiết lập, dữ liệu) để người khác kiểm chứng/lập lại (verifiable) không?	- Trình bày chi tiết kiến trúc mạng, số lớp, kích thước kernel, số lượng feature maps. - Ghi rõ dữ liệu huấn luyện (183,200 ảnh từ tập riêng), chuẩn hóa, kích thước ảnh, dropout, adaptive pooling $L = 6$. - Tham số kỹ thuật: kích thước sliding window trong RPN ($n=3$), số region proposals ($k=3$), ngưỡng NMS = 0.7, cấu hình SVD để nén fully-connected layers. - Công cụ: Dựa trên Caffe và cuda-convnet, có thể tái triển khai nếu có dữ liệu và kiến thức kỹ thuật. ⇒ Tuy không có code đi kèm, nhưng mức chi tiết đủ tốt để reproduce nếu có kinh nghiệm.	4
3	Bài báo có giảm rủi ro “kết luận dựa trên một bối	- Kiểm thử trên 3 tập dữ liệu đa dạng, đại diện cho nhiều tình huống khác nhau (pose, occlusion, cluttered background, blur): AFW (ảnh web tự nhiên), FDDB (face detection khó với ellipses), Pascal Faces (đa cảnh và điều kiện ánh sáng).	5

cảnh hẹp”
bằng kiểm
thử đa điều
kiện/đa bộ dữ
liệu không?

- Bổ sung thêm tập dữ liệu riêng gồm **980,354 mặt người** trong điều kiện không kiểm soát để tăng tính tổng quát.
- Có minh họa bằng ảnh thật (Hình 7) để chứng minh khả năng khái quát.



Fig. 7. Examples of our detection results.

- **Dẫn chứng:** “We conduct the experiments on five datasets: AFW [17] (205 images with bounding boxes), FDDB [18] (2845 images with ellipses annotations), Pascal Faces dataset [19] (851 Pascal VOC images with bounding boxes), AFLW [21] (26,000 annotated faces), and the dataset collected by ourselves, which has a total of 980,354 annotated faces. All the face images are captured in uncontrolled conditions with

		<i>cluttered backgrounds and large variations in both face viewpoint and appearance”</i> (page 3-4/6)	
VI	Tính Empirical		
1	Bài báo có bằng chứng thực nghiệm trực tiếp (hard evidence) để hỗ trợ kết luận chính không?	- Bài báo cung cấp kết quả trên 3 benchmark datasets: AFW, FDDB, Pascal Faces. Các kết quả được trình bày qua các biểu đồ PR curve (AFW, Pascal Faces) và ROC curve (FDDB), có so sánh trực tiếp với nhiều phương pháp SOTA như: Hierarchical Deep Detector, Fast-RCNN, DPM, Viola-Jones, Google Picasa, v.v. ⇒ Thuyết phục cho kết luận về tính chính xác và hiệu quả của mô hình FaceHunter. - Dẫn chứng: “<i>“We conduct the experiments on five datasets: AFW [17] (205 images with bounding boxes), FDDB , ...”</i> (page 3-4/6)	5
2	Thực nghiệm có được thiết kế để phản ánh các dạng biến thiên/điều kiện khó của bài toán không?	- Dữ liệu bao gồm các hình ảnh với: • Giao diện không kiểm soát (in the wild) • Nhiều góc nhìn, occlusion, và nhiễu nền • Đa dạng về kích thước và độ mờ • Đặc biệt, tập dữ liệu tự thu thập có 980,354 khuôn mặt với “large variations in both face viewpoint and appearance” và ảnh minh họa (Hình 7, trang 5) cho thấy mô hình xử lý tốt các điều kiện khó. - Dẫn chứng: “<i>All the face images are captured in uncontrolled conditions with cluttered backgrounds and large variations in both face viewpoint and appearance.”</i> (page 4/6)	5
3	Bài báo có đánh giá khía cạnh thực dụng (ví dụ thời gian chạy/chi phí tính toán) để hỗ trợ tính khả thi không?	- Bài báo phân tích thời gian chạy chi tiết: • Thời gian per image trên GPU: 0.041s (conv) + 0.034s (NMS, fc, softmax) + 0.004s (proposal) → Tổng $\approx$ 0.079s/image. • So sánh với R-CNN truyền thống và cho thấy giảm chi phí tính toán rõ rệt. • Các kỹ thuật như truncated SVD, adaptive pooling, RPN sharing features được áp dụng để tối ưu chi phí. - Dẫn chứng: “Our detector takes only 0.041 s per image for convolutions... GPU time for computing NMS, fc, softmax... about 0.034 s...” (page 6/6)	5
VII	Tính Critical		
1	Bài báo có phê bình/đánh giá điểm yếu	- Bài báo chỉ rõ điểm yếu của các phương pháp trước như: • Adaboost-based: dựa trên đặc trưng thủ công → kém hiệu quả với ảnh “in the wild”	5

	của phương pháp trước để xác định khoảng trống nghiên cứu không?	• Deformable Part Model (DPM): không đủ mạnh với biến thiên lớn về hình dạng và occlusion • Các CNN trước: bỏ qua yếu tố ổn định và chính xác của bounding box, chưa tối ưu về chi phí tính toán. - Dẫn chứng: “...most detectors ignore the issue about the stability and reliability of the bounding box, which has a significant impact on the precision as well as the subsequent analysis.” (page 1/6)	
2	Bài báo có tự phê bình hạn chế của phương pháp đề xuất hoặc nêu điều kiện khó khăn khi triển khai không?	- Trong bài báo này việc tự nhận các giới hạn chưa được rõ ràng. - Bài báo không có phần riêng về <i>Limitations</i> hoặc thảo luận các thách thức/hạn chế của FaceHunter. Không thấy nêu rõ các tình huống mô hình có thể thất bại, như: xử lý khuôn mặt quá nhỏ, bị che khuất nặng, thiếu nhãn chất lượng thấp, v.v. - Mặc dù có trình bày ưu điểm so với mô hình khác, nhưng thiếu phản biện nội tại (những giới hạn của chính kiến trúc tác giả đề xuất). - Điều này làm giảm độ tin cậy về tính toàn diện.	2
3	Thiết kế đánh giá có đủ “chịu được phản biện” (critical scrutiny) thông qua kiểm tra đa khía cạnh (accuracy, stability, runtime, sensitivity) không?	- Bài báo đánh giá toàn diện với nhiều khía cạnh: • Accuracy: PR/ROC curves trên 3 dataset chuẩn • Runtime: phân tích thời gian từng module (conv, proposal, fc) rõ ràng • Stability & Generalization: test trên nhiều dataset có độ đa dạng cao • Ablation: so sánh giữa “with RPN” và “without RPN”, giữa multi-task và single-task => Thiết kế bài thực nghiệm đủ thuyết phục để kiểm chứng tính hiệu quả của mô hình.	5

=> **Điểm trung bình: 4.36 điểm.**