

Phân tích đánh giá Luận văn

MÔ HÌNH HỌC SÂU PHÁT HIỆN BẤT THƯỜNG ĐẬM ĐỘ TRÊN



ẢNH Y KHOA HỖ TRỢ TRONG CHẨN ĐOÁN UNG THƯ

Tác giả: Nguyễn Kiều Phát

STT	Tiêu chí đánh giá	Lý giải dựa vào nội dung của bài báo	Đánh giá
I	Nghiên cứu tốt		Tốt
1	Lựa chọn chủ đề và tính cấp thiết: Những vấn đề thách thức và thực tế.	❖ Tính thời sự và Bối cảnh nghiên cứu: - Bắt kịp xu hướng công nghệ (Năm 2018): Tại thời điểm 2018, Deep Learning và đặc biệt là CNN đang tạo ra cuộc cách mạng trong y tế. Tác giả đã nắm bắt rất đúng "điểm rơi" của công nghệ khi chọn đề tài này. - Bối cảnh y tế (Trang 9, 10): Tác giả dẫn dắt vấn đề từ sự bùng nổ dữ liệu hình ảnh y khoa và sự quá tải của bác sĩ chẩn đoán hình ảnh. Nhu cầu cần một "trợ lý ảo" để sàng lọc ban đầu là cực kỳ lớn. ⇒ Chủ đề không bị lỗi thời, ngược lại rất "hot" và đúng xu hướng chuyển đổi số trong y tế. ❖ Vấn đề giải quyết: Chọn bài toán "X-quang" thay vì "CT/MRI" (Trang 14) - Đây là điểm thông minh nhất trong việc chọn đề tài. Tác giả phân tích: - <i>CT scan</i>: Chính xác nhưng đắt tiền, gây nhiễm xạ cao, không có sẵn ở tuyến dưới. - <i>X-quang</i>: Rẻ, nhanh, phổ biến, nhưng khó đọc do hình ảnh chồng chéo (2D). ⇒ Việc xây dựng AI cho X-quang có ý nghĩa xã hội lớn hơn nhiều vì nó giúp người dân nghèo hoặc ở vùng sâu vùng xa (nơi chỉ có máy X-quang) có cơ hội được tầm soát ung thư sớm. ❖ Tính cấp thiết: Tác giả đã chỉ ra được những vấn đề bức thiết thúc đẩy nghiên cứu này: - Gánh nặng lên hệ thống y tế: Số lượng hình ảnh y khoa (X-quang, CT, MRI) ngày càng lớn khiến công việc đọc và chẩn đoán của bác sĩ ngày càng nặng nề. Nhu cầu cấp thiết là phải có công cụ hỗ trợ giảm tải cho bác sĩ. - Tầm quan trọng: Mặc dù CT cung cấp cái nhìn toàn diện hơn, nhưng chi phí cao và không sẵn có ở các bệnh viện nhỏ hoặc vùng nông thôn. Ngược lại, X-quang rẻ, nhanh và ít bức xạ hơn, nên vẫn là bước chẩn đoán đầu tiên phổ biến nhất để phát hiện bất thường. - Hỗ trợ chẩn đoán sớm: Việc phát hiện sớm các dấu hiệu bất thường (như đậm độ phổi) có ý nghĩa sống còn trong điều trị ung thư và các bệnh lý phổi. ❖ Độ khó và Thách thức của vấn đề: - Thách thức về Dữ liệu: Ảnh X-quang phổi rất khó phân tích vì xương sườn, xương đòn thường che lấp nhu mô phổi. Việc phát hiện "bất thường đậm độ" (nốt mờ nhỏ) lẫn trong xương là một bài toán khó ngay cả với bác sĩ, chứ chưa nói đến máy tính. Bên cạnh đó, để ứng dụng Deep Learning (như CNN) đòi hỏi phải có lượng lớn dữ liệu được gán nhãn chính xác bởi chuyên gia, điều này rất khó khăn và tốn kém. - Thách thức về Tài nguyên: Các mô hình học sâu thường yêu cầu phần cứng mạnh (GPU), tuy nhiên tác giả đặt ra bài toán không chỉ là "chạy được" mà là chạy trên nền tảng web (ConvNetJS) và máy tính cá nhân thông thường (CPU i7, không có GPU) (Trang 72-73) để dễ dàng triển khai tại các cơ sở tuyến dưới. Đây là thách thức kỹ thuật lớn vì CNN thường đòi hỏi tài nguyên tính toán khổng lồ. ❖ Phạm vi đề tài: Được giới hạn cụ thể, tựa đề ghi rõ: "<i>Phát hiện bất thường đậm độ</i>". Tác giả không tham lam làm chẩn đoán tất cả các bệnh phổi, mà tập trung vào dấu hiệu sớm của ung thư (các vùng đậm độ bất thường). Sự khu biệt này giúp đề tài có độ sâu thay vì dàn trải. ❖ Tính thực tế: - Sử dụng dữ liệu thực tế tại Việt Nam: Tác giả không chỉ dùng dữ liệu có sẵn trên mạng mà đã tự thu thập và xây dựng bộ dữ liệu AB-Chest X-rays từ Bệnh viện An Bình (TP.HCM). - Có sự tham vấn chuyên gia: Bộ dữ liệu này đã được các bác sĩ chuyên khoa chẩn đoán hình ảnh gán nhãn, đảm bảo độ tin cậy về mặt y khoa. - Triển khai ứng dụng: Tác giả đã xây dựng được công cụ phần mềm thực nghiệm chạy trên nền tảng web, chứng minh khả năng ứng dụng thực tiễn của đề tài vào quy trình chẩn đoán.	Tốt

2	Đọc những khảo sát liên quan đến lĩnh vực nghiên cứu: Độ bao phủ và cập nhật.	❖ Bao phủ về Cơ sở lý thuyết: Hệ thống hóa kiến thức nền tảng (Chương 2 - Trang 18-56): - Tác giả không chỉ giới thiệu CNN sơ sài mà đi rất sâu vào bản chất toán học. Bao phủ từ mạng nơ-ron sinh học, cấu trúc ANN, thuật toán lan truyền ngược (Backpropagation - có công thức toán học chi tiết tại trang 26-27). - Các thuật toán tối ưu: Bao phủ các phương pháp tối ưu hiện đại như SGD, Momentum, Adagrad, Adadelata (Trang 45-48). - Các hàm kích hoạt & Loss: Bao phủ Sigmoid, Tanh, ReLU, Softmax, Cross-entropy. ⇒ Phân lý thuyết nền tảng cực kỳ vững chắc, bao phủ đầy đủ các thành phần để xây dựng một mạng Deep Learning từ con số 0. ❖ Bao phủ về Các nghiên cứu liên quan: - Trong nước (Trang 15): Khảo sát các luận văn về nhận dạng chữ viết tay, biển số xe, và phát hiện bất thường y tế bằng KNN (Nguyễn Thị Thu [2]). Tác giả chỉ ra hạn chế của các phương pháp cũ (KNN) để làm bật lên nhu cầu dùng CNN. - Ngoài nước (Trang 16-17): Tác giả khảo sát các nghiên cứu ứng dụng CNN trong y tế. Tuy nhiên, có một điểm lệch pha nhẹ: Các nghiên cứu được mô tả chi tiết lại tập trung nhiều vào Ung thư vú (Gallego-Posada [7], Daniel Levy [2], Omar S. Soliman [12]) thay vì tập trung sâu vào X-quang phổi. ⇒ Mặc dù kỹ thuật CNN có thể chuyển giao (transfer) giữa các loại ảnh y tế, nhưng việc thiếu vắng sự phân tích sâu các bài báo chuyên về <i>Chest X-ray Nodule Detection</i> trong phần lời văn (dù có trong danh mục tham khảo) là một điểm trừ nhỏ về độ bao phủ chuyên sâu. ❖ Bao phủ về phương pháp: Tác giả không chỉ tập trung vào một kỹ thuật duy nhất mà đã khảo sát sự chuyển dịch từ các phương pháp học máy truyền thống (như SVM, K-NN, Neural Network cổ điển) sang các phương pháp học sâu hiện đại (Deep Learning, CNN). Điều này giúp người đọc thấy rõ bối cảnh công nghệ và lý do tại sao CNN lại ưu việt hơn trong xử lý ảnh. ❖ Bao phủ về ứng dụng: Phạm vi khảo sát trải rộng từ các bài toán nhận dạng cơ bản trong nước (nhận dạng chữ viết tay, biển số xe, độ chín trái cây) đến các bài toán y khoa phức tạp trên thế giới (phát hiện ung thư vú, phát hiện nốt phổi, phân đoạn ảnh y tế). Cách tiếp cận này giúp định vị nghiên cứu của luận văn nằm ở đâu trong bức tranh tổng thể của ngành Trí tuệ nhân tạo. ❖ Tính cập nhật của tài liệu tham khảo: Dữ liệu từ Danh mục tham khảo (Trang 86-88). Tại thời điểm bảo vệ (2018), các tài liệu tham khảo rất mới: - Năm 2017: Tài liệu [13] Tataru et al. về "<i>Deep Learning for abnormality detection in Chest X-Ray images</i>". Đây là tài liệu cực kỳ sát với đề tài. - Năm 2016: Các tài liệu [1] (Le Thi Thu Hang), [2] (Daniel Levy), [3] (Vu Manh Hung), [8], [9]. - Tỷ lệ: Hơn 50% tài liệu nằm trong khoảng 2-3 năm gần nhất so với thời điểm nghiên cứu. ⇒ Điều này cho thấy tác giả đã tiếp cận được những tri thức State-of-the-art (SOTA) lúc bấy giờ. ❖ Tính cập nhật về Công nghệ và Dữ liệu: - Công nghệ tại thời điểm nghiên cứu: Tại thời điểm luận văn được thực hiện (2018), Deep Learning và CNN đang là "làn sóng" công nghệ mới bùng nổ mạnh mẽ trong y tế. Việc tác giả lựa chọn đi sâu vào CNN thay vì các phương pháp cũ cho thấy tư duy bắt kịp thời đại. - Dữ liệu (Trang 70): Cập nhật bộ dữ liệu chuẩn Shenzhen (SZ-Chest X-rays) và trích dẫn nguồn từ <i>National Institutes of Health (NIH)</i>. Đây là các bộ dữ liệu chuẩn mực quốc tế mới được công bố rộng rãi vào giai đoạn đó. - Nguồn kiến thức: Tác giả tham khảo cả các khóa học trực tuyến nổi tiếng thời điểm đó như Andrew Ng's Coursera (Hình 2-26, Trang 47). Dù không phải bài báo hàn lâm, nhưng đây là nguồn kiến thức cập nhật nhất cho cộng đồng AI lúc bấy giờ. $\theta_1 := \theta_1 - \alpha \frac{\partial}{\partial \theta_1} J(\theta_1)$ If α is too small, gradient descent can be slow. If α is too large, gradient descent can overshoot the minimum. It may fail to converge, or even diverge.	Tốt
---	---	--	-----

Hình 2-26: Gradient gốc với tỷ lệ học tập nhỏ (trên) và lớn (dưới). Nguồn Andrew Ng's Machine Learning course on Coursera [16]

3	Dành nhiều thời gian cho tham khảo: Đánh giá chiều sâu của việc đọc và tổng hợp tài liệu.	❖ Chiều sâu trong việc nắm bắt cơ sở lý thuyết: Nắm vững kiến thức nền tảng và không né tránh Toán học (Chương 2). Phần cơ sở lý thuyết về mạng nơ-ron tích chập (CNN) được trình bày rất cặn kẽ, từ các phép toán tích chập (Convolution), các hàm kích hoạt (Activation functions), đến các kỹ thuật giảm thiểu overfitting (như Dropout). Điều này chứng tỏ tác giả không chỉ áp dụng công cụ ("black box") mà đã dành thời gian đọc hiểu sâu về toán học bên dưới mô hình. - Tích chập (Convolution): Trình bày công thức tích chập liên tục (2.8) và rời rạc (2.11) (Trang 32-33). $(f * g)(t) = \int_{-\infty}^{\infty} f(\tau)g(t - \tau)d\tau = \int_{-\infty}^{\infty} f(t - \tau)g(\tau)d\tau \quad (2.8)$ $f(x, y) * k(x, y) = \sum_{u=-\frac{m}{2}}^{\frac{m}{2}} \sum_{v=-\frac{n}{2}}^{\frac{n}{2}} k(u, v)f(x - u, y - v) \quad (2.11)$ - Lan truyền ngược (Backpropagation): Diễn giải chi tiết thuật toán cập nhật trọng số qua các công thức (2.5) đến (2.19). $a^{m+1} = f^{m+1}(W^{m+1}a^m + b^{m+1}) \text{ với } m = 0, 1, \dots, M - 1 \quad (2.5)$ $(f * g)(x) = \int_{\mathbb{R}^d} f(y)g(x - y)dy = \int_{\mathbb{R}^d} f(x - y)g(y)dy \quad (2.9)$ $\begin{aligned} (f * g)(n) &= \sum_{m=-\infty}^{\infty} f(m)g(n - m)dm \\ &= \sum_{m=-\infty}^{\infty} f(n - m)g(m)dm \end{aligned} \quad (2.10)$ $f(x) = \max(0, x) \quad (2.12)$ $\tanh \theta = \frac{\sinh \theta}{\cosh \theta} \quad (2.13)$  Hình 2-20: Biểu diễn của công thức 2.13 trên hệ trục tọa độ + Hàm Sigmoid: là hàm phi tuyến tính được định nghĩa như công thức sau: $y = \frac{1}{1 + e^{-x}} \quad (2.14)$  Hình 2-21: Biểu diễn của công thức 2.14 trên hệ trục tọa độ $y_i = \frac{e^{z_i}}{\sum_{j \in group} e^{z_j}} \quad (2.15) [4]$	Tốt
---	--	---	-----

$$C = - \sum_j t_j \log y_i$$

(2.16) [4]

$$\theta_{k+1} = \theta_k - \alpha_k \frac{\partial}{\partial \theta} C(\theta_k)$$

(2.17) [1]

$$\theta_{k+1} = \theta_k - \alpha_k \frac{\partial}{\partial \theta} L(\theta_k, z)$$

(2.18) [1]

$$\Delta \theta_{k+1} = \varepsilon \Delta \theta_k + (1 - \varepsilon) \frac{\partial}{\partial \theta} L(\theta_k, z)$$

(2.19) [1]

- **Tối ưu hóa (Optimization):** Không chỉ dùng SGD, tác giả hiểu sâu về các biến thể như *Momentum*, *Adagrad*, *Adadelta* (Trang 46-48).

⇒ Việc viết lại được các công thức này một cách mạch lạc chứng tỏ tác giả đã dành rất nhiều thời gian để đọc các tài liệu giáo khoa (Textbooks) và các bài báo nền tảng (Seminal papers), chứ không chỉ đọc hướng dẫn sử dụng thư viện.

❖ **Chiều sâu trong kiến thức nghiệp vụ:**

- **Hiểu sâu về đặc thù ảnh X-quang (Trang 56):** Tác giả phân tích kỹ các yếu tố ảnh hưởng chất lượng ảnh: *Độ tương phản*, *Độ rõ nét*, *Kích thước tiêu điểm phát tia*, *Sự tán xạ*.

- **Hiểu về dữ liệu y khoa:** Việc tham khảo các tài liệu y khoa giúp tác giả hiểu rằng dấu hiệu bất thường trên phổi thường rất tinh tế và dễ bị nhầm lẫn bởi xương sườn hoặc bóng tim. Kiến thức này (có được từ việc đọc tài liệu chuyên ngành) là cơ sở để tác giả xây dựng các **Quy tắc kết hợp (Fusion Rules)**, đặc biệt là quy tắc xử lý vùng xung đột.

- **Tổng hợp kiến thức giải phẫu để thiết kế mô hình:** Việc tác giả chia mô hình thành 3 phần (Phổi trái, Phổi phải, Toàn cục) không phải là ngẫu nhiên. Nó thể hiện sự tổng hợp kiến thức về giải phẫu học: Phổi là cơ quan đối xứng, việc so sánh hai bên là kỹ thuật đọc phim cơ bản của bác sĩ. Tác giả đã "dịch" kiến thức y khoa này thành kiến trúc mạng **Multi-CNNs**.

⇒ Đây là minh chứng rõ nhất cho việc tổng hợp tài liệu liên ngành (Y học + Tin học).

❖ **Sự tổng hợp và so sánh:**

- **Từ Máy học đến Học sâu:** Tác giả đã dành thời gian nghiên cứu sâu về lịch sử phát triển của các phương pháp. Thay vì chỉ trình bày các định nghĩa rời rạc, luận văn đã so sánh được sự khác biệt về hiệu quả giữa các phương pháp Máy học truyền thống (như SVM, KNN đã được dùng trong các nghiên cứu trước đó) với phương pháp Học sâu (Deep Learning).

- **Đối sánh các kiến trúc:** Tác giả không chọn bừa một mạng CNN. Thông qua việc tham khảo tài liệu, tác giả đã phân tích được ưu/nhược điểm của việc xử lý ảnh nguyên gốc so với việc chia tách ảnh, từ đó dẫn đến quyết định thiết kế mô hình **Multi-CNNs** (chia ảnh thành 3 phần: toàn thể, trái, phải) để tối ưu hóa khả năng nhận diện các chi tiết nhỏ.

- **So sánh các phương pháp (Trang 29-30):** Tác giả so sánh ANN truyền thống và CNN để biện luận tại sao ANN thất bại với ảnh lớn (do bùng nổ tham số) và CNN thành công (nhờ kết nối cục bộ và chia sẻ trọng số). Lập luận này rất chặt chẽ, logic.

- **Tổng hợp các luật kết hợp (Fusion Rules - Trang 67-69):** Tác giả không chỉ chọn một cách kết hợp kết quả. Tác giả đã tổng hợp kiến thức về *Ensemble Learning* để đề xuất 3 quy tắc (FR1 - trung bình, FR2 - trọng số, FR3 - vùng xung đột). Điều này cho thấy sự đầu tư suy nghĩ sâu sắc để giải quyết các trường hợp nhập nhằng (Consultation cases).

- **FR1: Quy tắc kết hợp dựa trên việc tính trung bình giá trị xác suất.**

Trường hợp	Giá trị xác suất	Kết luận
2	$V = \frac{V_{128F} + V_{64R} + (1 - V_{64L})}{3}$	$V > 0.5 \rightarrow \text{Normal}$ $V \leq 0.5 \rightarrow \text{Abnormal}$
3	$V = \frac{V_{128F} + V_{64L} + (1 - V_{64R})}{3}$	$V > 0.5 \rightarrow \text{Normal}$ $V \leq 0.5 \rightarrow \text{Abnormal}$
4	$V = \frac{V_{128F} + (1 - V_{64L}) + (1 - V_{64R})}{3}$	$V > 0.5 \rightarrow \text{Normal}$ $V \leq 0.5 \rightarrow \text{Abnormal}$
8		$V > 0.5 \rightarrow \text{Abnormal}$ $V \leq 0.5 \rightarrow \text{Normal}$

		- FR2: Quy tắc kết hợp dựa trên tổng thể. Trong quy tắc này xem giá trị xác suất V128F là gấp đôi so với 2 giá trị còn lại <table><tr><th>Trường hợp</th><th>Giá trị xác suất</th><th>Kết luận</th></tr><tr><td>2</td><td>$V = \frac{V128F + V64R + (1 - V64L)}{4}$</td><td>V > 0.5 ➔ Normal V <= 0.5 ➔ Abnormal</td></tr><tr><td>3</td><td>$V = \frac{V128F + V64L + (1 - V64R)}{4}$</td><td>V > 0.5 ➔ Normal V <= 0.5 ➔ Abnormal</td></tr><tr><td>4</td><td rowspan="2">$V = \frac{V128F + (1 - V64L) + (1 - V64R)}{4}$</td><td>V > 0.5 ➔ Normal V <= 0.5 ➔ Abnormal</td></tr><tr><td>8</td><td>V > 0.5 ➔ Abnormal V <= 0.5 ➔ Normal</td></tr></table> - FR3: Quy tắc kết hợp dựa trên các vùng xung đột. Trong phương pháp này ta chỉ tính trung bình của toàn bộ ảnh và phần (trái hoặc phải) có kết luận ngược với kết quả của CNN-128F. <table><tr><th>Trường hợp</th><th>Giá trị xác suất</th><th>Kết luận</th></tr><tr><td>2</td><td>$V = \frac{V128F + (1 - V64L)}{2}$</td><td>V > 0.5 ➔ Normal V <= 0.5 ➔ Abnormal</td></tr><tr><td>3</td><td>$V = \frac{V128F + (1 - V64R)}{2}$</td><td>V > 0.5 ➔ Normal V <= 0.5 ➔ Abnormal</td></tr><tr><td>4</td><td rowspan="2">$V = \frac{2 * V128F + (1 - V64L) + (1 - V64R)}{4}$</td><td>V > 0.5 ➔ Normal V <= 0.5 ➔ Abnormal</td></tr><tr><td>8</td><td>V > 0.5 ➔ Abnormal V <= 0.5 ➔ Normal</td></tr></table> ❖ Tính chọn lọc và liên kết: - Tài liệu sát sườn: Danh mục tham khảo tập trung cao độ vào các từ khóa chính: "Lung nodule detection" (phát hiện nốt phổi), "Chest X-ray" (X-quang ngực), "Deep Learning". Tác giả không lan man sang các lĩnh vực AI không liên quan. - Nguồn dữ liệu uy tín: Tác giả đã tìm tòi và tiếp cận được các nguồn dữ liệu chuẩn mực (như bộ dữ liệu Thâm Quyển - Shenzhen dataset, và dữ liệu từ mạng lưới bệnh viện Đại học Indiana), cho thấy sự đầu tư thời gian trong việc tìm kiếm tài nguyên nghiên cứu chất lượng cao. ❖ Điểm hạn chế về nguồn tài liệu: Phụ thuộc vào tài liệu thứ cấp. Như đã phân tích ở phần trước, danh mục tham khảo có chứa các link <i>Wikipedia</i> và <i>Blog</i>. Điều này gợi ý rằng một phần thời gian đọc của tác giả dành cho các tài liệu dễ hiểu, tóm tắt sẵn thay vì "đào sâu" vào các bài báo gốc (Original Papers) khó đọc hơn. Ví dụ: Công thức Adadelta (Trang 48) được trích dẫn tốt từ Zeiler [14], nhưng một số khái niệm cơ bản lại trích dẫn Wikipedia [15].	Trường hợp	Giá trị xác suất	Kết luận	2	$V = \frac{V128F + V64R + (1 - V64L)}{4}$	V > 0.5 ➔ Normal V <= 0.5 ➔ Abnormal	3	$V = \frac{V128F + V64L + (1 - V64R)}{4}$	V > 0.5 ➔ Normal V <= 0.5 ➔ Abnormal	4	$V = \frac{V128F + (1 - V64L) + (1 - V64R)}{4}$	V > 0.5 ➔ Normal V <= 0.5 ➔ Abnormal	8	V > 0.5 ➔ Abnormal V <= 0.5 ➔ Normal	Trường hợp	Giá trị xác suất	Kết luận	2	$V = \frac{V128F + (1 - V64L)}{2}$	V > 0.5 ➔ Normal V <= 0.5 ➔ Abnormal	3	$V = \frac{V128F + (1 - V64R)}{2}$	V > 0.5 ➔ Normal V <= 0.5 ➔ Abnormal	4	$V = \frac{2 * V128F + (1 - V64L) + (1 - V64R)}{4}$	V > 0.5 ➔ Normal V <= 0.5 ➔ Abnormal	8	V > 0.5 ➔ Abnormal V <= 0.5 ➔ Normal	
Trường hợp	Giá trị xác suất	Kết luận																													
2	$V = \frac{V128F + V64R + (1 - V64L)}{4}$	V > 0.5 ➔ Normal V <= 0.5 ➔ Abnormal																													
3	$V = \frac{V128F + V64L + (1 - V64R)}{4}$	V > 0.5 ➔ Normal V <= 0.5 ➔ Abnormal																													
4	$V = \frac{V128F + (1 - V64L) + (1 - V64R)}{4}$	V > 0.5 ➔ Normal V <= 0.5 ➔ Abnormal																													
8		V > 0.5 ➔ Abnormal V <= 0.5 ➔ Normal																													
Trường hợp	Giá trị xác suất	Kết luận																													
2	$V = \frac{V128F + (1 - V64L)}{2}$	V > 0.5 ➔ Normal V <= 0.5 ➔ Abnormal																													
3	$V = \frac{V128F + (1 - V64R)}{2}$	V > 0.5 ➔ Normal V <= 0.5 ➔ Abnormal																													
4	$V = \frac{2 * V128F + (1 - V64L) + (1 - V64R)}{4}$	V > 0.5 ➔ Normal V <= 0.5 ➔ Abnormal																													
8		V > 0.5 ➔ Abnormal V <= 0.5 ➔ Normal																													
4	Phát biểu bài toán thiết lập các cơ sở dữ liệu chuẩn và tiến hành thực nghiệm.	❖ Phát biểu bài toán: Mô hình hóa bài toán (Trang 14, 57): - Tác giả chuyển đổi bài toán y khoa (Chẩn đoán bệnh) thành bài toán kỹ thuật: Phân lớp ảnh nhị phân (Binary Classification) trong học có giám sát. Đầu vào là ảnh X-quang phổi, đầu ra là nhãn: Bình thường (Normal) hoặc Bất thường (Abnormal/Disease) dựa trên các vùng đậm độ. - Phạm vi giải quyết: Bài toán không tham vọng chẩn đoán mọi loại bệnh phổi mà tập trung vào dấu hiệu "bất thường đậm độ" - bước sàng lọc đầu tiên quan trọng nhất để bác sĩ quyết định có chỉ định các xét nghiệm chuyên sâu tiếp theo hay không. - Điểm sáng tạo: Tác giả không xem xét bức ảnh X-quang như một khối duy nhất. Bài toán được chia nhỏ thành 3 bài toán con: Phân loại Phổi Trái (CNN-64L), Phân loại Phổi Phải (CNN-64R), Phân loại Toàn cục (CNN-128F). ⇒ Cách phát biểu bài toán này rất sát với tư duy lâm sàng (so sánh hai bên phổi) và giải quyết tốt vấn đề kích thước ảnh lớn. ❖ Thiết lập cơ sở dữ liệu chuẩn: Chiến lược dữ liệu "Lai" (Hybrid Dataset - Trang 70). Tác giả sử dụng 2 nguồn dữ liệu: - Chuẩn hóa dữ liệu nội địa (AB-Chest X-rays): ▪ Tác giả không dùng dữ liệu thô mà đã qua quy trình chuẩn hóa: Cắt vùng phổi (ROI), chuyển về ảnh xám (Grayscale), và thay đổi kích thước về 128 x 128 pixel để phù hợp với kiến trúc mạng. ▪ Độ tin cậy cao: Điểm mạnh nhất là khâu gán nhãn (Labeling). Dữ liệu được thu thập từ Bệnh viện An Bình và được gán nhãn xác thực bởi chuyên gia (PGS.BS Nguyễn Hoài Nam và các bác sĩ chẩn đoán hình ảnh). Điều này biến dữ liệu thô thành "cơ sở dữ liệu chuẩn" (Ground Truth) có giá trị khoa học. - Dữ liệu đối chứng quốc tế (SZ-Chest X-rays): Tác giả thiết lập thêm bộ dữ liệu của Viện Y tế Quốc gia Hoa Kỳ (NIH) để làm chuẩn so sánh, đảm bảo mô hình không bị thiên lệch theo thiết bị chụp của một bệnh viện cụ thể - Quy trình Tiền xử lý (Preprocessing - Trang 71, 73): Mô tả chi tiết các bước: Cắt (Crop), Chia đôi (Split Left/Right), Resize về 128x128 và 64x128. Việc chuẩn bị dữ liệu này khớp hoàn toàn với kiến trúc Multi-CNNs đã đề xuất.	Tốt																												

❖ **Tiến hành thực nghiệm (Trang 72):** Tác giả thực hiện trên **CPU (Core i7, No GPU)** và nền tảng web **ConvNetJS**. Điều này chứng minh tính "nhẹ" và khả năng triển khai rộng rãi của mô hình. **Phương pháp huấn luyện (Training Strategy - Trang 73):**

- Chia dữ liệu theo phương pháp **Hold-out**: Train/Val/Test với tỷ lệ cụ thể (150/150/50 cho bộ An Bình).
- Huấn luyện riêng lẻ từng mạng thành phần trước, sau đó mới kết hợp lại.

Bảng 4-2: Mô tả chi tiết số lượng hình ảnh lựa chọn trong bộ dữ liệu để huấn luyện và kiểm tra cho từng thành phần của CNN của mô hình

Bộ dữ liệu	Dữ liệu huấn luyện và đánh giá (Training and Validation dataset)			Dữ liệu kiểm tra (Testing dataset)		
	Normal	Abnormal	Tổng	Normal	Abnormal	Tổng
AB-Chest X-rays	150	150	300	50	50	100

Sau đó tiến hành xử lý dữ liệu hình ảnh theo phương pháp đã nêu tại mục 4.1.2 của luận văn. Đề huấn luyện và đánh giá từng CNN thành phần, học viên sử dụng phương pháp Hold-out đã trình bày tại mục 2.4.1 của luận văn và thực hiện như sau:




Kết quả huấn luyện của từng thành phần trên từng bộ dữ liệu được mô tả như bảng 4-3.

Bảng 4-3: Kết quả huấn luyện các CNN thành phần của mô hình Mulit-CNNs

Mạng CNN Bộ dữ liệu	CNN-128F		CNN-64L		CNN-64R	
	Độ chính xác	Thời gian	Độ chính xác	Thời gian	Độ chính xác	Thời gian
AB-Chest X-rays	94%	360 phút	93%	25 phút	93%	150 phút

- **Kịch bản kiểm thử (Test Scenarios - Trang 75-77):** Kiểm thử trên dữ liệu nội bộ (An Bình). Và kiểm thử chéo trên dữ liệu quốc tế (Shenzhen) để đánh giá khả năng tổng quát hóa (Generalization).



Hình 4-5: Biểu đồ so sánh độ chính xác của mô hình trên từng tập dữ liệu ứng với từng phương pháp tính toán kết hợp

5	Phân tích sâu kết quả thực nghiệm.		Tốt																																																																																																			
5.1	Bài báo có phân tích đủ chi tiết với các trường hợp thực nghiệm chưa?	❖ Phân tích theo Thành phần mô hình: Tác giả không chỉ đánh giá mô hình tổng thể (Multi-CNNs) mà còn đánh giá riêng lẻ hiệu quả của từng mạng thành phần. Bảng 4-3, 4-4 (Trang 73, 75): So sánh độ chính xác của riêng <i>CNN-128F</i> (92%), <i>CNN-64L</i> (86%) và <i>CNN-64R</i> (78%). Việc này giúp nhìn thấy rõ: Mạng toàn cục (Full) hiệu quả hơn mạng cục bộ (L/R), và phổi trái dễ chẩn đoán hơn phổi phải (hoặc ngược lại). Đây là phân tích rất chi tiết. Bảng 4-4: Kết quả kiểm tra trên 50 hình ảnh thuộc bộ dữ liệu AB-Chest X-rays tương ứng với 3 mạng CNN thành phần <table><tr><th rowspan="3">Luật kết hợp Kết luận</th><th colspan="6">Kết quả kiểm tra trên 50 ảnh của bộ dữ liệu AB-Chest X-rays</th></tr><tr><th colspan="2">CNN-128F</th><th colspan="2">CNN-64L</th><th colspan="2">CNN-64R</th></tr><tr><th>Số lượng</th><th>Độ chính xác</th><th>Số lượng</th><th>Độ chính xác</th><th>Số lượng</th><th>Độ chính xác</th></tr><tr><td>Đúng</td><td>46</td><td>92%</td><td>43</td><td>86%</td><td>39</td><td>78%</td></tr><tr><td>Sai</td><td>4</td><td>8%</td><td>7</td><td>14%</td><td>11</td><td>22%</td></tr></table> ❖ Phân tích theo Chiến lược kết hợp: Tác giả không chỉ đưa ra một kết quả tốt nhất mà trình bày rõ ràng sự tiến hóa của kết quả qua từng phương pháp thử nghiệm: từ Quy tắc 1 (FR1 - Phép giao/AND), Quy tắc 2 (FR2 - Phép hợp/OR) đến Quy tắc 3 (FR3 - Xử lý vùng xung đột). Tác giả còn giải thích được <i>nguyên nhân</i> tại sao FR3 lại vượt trội. Đó là vì FR3 không chỉ tin tưởng mù quáng vào một mạng nào, mà nó nhận diện được các trường hợp "tranh chấp" (khi mạng toàn cục bảo Bình thường nhưng mạng cục bộ bảo Bất thường) để đưa ra cơ chế xử lý riêng. Đây là một phân tích định tính (qualitative analysis) rất giá trị bên cạnh định lượng. - Bảng 4-5 (Trang 75): Trên tập An Bình, FR3 đạt cao nhất (96%) so với FR1/FR2 (94%). Bảng 4-5: Kết quả kiểm tra trên 50 hình ảnh thuộc bộ dữ liệu AB-Chest X-rays tương ứng với 3 luật kết hợp <table><tr><th rowspan="3">Luật kết hợp Kết luận</th><th colspan="6">Kết quả kiểm tra trên 50 ảnh của bộ dữ liệu AB-Chest X-rays</th></tr><tr><th colspan="2">FR1</th><th colspan="2">FR2</th><th colspan="2">FR3</th></tr><tr><th>Số lượng</th><th>Độ chính xác</th><th>Số lượng</th><th>Độ chính xác</th><th>Số lượng</th><th>Độ chính xác</th></tr><tr><td>Đúng</td><td>47</td><td>94%</td><td>47</td><td>94%</td><td>48</td><td>96%</td></tr><tr><td>Sai</td><td>3</td><td>6%</td><td>3</td><td>6%</td><td>2</td><td>4%</td></tr></table> - Bảng 4-7 (Trang 76): Trên tập Shenzhen, sự chênh lệch còn rõ rệt hơn: FR3 (92%) vượt trội so với FR1/FR2 (72%) ⇒ Tác giả đã phân tích sâu để tìm ra chiến lược tối ưu, chứng minh rằng cách kết hợp thông minh (dựa trên vùng xung đột) tốt hơn là cộng trung bình đơn thuần. Bảng 4-7: Kết quả kiểm tra trên 150 hình ảnh thuộc bộ dữ liệu SZ-Chest X-rays tương ứng với 3 luật kết hợp <table><tr><th rowspan="3">Luật kết hợp Kết luận</th><th colspan="6">Kết quả trên 150 ảnh của bộ dữ liệu SZ-Chest X-rays</th></tr><tr><th colspan="2">FR1</th><th colspan="2">FR2</th><th colspan="2">FR3</th></tr><tr><th>Số lượng</th><th>Độ chính xác</th><th>Số lượng</th><th>Độ chính xác</th><th>Số lượng</th><th>Độ chính xác</th></tr><tr><td>Đúng</td><td>108</td><td>72%</td><td>108</td><td>72%</td><td>138</td><td>92%</td></tr><tr><td>Sai</td><td>42</td><td>28%</td><td>42</td><td>28%</td><td>12</td><td>8%</td></tr></table> ❖ Phân tích theo Bộ dữ liệu: Tác giả phân tích kết quả trên 2 trường hợp dữ liệu khác nhau hoàn toàn: - Trường hợp 1 (Nội bộ): Dữ liệu Bệnh viện An Bình (cùng nguồn huấn luyện) → Đạt 96%. - Trường hợp 2 (Độc lập): Dữ liệu Shenzhen (khác nguồn, chưa từng học) → Đạt 92%. ⇒ Tác giả thẳng thắn chỉ ra sự sụt giảm độ chính xác khi áp dụng mô hình lên dữ liệu quốc tế (từ 96% xuống 92%). Việc phân tích này cho thấy sự trung thực trong nghiên cứu và khả năng nhìn nhận thực tế về vấn đề "Overfitting" (học vẹt) hoặc sự khác biệt về miền dữ liệu (Domain Shift) giữa các dòng máy chụp X-quang khác nhau. Việc phân tích sự sụt giảm hiệu năng (từ 96% xuống 92%) khi chuyển sang dữ liệu mới là một phân tích rất trung thực và khoa học. ❖ Phân tích theo Chỉ số Y tế: Thay vì chỉ tập trung vào độ chính xác (Accuracy), luận văn phân tích kỹ Độ nhạy (TPR) và Độ đặc hiệu (TNR). Tại các Bảng 4-10 và 4-12 (Trang 79, 81), tác giả phân tích chi tiết các chỉ số sống còn trong y tế: - TPR (Độ nhạy): Tỷ lệ phát hiện đúng bệnh (0.96 trên An Bình, 0.89 trên Shenzhen). - FNR (Tỷ lệ bỏ sót): Tỷ lệ bỏ sót bệnh (0.04 trên An Bình, 0.11 trên Shenzhen). ⇒ Đây là mức độ chi tiết cần thiết cho bài toán y khoa, vì bỏ sót ung thư (FNR) nguy hiểm hơn nhiều so với báo nhầm. ⇒ Tác giả lập luận rằng trong bài toán tầm soát ung thư, việc đạt độ nhạy cao (0.96 trên tập An Bình) là yếu tố tiên quyết để không bỏ sót bệnh nhân. Phân tích này cho thấy tác giả hiểu rõ ngữ cảnh ứng dụng thực tế của bài toán.	Luật kết hợp Kết luận	Kết quả kiểm tra trên 50 ảnh của bộ dữ liệu AB-Chest X-rays						CNN-128F		CNN-64L		CNN-64R		Số lượng	Độ chính xác	Số lượng	Độ chính xác	Số lượng	Độ chính xác	Đúng	46	92%	43	86%	39	78%	Sai	4	8%	7	14%	11	22%	Luật kết hợp Kết luận	Kết quả kiểm tra trên 50 ảnh của bộ dữ liệu AB-Chest X-rays						FR1		FR2		FR3		Số lượng	Độ chính xác	Số lượng	Độ chính xác	Số lượng	Độ chính xác	Đúng	47	94%	47	94%	48	96%	Sai	3	6%	3	6%	2	4%	Luật kết hợp Kết luận	Kết quả trên 150 ảnh của bộ dữ liệu SZ-Chest X-rays						FR1		FR2		FR3		Số lượng	Độ chính xác	Số lượng	Độ chính xác	Số lượng	Độ chính xác	Đúng	108	72%	108	72%	138	92%	Sai	42	28%	42	28%	12	8%	Tốt
Luật kết hợp Kết luận	Kết quả kiểm tra trên 50 ảnh của bộ dữ liệu AB-Chest X-rays																																																																																																					
	CNN-128F			CNN-64L		CNN-64R																																																																																																
	Số lượng	Độ chính xác	Số lượng	Độ chính xác	Số lượng	Độ chính xác																																																																																																
Đúng	46	92%	43	86%	39	78%																																																																																																
Sai	4	8%	7	14%	11	22%																																																																																																
Luật kết hợp Kết luận	Kết quả kiểm tra trên 50 ảnh của bộ dữ liệu AB-Chest X-rays																																																																																																					
	FR1		FR2		FR3																																																																																																	
	Số lượng	Độ chính xác	Số lượng	Độ chính xác	Số lượng	Độ chính xác																																																																																																
Đúng	47	94%	47	94%	48	96%																																																																																																
Sai	3	6%	3	6%	2	4%																																																																																																
Luật kết hợp Kết luận	Kết quả trên 150 ảnh của bộ dữ liệu SZ-Chest X-rays																																																																																																					
	FR1		FR2		FR3																																																																																																	
	Số lượng	Độ chính xác	Số lượng	Độ chính xác	Số lượng	Độ chính xác																																																																																																
Đúng	108	72%	108	72%	138	92%																																																																																																
Sai	42	28%	42	28%	12	8%																																																																																																

Bảng 4-10: Biểu diễn các cái trị TPR, FNR, FPR, TNR trên tập dữ liệu AB-Chest X-rays

	Dự đoán: Abnormal	Dự đoán: Normal
Thực tế: Abnormal	$TPR = 24 / (24 + 1) = 0.96$	$FNR = 1 / (24 + 1) = 0.04$
Thực tế: Normal	$FPR = 1 / (1 + 24) = 0.04$	$TNR = 24 / (1 + 24) = 0.96$

Bảng 4-12: Biểu diễn các cái trị TPR, FNR, FPR, TNR trên tập dữ liệu SZ-Chest X-rays


	Dự đoán: Abnormal	Dự đoán: Normal
Thực tế: Abnormal	$TPR = 67 / (67 + 8) = 0.89$	$FNR = 8 / (67 + 8) = 0.11$
Thực tế: Normal	$FPR = 4 / (4 + 71) = 0.05$	$TNR = 71 / (4 + 71) = 0.95$

- ❖ **Phân tích về Hiệu năng tính toán:** Đo đếm thời gian:
- **Bảng 4-8 (Trang 77):** Phân tích thời gian xử lý trung bình cho 1 ảnh. Mô hình Multi-CNNs tốn ~305ms.

Bảng 4-8: Thời gian trung bình của quá trình tính toán để đưa ra kết luận cuối cùng cho 1 ảnh đầu vào

Mạng	CNN-128F	CNN-64R	CNN-64L	Multi-CNNs
Thời gian				
Thời gian trung bình	146.47 ms	73.58 ms	80.31 ms	305.87 ms


- **Biểu đồ 4-4 (Trang 74):** So sánh thời gian huấn luyện (360 phút vs 25 phút).



Hình 4-4: Biểu đồ so sánh thời gian huấn luyện để đạt được độ chính xác cao nhất của mỗi mạng CNN thành phần

⇒ Phân tích này trả lời cho câu hỏi về tính khả thi khi triển khai thực tế.


- ❖ **Điểm cần cải thiện:** Mặc dù phân tích số liệu rất tốt, nhưng phần "Visual Error Analysis" (Phân tích lỗi trực quan) có thể làm sâu hơn nữa. Tức là, nếu tác giả đưa ra hình ảnh cụ thể của những ca bị dự đoán sai (False Positive/False Negative) và phân tích *tại sao* mô hình lại sai trên tấm ảnh đó (ví dụ: do bóng tim che khuất, do xương sườn dày...) thì luận văn sẽ hoàn hảo hơn. Tuy nhiên, ở mức độ hiện tại, việc phân tích các trường hợp xung đột (conflict cases) trong FR3 đã phần nào giải quyết vấn đề này.

5.3	Kết quả thực nghiệm có tính nhất quán với kết luận (hoặc giả thiết) không?	❖ Nhất quán với giả thiết về Mô hình Multi-CNNs: - Giả thiết: Tác giả cho rằng việc chia ảnh phổi thành các vùng giải phẫu riêng biệt (phổi trái, phổi phải) và kết hợp lại sẽ hiệu quả hơn là chỉ để máy học trên một bức ảnh toàn thể (dễ mất chi tiết). - Kết quả thực nghiệm: ▪ Đơn lẻ (Bảng 4-4, Trang 75): Các mạng đơn lẻ (chỉ chạy CNN-128F hoặc chỉ CNN-64L/R) có độ chính xác thấp hơn hoặc không ổn định bằng mô hình kết hợp với CNN-128F (92%), CNN-64L (86%), CNN-64R (78%). ▪ Kết hợp (Bảng 4-5, Trang 75): Quy tắc kết hợp FR3 (xử lý vùng xung đột giữa các mạng con) đạt độ chính xác cao nhất (96%). ⇒ Số liệu 96% > 92% đã chứng minh giả thiết là đúng đắn. Thực nghiệm đã xác nhận rằng kiến trúc Multi-CNNs và cơ chế xử lý xung đột là giải pháp đúng đắn để nâng cao hiệu năng. ❖ Nhất quán với giả thiết về Quy tắc kết hợp: - Giả thiết: Quy tắc FR3 (dựa trên vùng xung đột) sẽ hiệu quả hơn cách cộng trung bình đơn giản (FR1, FR2) vì nó xử lý được các ca khó. - Kết quả thực nghiệm (Điểm nhấn quan trọng): ▪ Trên tập An Bình (Bảng 4-5): FR3 (96%) > FR1/FR2 (94%). Sự chênh lệch ít. ▪ Trên tập Shenzhen (Bảng 4-7, Trang 76): FR3 (92%) >> FR1/FR2 (72%). ⇒ Đây là bằng chứng đanh thép nhất. Khi gặp dữ liệu lạ (Shenzhen), các quy tắc trung bình (FR1, FR2) bị sụt giảm nghiêm trọng (tụt 22%), trong khi FR3 vẫn giữ vững phong độ. Điều này nhất quán tuyệt đối với kết luận rằng FR3 là giải pháp tối ưu. ❖ Nhất quán với Mục tiêu "Hỗ trợ chẩn đoán" (Y tế): - Mục tiêu: Giúp bác sĩ không bỏ sót bệnh (giảm False Negative). - Kết quả thực nghiệm: ▪ Bảng 4-10 (Trang 79): Tỷ lệ bỏ sót (FNR) trên tập An Bình chỉ là 0.04 (4%). ▪ Bảng 4-12 (Trang 81): Tỷ lệ bỏ sót trên tập Shenzhen là 0.11 (11%). ⇒ Với độ nhạy (TPR) đạt 0.96 và 0.89, mô hình hoàn toàn đủ khả năng đóng vai trò "người sàng lọc" (screening) hỗ trợ bác sĩ, đúng như tên đề tài đã đặt ra. ❖ Nhất quán với Khả năng triển khai: - Yêu cầu: Tác giả đặt mục tiêu xây dựng mô hình có thể chạy trên trình duyệt web, máy tính cá nhân không cần GPU để phục vụ các bệnh viện tuyến dưới. - Kết quả (Bảng 4-8, Trang 77): Thời gian xử lý trung bình: 305.87 ms (khoảng 0.3 giây/ảnh) trên CPU Core i7. ⇒ Tốc độ này là tức thời (real-time) đối với trải nghiệm người dùng, khẳng định tính khả thi của việc triển khai trên web/máy trạm của bác sĩ. ❖ Nhất quán với yêu cầu Y khoa (độ nhạy cao): - Giả thiết: Trong y tế, việc bỏ sót bệnh (False Negative) nguy hiểm hơn là báo nhầm người lành thành bệnh (False Positive). Do đó, mô hình cần ưu tiên Độ nhạy (Sensitivity). - Kết quả thực nghiệm: Trên tập dữ liệu An Bình, Độ nhạy (TPR) đạt con số rất cao là 0.96. ⇒ Kết quả này nhất quán với yêu cầu hỗ trợ chẩn đoán sàng lọc, giúp bác sĩ yên tâm rằng mô hình ít khi bỏ sót các ca bất thường. ❖ Nhất quán về khả năng tổng quát hóa: - Giả thiết: Mô hình huấn luyện trên dữ liệu Việt Nam có thể hoạt động tốt trên các nguồn dữ liệu khác? - Kết quả thực nghiệm: Khi kiểm thử trên bộ dữ liệu SZ-Chest X-rays, độ chính xác giảm nhẹ xuống 92% (so với 96% nội bộ) nhưng vẫn ở mức cao và chấp nhận được. ⇒ Kết quả này cho thấy mô hình có tính ổn định, không bị "học vẹt" (overfitting) quá mức vào dữ liệu của một bệnh viện duy nhất, khẳng định tính khả thi khi triển khai rộng rãi.	Tốt
5.4	Có thể tinh chỉnh một số thông số chính để có kết quả tốt hơn không? Nếu có thì dùng hình minh hoạ hoặc bảng hiển thị hiệu suất hệ thống.	❖ Cơ sở lý thuyết vững chắc (Chương 2): Tác giả dành dung lượng lớn để giải thích lý thuyết về việc tinh chỉnh tham số: - Hình 2-27 (Trang 47): Minh họa ảnh hưởng của <i>Learning Rate</i> (Tỷ lệ học) đến độ hội tụ.  Hình 2-27: Ảnh hưởng của giá trị learning rate đến độ hội tụ của mô hình mạng [16] - Mục 2.5.1 (Trang 51): Trình bày quy trình 3 giai đoạn (Train → Validate → Test), trong đó giai đoạn 2 dùng để "<i>tunning parameter để nâng cao độ chính xác</i>".	Tốt


		❖ Thực nghiệm (Chương 4): - Số liệu: Trong phần báo cáo kết quả (Bảng 4-3, 4-4), tác giả chỉ trình bày kết quả cuối cùng (đã tối ưu) mà thiếu các bảng số liệu so sánh quá trình tinh chỉnh (ví dụ: So sánh Accuracy khi Learning Rate = 0.01 vs 0.001). - Hình minh họa: Hình 4-4 (Trang 74) so sánh thời gian huấn luyện. Đây là một dạng tinh chỉnh: Chấp nhận thời gian lâu hơn (360 phút) cho mạng lớn để đạt độ chính xác cao hơn, hoặc dùng mạng nhỏ (25 phút) chấp nhận độ chính xác thấp hơn. ⇒ Tác giả có thực hiện tinh chỉnh (thể hiện qua quy trình), nhưng báo cáo hơi thiếu các bảng số liệu so sánh các phương án tham số (Hyperparameter ablation study). Biểu đồ so sánh thời gian huấn luyện để đạt độ chính xác mong muốn trên từng bộ dữ liệu của từng CNN thành phần <table><tr><th>CNN thành phần</th><th>Thời gian huấn luyện (phút)</th></tr><tr><td>CNN-128F</td><td>360</td></tr><tr><td>CNN-64L</td><td>25</td></tr><tr><td>CNN-64R</td><td>150</td></tr></table> Các CNN thành phần trên từng bộ dữ liệu ■ AB-Chest X-rays Hình 4-4: Biểu đồ so sánh thời gian huấn luyện để đạt được độ chính xác cao nhất của mỗi mạng CNN thành phần	CNN thành phần	Thời gian huấn luyện (phút)	CNN-128F	360	CNN-64L	25	CNN-64R	150	
CNN thành phần	Thời gian huấn luyện (phút)										
CNN-128F	360										
CNN-64L	25										
CNN-64R	150										
5.5	Kết quả thực nghiệm có tương ứng với mục tiêu bài báo hay không?	❖ Đối chiếu Mục tiêu (Trang 11) vs. Kết quả (Chương 4 & 5): - Mục tiêu 1: Xây dựng mô hình học sâu hỗ trợ chẩn đoán bất thường đậm độ phổi. <i>"Áp dụng mô hình... trên bộ dữ liệu tự thu thập từ bệnh viện"</i>. ⇒ Kết quả: Thu thập và gán nhãn bộ dữ liệu AB-Chest X-rays từ Bệnh viện An Bình. Đã thực hiện trên bộ dữ liệu Bệnh viện An Bình (450 ảnh), đạt 96%. (Đạt) - Mục tiêu 2: <i>"Trên bộ dữ liệu chuẩn đã được công bố"</i>. ⇒ Kết quả: Đã thực hiện trên bộ Shenzhen (662 ảnh), đạt 92%. (Đạt) - Mục tiêu 3: <i>"Đề xuất mô hình... Multi-CNNs"</i>. ⇒ Kết quả: Đã xây dựng và chứng minh Multi-CNNs hiệu quả hơn CNN đơn lẻ. (Đạt) - Mục tiêu 4: Hệ thống phải hoạt động được trên môi trường hạn chế tài nguyên (máy tính cá nhân, không GPU). ⇒ Kết quả: Sử dụng thư viện ConvNetJS chạy trên trình duyệt web. Tốc độ xử lý trung bình ~305ms/ảnh trên CPU Core i7. Đây là tốc độ "thời gian thực" chấp nhận được trong khám chữa bệnh. (Đạt). ➔ Kết quả thực nghiệm khớp 100% với các gạch đầu dòng mục tiêu đã đề ra ban đầu.	Tốt								
5.6	Cái gì được tìm thấy là bất thường nên tránh trong thực nghiệm.	❖ Phát hiện bất thường quan trọng (The "Shenzhen Anomaly"): - Hiện tượng: Khi áp dụng quy tắc kết hợp trung bình đơn giản (FR1, FR2) lên bộ dữ liệu mới (Shenzhen), độ chính xác sụt giảm thê thảm xuống còn 72% (Bảng 4-7, Trang 76), trong khi trên bộ dữ liệu cũ (An Bình) vẫn đạt 94%. - Nguyên nhân: Do dữ liệu khác nguồn có đặc điểm phân bố khác nhau, dẫn đến các mạng con (Local networks) bị xung đột ý kiến nhiều hơn. ⇒ Bài học tránh: Trong các bài toán Ensemble Learning (Học kết hợp) trên dữ liệu y tế đa nguồn, tuyệt đối tránh dùng phương pháp lấy trung bình cộng (Averaging) ngây thơ. Phải dùng phương pháp xử lý xung đột (như FR3) mới đảm bảo độ ổn định (Robustness). ❖ Tránh việc "Tin tưởng mù quáng" vào cái nhìn toàn thể: - Bất thường: Trong nhiều trường hợp, mạng nhìn toàn bộ phổi (CNN-128F) báo kết quả là "Bình thường", nhưng mạng nhìn cục bộ (CNN-64L/R) lại phát hiện ra đốm mờ nhỏ. - Bài học: Nếu chỉ dùng một mạng lớn (như cách làm truyền thống), sẽ bị bỏ sót bệnh (False Negative). Luận văn chỉ ra rằng cần tránh việc bỏ qua các "tín hiệu yếu" từ các vùng cục bộ. Đây là lý do FR3 ra đời. ❖ Tránh hiện tượng "Học vẹt" (Overfitting) trên một nguồn dữ liệu: - Bất thường: Khi mang mô hình huấn luyện trên dữ liệu Bệnh viện An Bình sang chạy trên dữ liệu Thẩm Quyền, độ chính xác giảm từ 96% xuống 92%. - Bài học: Các máy chụp X-quang khác nhau có độ tương phản và nhiễu khác nhau. Cần tránh việc tuyên bố độ chính xác tuyệt đối chỉ dựa trên một nguồn dữ liệu duy nhất. Thực nghiệm cần đa dạng hóa nguồn dữ liệu kiểm thử (như tác giả đã làm) để thấy được độ chênh lệch thực tế.	Tốt								

		❖ Tránh mất cân bằng dữ liệu trong tập kiểm tra: - Bất thường: Nếu tập kiểm tra chứa 90 ảnh bình thường và chỉ 10 ảnh bệnh, một mô hình "ngốc" luôn đoán "bình thường" cũng đạt 90% độ chính xác. - Bài học: Tác giả đã chủ động thiết lập tập Train và Test với tỷ lệ 50-50 (50 Normal - 50 Abnormal). Điều này là bắt buộc để các chỉ số Độ nhạy (Sensitivity) và Độ đặc hiệu (Specificity) có ý nghĩa thực tiễn.	
6	Tìm ra trường hợp thuyết phục		Tốt
6.1	Vấn đề cần giải quyết chính xác là gì?	❖ Vấn đề cốt lõi: Tác giả không nói chung chung là "chẩn đoán bệnh phổi". Vấn đề được định nghĩa rất cụ thể tại Trang 14: "<i>Bài toán phát hiện bất thường đậm độ trên hình ảnh X-quang</i>". Tự động phát hiện các vùng "bất thường đậm độ" (abnormal densities/opacity) trên ảnh X-quang ngực thẳng là dấu hiệu sớm và quan trọng nhất để sàng lọc ung thư phổi và các bệnh lý phổi khác. ❖ Vấn đề thực tiễn: - Giải quyết tình trạng quá tải tại các bệnh viện (bác sĩ không đủ thời gian đọc kỹ từng ảnh). - Giải quyết bài toán thiếu hụt phần cứng: Các mô hình AI hiện đại thường đòi hỏi máy chủ GPU đắt tiền, khó triển khai ở bệnh viện tuyến huyện/xã. Tác giả đặt mục tiêu giải quyết vấn đề này bằng mô hình chạy được trên Web/CPU. ❖ Tại sao thuyết phục? - Tính thực tế: "Bất thường đậm độ" (các nốt mờ, đám mờ) là dấu hiệu chỉ điểm đầu tiên của ung thư phổi. - Tính khả thi: Với ảnh X-quang 2D chồng lẫn, việc máy tính phát hiện ra vùng đậm độ khác thường là mục tiêu khả thi hơn là bắt máy tính chẩn đoán chính xác tên bệnh (lao, viêm hay ung thư). ⇒ Cách đặt vấn đề này rất khôn ngoan, tránh được việc hứa hẹn quá đà (over-promise).	Tốt
6.2	Ý tưởng đang xem xét có hiệu quả đáng kể không?	❖ Hiệu quả của Kiến trúc Multi-CNNs: - Về mặt kỹ thuật: Ý tưởng chia ảnh thành 3 phần (Trái/Phải/Toàn cục) kết hợp với Quy tắc xử lý xung đột (FR3) giúp giảm kích thước đầu vào (từ ảnh lớn xuống 128x128 và 64x128) mà vẫn giữ được chi tiết. Điều này giúp mô hình chạy được trên máy tính không có GPU (Trang 72). - Về mặt kết quả: Độ chính xác 96% (An Bình) và 92% (Shenzhen) là những con số biết nói, chứng minh ý tưởng này hoạt động hiệu quả đáng kể so với việc dùng mắt thường (dễ bỏ sót). ⇒ Ý tưởng này giải quyết được điểm yếu chí mạng của các mạng CNN thông thường là hay bỏ sót các chi tiết nhỏ (nốt mờ) khi phải xử lý một bức ảnh quá lớn. Việc "chia để trị" giúp mạng "nhìn" sâu hơn vào từng lá phổi.	Tốt
6.3	Chất lượng của những bài báo nghiên cứu tham chiếu thế nào?	❖ Nguồn tham chiếu (Trang 86-88): - Điểm cộng: Có tham chiếu các bài báo từ hội nghị NIPS (Hội nghị AI hàng đầu thế giới - Ref [3]), các sách kinh điển của MIT Press (Ref [5]). Điều này tạo nền tảng lý thuyết vững chắc. - Điểm trừ: Vẫn còn trích dẫn các nguồn chưa đủ sức nặng học thuật như <i>Wikipedia</i> (Ref [15]), <i>Towards Data Science</i> (Ref [16]), <i>Mathworks</i> (Ref [21]). Đối với một luận văn thạc sĩ, nên hạn chế tối đa các nguồn này. - Bù đắp: Tác giả có bài báo của chính mình đăng tại hội nghị IEEE KSE (Phụ lục 1, Trang 90), điều này kéo lại uy tín cho phần tham chiếu. ❖ Tính cập nhật: Tại thời điểm 2018, các tài liệu tham khảo tập trung vào giai đoạn 2011-2017, phản ánh đúng giai đoạn chuyển giao công nghệ từ Machine Learning cổ điển sang Deep Learning. ❖ Nguồn dữ liệu: Tác giả tham chiếu và sử dụng các bộ dữ liệu chuẩn (Shenzhen, Indiana University), cho thấy sự nghiêm túc trong việc tìm kiếm "Ground Truth" (chân lý) để đối sánh.	Tốt
6.4	Việc so sánh với các nghiên cứu của tác giả với các trường hợp trước đây có tốt hay không có hiệu quả hay không?	❖ So sánh nội tại: Tác giả làm rất tốt việc so sánh giữa các phiên bản của chính mình (128F vs 64L/R, FR1 vs FR2 vs FR3). Tác giả còn so sánh mô hình đề xuất (Multi-CNNs) với mô hình cơ sở (Single CNN) để chứng minh sự cải thiện là do kiến trúc mạng chứ không phải do may mắn. ❖ So sánh phương pháp: Tác giả so sánh các quy tắc kết hợp (Mean vs. Weighted vs. Conflict Rules) để tìm ra phương án tối ưu. ❖ So sánh ngoại tại: Đây là điểm luận văn còn thiếu. Trong chương Thực nghiệm, tác giả chưa chạy thử các model kinh điển (như AlexNet, VGG16, ResNet) trên cùng bộ dữ liệu An Bình để so sánh đối chứng. ⇒ Nếu có bảng so sánh: "<i>Multi-CNNs (96%) vs AlexNet (90%)</i>" thì tính thuyết phục sẽ cao hơn nhiều. Hiện tại người đọc chỉ thấy nó tốt, nhưng chưa biết nó đứng đâu so với thế giới. ❖ Đánh giá tính hiệu quả của chiến lược so sánh: - Điểm trừ: Tác giả sử dụng "Số lượng kết quả tìm kiếm Google Scholar" (Hình 5) làm minh chứng cho sự vượt trội của CNN. Đây là một so sánh mang tính định tính và thiếu sức nặng khoa học. Cần thay thế bằng các bảng so sánh độ chính xác (Accuracy) cụ thể từ các bài báo Review. - Kế hoạch so sánh thực nghiệm chưa rõ ràng. Tác giả chỉ nói thực nghiệm mô hình CNN đề xuất chứ chưa nêu rõ sẽ chạy song song với một mô hình SVM (baseline) để chứng minh sự hiệu quả thực tế.	Khá

6.5	Hệ thống đã lập trình sử dụng có qua kiểm tra hay chưa có phổ biến thành ứng dụng thực tế được không?	❖ Kiểm tra: Hệ thống đã qua kiểm tra kỹ lưỡng trên 2 tập dữ liệu độc lập (An Bình và Shenzhen). Đã đo đạc cả độ chính xác lẫn thời gian phản hồi. ❖ Khả năng phổ biến: - Công nghệ: Sử dụng ConvNetJS chạy trên trình duyệt web. Đây là điểm mạnh nhất về mặt ứng dụng. Bác sĩ ở bất cứ đâu, dùng máy tính văn phòng bình thường cũng có thể mở web lên và chạy chẩn đoán, không cần cài đặt phần mềm phức tạp hay mua máy trạm đắt tiền. - Thời gian: Xử lý 1 ảnh mất 0.3 giây (Trang 77). Hoàn toàn đáp ứng thời gian thực. - Hạn chế: Cần đóng gói lại giao diện (UI/UX) thân thiện hơn cho bác sĩ lâm sàng, vì hiện tại giao diện vẫn mang tính chất thực nghiệm kỹ thuật.	Tốt
II	Đánh giá chất lượng đóng góp bài báo		
1	Xác định tạp chí hội nghị quốc tế có uy tín có ảnh hưởng lớn để đăng bài báo	❖ Minh chứng về bài báo đã công: Thông tin tại Trang 85 và Phụ lục (Trang 90-97): Tác giả không chỉ "dự kiến" đăng bài mà đã đăng thành công bài báo khoa học. - Tên bài: <i>"Applying Multi-CNNs model for detecting abnormal problem on chest x-ray images"</i>. - Tác giả: Phat Nguyen, Hai Tran, Thai Le, Tuan Le, Thuy Nguyen. - Nơi đăng: 2018 10th International Conference on Knowledge and Systems Engineering (KSE). - Nhà xuất bản: IEEE (Institute of Electrical and Electronics Engineers) ❖ Đánh giá uy tín của nơi công bố: Về Hội nghị KSE (Knowledge and Systems Engineering): - Đây là một hội nghị quốc tế uy tín, được tổ chức thường niên và có quy trình phản biện (peer-review) nghiêm túc. - Chỉ số ảnh hưởng: KSE Proceedings được xuất bản bởi IEEE và được lập chỉ mục (index) trong cơ sở dữ liệu IEEE Xplore và Scopus. Điều này đảm bảo bài báo có độ nhận diện cao trong cộng đồng khoa học quốc tế. - Chất lượng: Việc bài báo vượt qua vòng phản biện để được đăng trong kỷ yếu của IEEE KSE chứng tỏ phương pháp và kết quả nghiên cứu đạt chuẩn mực học thuật quốc tế. ❖ Sự phù hợp giữa nội dung luận văn và bài báo: So sánh nội dung: - Bài báo (Trang 90-97) là phiên bản tiếng Anh tóm tắt lại các kết quả cốt lõi của luận văn: Kiến trúc Multi-CNNs, các luật kết hợp, và kết quả thực nghiệm trên bộ dữ liệu An Bình/Shenzhen. - Điều này khẳng định luận văn không phải là một báo cáo nội bộ mà là một công trình nghiên cứu có giá trị đóng góp tri thức mới cho cộng đồng (Novelty). - Tính thực tiễn: Giải pháp không đòi hỏi phần cứng GPU đắt tiền, phù hợp xu hướng "AI for Good" hoặc "AI for Developing Countries". - Dữ liệu: Đóng góp bộ dữ liệu mới (AB-Chest) là một đóng góp khoa học có giá trị cao, vì dữ liệu y tế thường khan hiếm. - Phương pháp: Kiến trúc Multi-CNNs kết hợp quy tắc FR3 là một cải tiến kỹ thuật rõ ràng, có logic và chứng minh được hiệu quả.	Tốt
2	Luôn nghĩ về người đọc	❖ Sử dụng hình ảnh trực quan: Trực quan hóa CNN - Đây là điểm sáng nhất. Thông thường, CNN được coi là "hộp đen", khó hiểu bên trong. Tác giả đã dành công sức lớn để trực quan hóa các lớp trung gian: - Hình 3-3 đến 3-11 (Trang 59-63): Tác giả không chỉ vẽ sơ đồ khối mà hiển thị cả ảnh kết quả sau khi đi qua lớp Convolution, lớp ReLU, lớp Pool. Người đọc nhìn vào là thấy ngay: "À, lớp này lọc cạnh, lớp kia làm mờ, lớp nọ giảm kích thước". Hình 3-3: Mô tả hình ảnh đầu vào được đưa vào và tính toán ở tầng Input của kiến trúc CNN-128F	Tốt




Hình 3-7: Mô tả trực quan tầng conv của layer 2 của kiến trúc mạng CNN-128F




Hình 3-11: Mô tả trực quan tầng ReLU và Pool của layer 3 của kiến trúc mạng CNN-128F

- **Hình 2-10 đến 2-13 (Trang 34-35):** Minh họa phép tính tích chập bằng ma trận số cụ thể, từng bước trượt (stride). Cách giải thích này cực kỳ sư phạm, giúp người không chuyên toán cũng hiểu được cơ chế.



Hình 2-10: Biểu diễn hình ảnh đầu vào và bộ lọc dưới dạng ma trận

Hình 2-11: Tính tích chập của ảnh đầu vào với bộ lọc 3 x 3



Hình 2-12: Thực hiện di chuyển ma trận bộ lọc

Hình 2-13: Kết quả sau khi thực xong phép toán tích chập

⇒ **Nhận xét:** Tác giả rất quan tâm đến trải nghiệm hiểu của người đọc, biến cái trừu tượng thành cái nhìn thấy được.

❖ **Cung cấp kiến thức nền đa ngành:** Phục vụ cả 2 đối tượng độc giả, luận văn giao thoa giữa CNTT và Y khoa.


- **Với dân CNTT:** Tác giả giải thích kỹ về **Ảnh X-quang** (Trang 55-56): Cách ghi hình, độ tương phản, độ rõ nét. Giúp dân kỹ thuật hiểu dữ liệu mình đang xử lý.

- **Với người mới nhập môn AI:** Tác giả đi từ mạng nơ-ron sinh học (Hình 2-1) đến nhân tạo, giải thích cặn kẽ các khái niệm SGD, Learning Rate, Overfitting. Đây là tài liệu nhập môn rất tốt.

⇒ Tác giả không mặc định "người đọc đã biết hết rồi", mà kiên nhẫn giải thích từ gốc.


		❖ Về mặt dữ liệu: - Sự khác biệt của dữ liệu địa phương: Thông qua việc so sánh kết quả giữa tập An Bình (96%) và Shenzhen (92%), người đọc rút ra được rằng: Các mô hình AI trong y tế cần được tinh chỉnh (fine-tune) với dữ liệu địa phương (local data) để đạt hiệu quả cao nhất, vì máy móc và quy trình chụp mỗi nơi mỗi khác. - Quy trình xây dựng dữ liệu y khoa chuẩn: Người đọc học được quy trình làm việc nghiêm túc từ việc xin dữ liệu thô → Ấn danh thông tin bệnh nhân → Cắt vùng quan tâm (ROI) → Nhờ chuyên gia gán nhãn → Chuẩn hóa kích thước. Đây là tài liệu tham khảo tốt cho ai muốn xây dựng bộ dữ liệu "Made in Vietnam". ❖ Bức tranh toàn cảnh về Y tế thông minh: Người đọc thấy được tiềm năng to lớn của việc kết hợp giữa Bác sĩ và Kỹ sư. Luận văn chứng minh rằng với sự hợp tác chặt chẽ (bác sĩ gán nhãn, kỹ sư xây mô hình), chúng ta hoàn toàn có thể tạo ra các sản phẩm công nghệ y tế nội địa có chất lượng cao, cạnh tranh được với các bộ dữ liệu quốc tế.	
3	Tìm hiểu về người phản biện (người hướng dẫn và hội đồng)	❖ Sự phù hợp với Người hướng dẫn (PGS. TS. Lê Hoàng Thái): - Hồ sơ khoa học của GVHD: PGS. TS. Lê Hoàng Thái là chuyên gia hàng đầu về Xử lý ảnh, Nhận dạng mẫu và Ứng dụng Y sinh. Các nghiên cứu của thầy thường tập trung vào việc áp dụng các mô hình học máy (SVM, ANN, CNN) để giải quyết các bài toán thực tế (Vân tay, Khuôn mặt, Ảnh y tế). - Sự phù hợp của Luận văn: ▪ Chủ đề: Tác giả chọn "<i>Phát hiện bất thường trên ảnh X-quang phổi</i>" → Hoàn toàn nằm trong hướng nghiên cứu trọng điểm (Biomedical Application) của GVHD. ▪ Phương pháp: Sử dụng Deep Learning (CNN) → Đây là hướng đi mà GVHD đang quan tâm và khuyến khích tại thời điểm 2018 (chuyển dịch từ các phương pháp cổ điển sang Deep Learning). ▪ Minh chứng: Việc GVHD đứng tên chung trong bài báo quốc tế (Trang 90) cho thấy sự đồng thuận và hài lòng cao đối với hướng đi này. ❖ Chuyên gia tham vấn (Phản biện chuyên môn Y khoa): PGS.BS Nguyễn Hoài Nam và các bác sĩ Bệnh viện An Bình: Đây là nhóm "người phản biện ngầm" cực kỳ quan trọng. Họ không chấm điểm thuật toán, nhưng họ xác nhận tính đúng đắn của dữ liệu. - Nhờ có sự tham gia của các bác sĩ (được nhắc đến trong lời cảm ơn và phần thu thập dữ liệu), luận văn tránh được lỗi sơ đẳng mà dân IT hay mắc phải: Gán nhãn sai bệnh lý. - Họ chính là người đặt ra yêu cầu: "Mô hình không được bỏ sót bệnh" → Dẫn đến việc tác giả phải tối ưu hóa Độ nhạy (Sensitivity/TPR) lên mức 0.96. ❖ Đáp ứng tiêu chuẩn của Hội đồng (Trường ĐH KHTN - ĐHQG TP.HCM): Tiêu chuẩn học thuật Trường ĐH KHTN rất cao, đây là một trong những cơ sở đào tạo CNTT hàng đầu, nổi tiếng với sự khắt khe về tính hàn lâm và toán học. Cách tác giả đáp ứng: - Chương 2 (Cơ sở lý thuyết): Tác giả không viết sơ sài mà đi sâu vào bản chất toán học (Công thức tích chập, Backpropagation, Gradient Descent). Điều này nhằm thỏa mãn các thành viên Hội đồng thiên về lý thuyết/toán học. - Chương 4 (Thực nghiệm): Tác giả thực hiện đánh giá trên bộ dữ liệu chuẩn quốc tế (Shenzhen) bên cạnh dữ liệu nội địa. Điều này nhằm thỏa mãn yêu cầu về tính chuẩn hóa và hội nhập quốc tế của Hội đồng. - Công bố: Có bài báo IEEE KSE (Hội nghị uy tín). Đây là "thẻ bài miễn tử" mạnh nhất trước bất kỳ câu hỏi hóc búa nào về tính mới của đề tài. ❖ Dự đoán và trả lời các câu hỏi phản biện: Tác giả đã khéo léo lồng ghép câu trả lời cho những câu hỏi thường gặp của người phản biện ngay trong nội dung: - Hỏi: "<i>Tại sao không dùng các mạng có sẵn (Pre-trained) như VGG/ResNet cho nhanh?</i>" ⇒ Đáp (ngầm hiểu qua thiết kế): Vì ảnh X-quang có cấu trúc đặc biệt (đối xứng), cần mạng chuyên biệt (Multi-CNNs) để so sánh hai bên phổi, điều mà VGG/ResNet không làm được - Hỏi: "<i>Dữ liệu ít thế này (vài trăm ảnh) có bị Overfitting không?</i>" ⇒ Đáp: Tác giả sử dụng kỹ thuật Data Augmentation (cắt, chia nhỏ ảnh) và kiểm thử chéo trên tập dữ liệu hoàn toàn khác (Shenzhen) để chứng minh mô hình vẫn hoạt động tốt (Generalization). - Hỏi: "<i>Tại sao lại dùng ConvNetJS (Javascript)?</i>" ⇒ Đáp (Trang 72-73): Tác giả giải trình rõ ràng về hạn chế phần cứng (không GPU) và mục tiêu triển khai web. Lý do này rất thực tế và dễ được chấp nhận.	Tốt
4	Kiểm tra việc tuân thủ quy định theo mẫu bài.	Bố cục hành chính: ❖ Trang bìa và Bìa phụ (Trang 1-2): - Đầy đủ thông tin bắt buộc: Đơn vị chủ quản (ĐHQG, ĐH KHTN), Tên đề tài, Tên học viên, Chuyên ngành/Mã số (60480101), Người hướng dẫn, Năm thực hiện. - Khung viền (Border): Sử dụng khung viền kép đúng quy cách trang trọng của luận văn. ❖ Các mục bắt buộc khác: - Lời cam đoan (Trang 3). - Mục lục (Trang 4-5). - Danh mục từ viết tắt (Trang 6). - Danh mục Hình ảnh/Bảng biểu (Trang 7-8). ⇒ Đầy đủ, không thiếu thành phần nào theo quy định.	Tốt

		❖ Cấu trúc nội dung: Tuân thủ mô hình IMRaD mở rộng: - Mở đầu: Lý do, Mục đích, Đối tượng, Phạm vi. - Chương 1: Tổng quan (Literature Review). - Chương 2: Cơ sở lý thuyết (Theory). - Chương 3: Mô hình đề xuất (Methodology). - Chương 4: Thực nghiệm (Experiments & Results). - Chương 5: Kết luận (Conclusion). ⇒ Việc phân chia chương hồi rất logic, cân đối giữa Lý thuyết và Thực nghiệm. ❖ Quy định trình bày Hình/Bảng: Tuân thủ quy tắc định dạng chuẩn: - Hình ảnh: Chú thích (Caption) nằm bên dưới hình (Ví dụ: Hình 1-1: Mô hình bài toán... - Trang 16). - Bảng biểu: Chú thích nằm bên trên bảng (Ví dụ: <i>Bảng 2-1: Các hàm truyền cơ bản</i> - Trang 22). ⇒ Đây là chi tiết nhỏ nhưng rất quan trọng thể hiện sự am hiểu quy chuẩn soạn thảo văn bản khoa học. Tác giả thực hiện chính xác. ❖ Quy định Trích dẫn & Tài liệu tham khảo: - Sử dụng số trong ngoặc vuông [1], [2] tương ứng với danh mục tham khảo. - Danh mục tham khảo (Trang 88) được chia tách rõ ràng: 1. Tiếng Việt và 2. Tiếng Anh. Đây là quy định bắt buộc của nhiều trường ĐH tại Việt Nam. ⇒ Hạn chế nhỏ: Định dạng tài liệu tham khảo chưa hoàn toàn nhất quán. Một số tài liệu là bài báo (Ref [1], [2]), một số chỉ là đường link URL trần (Ref [15], [17], [21]). Trong các luận văn chuẩn mực, nên hạn chế tối đa việc dẫn link web trực tiếp mà nên dẫn tên tác giả/tổ chức sở hữu trang web đó.	
5	Đánh giá kỹ năng ngôn ngữ viết.	❖ Văn phong khoa học: - Sự trang trọng và khách quan: Tác giả sử dụng ngôi xưng hô phù hợp: "<i>Học viên</i>", "<i>Luận văn này</i>", "<i>Chúng tôi</i>". Không dùng ngôi thứ nhất "Tôi" (trừ phần Lời cam đoan). Cách diễn đạt mang tính khẳng định và dựa trên dữ liệu (Data-driven). Ví dụ: "<i>Kết quả đạt được là 96%...</i>", "<i>Biểu đồ cho thấy...</i>". - Sử dụng thuật ngữ chuyên ngành: Sử dụng chính xác và nhất quán các thuật ngữ tiếng Anh chuyên ngành (Deep Learning, Convolution, Pooling, Over-fitting, Softmax). Đây là điều cần thiết trong ngành CNTT vì dịch sang tiếng Việt đôi khi làm mất nghĩa. ❖ Cấu trúc câu và Tính mạch lạc: - Khả năng diễn giải vấn đề phức tạp: Tác giả có kỹ năng viết rất tốt khi giải thích các khái niệm toán học trừu tượng. Ví dụ đoạn giải thích về Tích chập (Convolution) ở trang 33-34: Dẫn dắt từ định nghĩa toán học → Ứng dụng trong xử lý ảnh → Ví dụ minh họa ma trận. Cách viết này rất sư phạm, dễ hiểu. - Các đoạn văn có sự liên kết (transition) tốt, không bị rời rạc. ❖ Lỗi chính tả và trình bày: Mặc dù văn phong tốt, nhưng khâu rà soát lỗi chính tả (Proofreading) của tác giả chưa kỹ, để sót nhiều lỗi sơ đẳng ngay ở các tiêu đề lớn: - Trang 2 (Bìa phụ): "<i>NGƯỜI HƯỚNG DẪN</i>" (Thiếu chữ I). - Trang 4 & 12: "<i>Mục đích nghiên cứu</i>" (Thiếu dấu sắc). - Trang 51: "<i>Tập dữ liệu</i>" (Dữ liệu). - Trang 70: "<i>huấn luyện (training)</i>" (Training). - Trang 72: "<i>Thư viện ConvNetJS</i>" (Thư viện). - Trang 80: "<i>Confusion matrix chưa chuẩn hoas</i>" (Lỗi gõ Telex).	Khá
6	Hai thành phần chính trong bài báo		Tốt
6.1	Định nghĩa rõ ràng đóng góp của vấn đề nghiên cứu.	<i>Tác giả định nghĩa đóng góp rất tường minh tại Mục 6 (Trang 11) và Chương 3 (Trang 57):</i> ❖ Đóng góp về Kiến trúc: - Thay vì sử dụng một mạng CNN đơn lẻ (Single Stream) thường làm mất chi tiết nhỏ khi co nhỏ ảnh, tác giả đề xuất kiến trúc Multi-CNNs (Đa luồng). - Cụ thể: Chia bài toán thành 3 mạng con chuyên biệt xử lý 3 vùng nhìn: Toàn thể, Phổi trái và Phổi phải. - Điểm nhấn sáng tạo là Quy tắc kết hợp FR3 (Fusion Rule 3): Một thuật toán hậu xử lý thông minh giúp giải quyết các xung đột khi các mạng con "cãi nhau" (ví dụ: mạng toàn thể bảo bình thường nhưng mạng cục bộ phát hiện đốm mờ), từ đó giảm thiểu đáng kể tỷ lệ bỏ sót bệnh (False Negative). ❖ Đóng góp về Thuật toán: Đề xuất Quy tắc kết hợp (Fusion Rules): Tác giả không chỉ cộng gộp kết quả mà thiết kế ra các luật (FR1, FR2, FR3) để xử lý các trường hợp xung đột (ví dụ: mạng Trái bảo bệnh, mạng Toàn cục bảo không). ❖ Đóng góp về dữ liệu: - Xây dựng thành công bộ dữ liệu AB-Chest X-rays từ việc thu thập và gán nhãn bộ dữ liệu X-quang phổi từ Bệnh viện An Bình (450 ảnh). Đây là đóng góp thiết thực cho cộng đồng nghiên cứu trong nước. - Giá trị nằm ở chỗ: Dữ liệu này đã được chuẩn hóa và gán nhãn bởi chuyên gia y tế (PGS.BS Nguyễn Hoài Nam và các cộng sự), biến nó thành một tài sản khoa học (Ground Truth) tin cậy cho các nghiên cứu trong nước, giải quyết bài toán thiếu dữ liệu y tế bản địa.	Tốt

		❖ Đóng góp về Tính thực tiễn: - Chứng minh khả năng triển khai Deep Learning trên nền tảng Web (Client-side) sử dụng thư viện ConvNetJS. - Giải quyết bài toán triển khai tại các cơ sở y tế tuyến dưới không có kinh phí đầu tư máy chủ GPU đắt tiền. ⇒ Nhận xét: Đóng góp được định nghĩa rõ ràng, không chung chung.	
6.2	Mình chứng hỗ trợ nghiên cứu đầy đủ.	Hệ thống mình chứng được xây dựng kiên cố qua 3 lớp: ❖ Lớp 1: Minh chứng bằng Thực nghiệm. - Để chứng minh <i>Multi-CNNs</i> tốt hơn <i>CNN đơn lẻ</i>: Tác giả so sánh độ chính xác (96% vs 92%) tại Bảng 4-4 và 4-5. - Để chứng minh <i>Luật FR3</i> tốt hơn <i>FR1/FR2</i>: Tác giả đưa ra kết quả trên tập dữ liệu Shenzhen (92% vs 72%) tại Bảng 4-7. Đây là bằng chứng đáng thép nhất cho tính hiệu quả của thuật toán đề xuất. ❖ Lớp 2: Minh chứng bằng Chỉ số Y tế. Tác giả không chỉ dùng Accuracy mà dùng các chỉ số y khoa: Độ nhạy (TPR = 0.96) và Độ đặc hiệu (TNR = 0.96) (Trang 79). Điều này chứng minh mô hình không chỉ "đoán mò" mà thực sự có khả năng sàng lọc bệnh. ❖ Lớp 3: Minh chứng bằng Công nhận Quốc tế. Bài báo đăng tại hội nghị IEEE KSE 2018 (Phụ lục 1, Trang 90) là minh chứng khách quan nhất. Nó cho thấy đóng góp của tác giả đã được cộng đồng khoa học quốc tế thẩm định và công nhận là đúng đắn.	Tốt
7	Bài báo là chưa đủ thiết kế hệ thống khác mà không có đánh giá thuyết phục (Đánh giá sự chặt chẽ giữa thiết kế và kiểm chứng)	❖ Thiết kế hệ thống có rõ ràng và giải quyết được vấn đề không? - Vấn đề: Ảnh X-quang phổi có kích thước lớn, chi tiết nhỏ (nốt mờ) dễ bị mất khi qua mạng CNN thông thường. Tài nguyên phần cứng hạn chế (không GPU). - Thiết kế (Trang 57-58): ▪ Tác giả thiết kế hệ thống Multi-CNNs với chiến lược chia nhỏ ảnh (Cắt trái, Cắt phải, Resize toàn cục). ▪ Logic thiết kế: Việc chia nhỏ ảnh giúp giữ được độ phân giải cục bộ (Local resolution) cho mạng CNN con học, giải quyết vấn đề mất chi tiết. Mạng con nhỏ gọn cũng giúp chạy được trên máy không GPU. ⇒ Thiết kế này không ngẫu nhiên mà giải quyết trực diện các thách thức đã đặt ra. Sơ đồ hệ thống (Hình 3-1) rất mạch lạc.  Hình 3-1: Mô tả mô hình học sâu Multi-CNNs ❖ Phương pháp đánh giá có khớp với thiết kế không? - Sự khớp lệnh (Alignment): ▪ Thiết kế: Multi-stream (3 dòng chảy dữ liệu). ⇒ Kiểm chứng: Tác giả đánh giá riêng lẻ từng dòng chảy (128F, 64L, 64R) trước khi đánh giá tổng thể. Điều này giúp xác định đóng góp của từng thành phần trong thiết kế. ▪ Thiết kế: Fusion Rules (Luật kết hợp) để xử lý xung đột. ⇒ Kiểm chứng: Tác giả so sánh trực tiếp các luật (FR1 vs FR2 vs FR3) trên tập dữ liệu khó (Shenzhen) để chứng minh sự cần thiết của thiết kế này. ▪ Thiết kế: Ứng dụng hỗ trợ chẩn đoán (Support System). ⇒ Kiểm chứng: Đo lường các chỉ số y tế (TPR, TNR) thay vì chỉ đo Accuracy. ❖ So sánh với hệ thống khác - Điểm hạn chế nhỏ: ▪ Tác giả so sánh rất tốt giữa các phiên bản nội bộ (Multi-CNNs vs Single CNN). ▪ Tuy nhiên, thiếu sự so sánh trực tiếp (side-by-side) với các kiến trúc chuẩn khác (như VGG16, ResNet50, DenseNet) trên cùng tập dữ liệu An Bình. ▪ Nếu có thêm bảng so sánh này, sự ưu việt của thiết kế Multi-CNNs sẽ được khẳng định tuyệt đối hơn.	Tốt
8	Đánh giá chất lượng đóng góp nghiên cứu		Tốt
8.1	Mình chứng cho việc nâng cao kiến thức trong nghiên cứu	Luận văn không chỉ dừng lại ở việc ứng dụng (application) mà còn đóng góp vào việc nâng cao tri thức (advancing knowledge) cho cộng đồng nghiên cứu AI trong y tế thông qua các minh chứng cụ thể: ❖ Chuyển dịch tư duy kiến trúc: - Trước đó: Đa số các nghiên cứu (như Reference [13] trong bài) thường áp dụng các mạng CNN tiêu chuẩn (như AlexNet, VGG) lên toàn bộ bức ảnh gốc đã được co nhỏ (resize). Điều này làm mất mát thông tin chi tiết của các đốm mờ nhỏ. - Đóng góp mới: Luận văn chứng minh rằng kiến trúc "Chia để trị" (Multi-CNNs) — tách riêng phổi trái và phải để xử lý ở độ phân giải tốt hơn — mang lại hiệu quả vượt trội. Đây là minh chứng cho thấy cấu trúc giải phẫu học (Anatomical Structure) cần được tích hợp vào thiết kế mạng nơ-ron thay vì coi ảnh y tế như ảnh thông thường.	Tốt

		- Tri thức về Xử lý xung đột: ▪ Luận văn cung cấp minh chứng thực nghiệm rằng: Trong y tế, các phương pháp kết hợp truyền thống như "Lấy trung bình cộng" (Average Voting) là chưa đủ. ▪ Tác giả đóng góp tri thức mới thông qua Quy tắc FR3: Khi có xung đột (một mạng bảo bệnh, một mạng bảo không), cần phải ưu tiên tín hiệu "bệnh" từ mạng cục bộ. Đây là một đóng góp quan trọng về mặt chiến lược thuật toán cho các hệ thống hỗ trợ chẩn đoán (CAD). - Tri thức về Đặc điểm dữ liệu nội địa: Việc công bố các chỉ số trên bộ dữ liệu AB-Chest X-rays (Bệnh viện An Bình) cung cấp một tham chiếu (Benchmark) cho các nhà nghiên cứu sau này biết được độ khó và đặc thù của dữ liệu X-quang tại Việt Nam so với dữ liệu quốc tế.	
8.2	Giải thích ý tưởng nghiên cứu dễ dàng được truy xuất sử dụng bởi mọi người	❖ Điểm mạnh nhất của luận văn này là tính truy xuất và tính khả dụng cực cao. - Dễ dàng truy xuất: Tác giả sử dụng ConvNetJS, một thư viện Deep Learning chạy hoàn toàn bằng JavaScript. Điều này có nghĩa là bất kỳ ai có trình duyệt web (Chrome, Firefox) đều có thể truy xuất và chạy mô hình mà không cần cài đặt môi trường phức tạp (như Python, CUDA, Docker) hay sở hữu phần cứng chuyên dụng. - Dễ dàng sử dụng: Ý tưởng được gói gọn trong một giao diện web đơn giản: "Upload ảnh → Chờ 300ms → Xem kết quả".	Tốt
8.2.1	Kỹ thuật nghiên cứu là đầu tiên	❖ Mặc dù CNN không mới, nhưng cách tiếp cận của tác giả mang tính tiên phong trong bối cảnh cụ thể (Contextual Novelty) tại thời điểm 2018: - Tiên phong về triển khai Client-side trong Y tế tại Việt Nam: Đây là một trong những nghiên cứu đầu tiên tại Việt Nam dám đưa mô hình chẩn đoán ảnh X-quang phổi chạy trực tiếp trên trình duyệt (Client-side) thay vì mô hình Client-Server truyền thống. - Tiên phong trong việc "Bình dân hóa" AI: Kỹ thuật này chứng minh rằng AI chẩn đoán ung thư không nhất thiết phải nằm trong các siêu máy tính của các bệnh viện lớn, mà có thể "chạy" ngay trên laptop của một bác sĩ ở trạm y tế xã.	Tốt
8.2.2	Kỹ thuật nghiên cứu thực hiện tốt hơn gần liền với một hay nhiều khía cạnh	Kỹ thuật Multi-CNNs kết hợp FR3 của tác giả đã được chứng minh là thực hiện tốt hơn các phương pháp khác ở 3 khía cạnh then chốt: ❖ Tốt hơn về Độ nhạy: - So với mạng đơn lẻ (Single CNN), kỹ thuật này nâng độ nhạy lên 0.96. - <i>Ý nghĩa:</i> Giảm thiểu tối đa tỷ lệ bỏ sót bệnh (False Negative), khía cạnh quan trọng nhất trong sàng lọc ung thư. ❖ Tốt hơn về Chi phí/Hiệu năng): - So với các mạng SOTA (State-of-the-art) thời đó như ResNet-50 (rất nặng), mô hình của tác giả nhẹ hơn nhiều nhưng vẫn đạt độ chính xác 96%. - Nó "tốt hơn" vì nó chạy được trên CPU rẻ tiền, trong khi các mạng lớn bắt buộc phải có GPU đắt tiền. ❖ Tốt hơn về Khả năng xử lý ca khó: - Nhờ quy tắc FR3, kỹ thuật này xử lý tốt hơn các trường hợp "Bất thường nhỏ/mờ" (Subtle Opacities) mà mạng toàn thể thường bỏ qua. Đây là sự cải thiện trực tiếp về chất lượng chẩn đoán lâm sàng.	Tốt
9	Tránh nghiên cứu nhiều hướng chỉ nên nghiên cứu sâu theo một hướng	❖ Xác định một bài toán cốt lõi duy nhất: Tác giả có sự lựa chọn dứt khoát (Trang 14). - Loại ảnh: Tác giả chỉ chọn X-quang ngực. Mặc dù có nhắc đến CT, MRI nhưng tác giả loại bỏ ngay để tập trung vào X-quang vì tính phổ biến và thách thức kỹ thuật của nó. - Nhiệm vụ: Tác giả xác định bài toán là "Phát hiện bất thường đậm độ" (Binary Classification: Normal vs Abnormal). Tác giả không tham lam làm bài toán "Chẩn đoán đa bệnh" (Multi-class: Lao, Ung thư, Viêm phổi...). ⇒ Việc giới hạn bài toán về nhị phân (Có bệnh/Không bệnh) giúp tác giả dồn toàn lực để tối ưu độ chính xác cho nhiệm vụ sàng lọc (screening) quan trọng nhất. ❖ Tránh nghiên cứu nhiều hướng (Focus): Tác giả đã rất tinh tế trong việc xác định phạm vi (Scope) để không bị "loãng" đề tài. - Về đối tượng bệnh lý: ▪ Tác giả KHÔNG tham vọng xây dựng một hệ thống chẩn đoán "bách bệnh" (vừa lao, vừa viêm phổi, vừa tràn dịch, vừa gãy xương...). ▪ Chỉ tập trung: Vào duy nhất dấu hiệu "Bất thường đậm độ" (Opacity Abnormality). Tác giả hiểu rằng đây là dấu hiệu cơ bản và quan trọng nhất để sàng lọc ung thư phổi. Việc thu hẹp phạm vi này giúp mô hình học được các đặc trưng tốt hơn. - Về phương pháp công nghệ: ▪ Tác giả KHÔNG so sánh tràn lan hàng chục thuật toán (SVM, Random Forest, Bayesian...) một cách hời hợt. ▪ Chỉ tập trung: Vào Convolutional Neural Network (CNN). Tác giả đặt cược toàn bộ vào Deep Learning và tập trung tối ưu hóa nó. - Về nền tảng triển khai: ▪ Tác giả KHÔNG cố làm cả Mobile App, Desktop App và Cloud Server. ▪ Chỉ tập trung: Vào nền tảng Web (ConvNetJS) chạy Client-side. Hướng đi này nhất quán từ đầu đến cuối để giải quyết bài toán "tài nguyên thấp". ❖ Nghiên cứu sâu theo một hướng: Thay vì mở rộng chiều ngang, tác giả đã phát triển theo chiều sâu của giải pháp Multi-CNNs. - Chiều sâu về Kiến trúc: ▪ Không dừng lại ở việc dùng thư viện có sẵn (Import library → Train → Test). ▪ Tác giả đã mổ xẻ cấu trúc ảnh phổi: Nhận thấy ảnh phổi có tính đối xứng và chi tiết nhỏ, tác giả thiết kế kiến trúc 3 luồng (Toàn thể - Trái - Phải). Đây là sự đào sâu về mặt kỹ thuật xử lý ảnh y tế.	Tốt

		- Chiều sâu về Thuật toán: - Tác giả dành nhiều công sức để nghiên cứu Cơ chế kết hợp (Fusion Mechanisms). - Việc đề xuất và so sánh 3 quy tắc (FR1, FR2, FR3) và phân tích kỹ lưỡng tại sao FR3 (xử lý xung đột) lại tốt hơn cho thấy tác giả đã đi rất sâu vào bản chất của việc ra quyết định trong AI. - Chiều sâu về Dữ liệu: - Tác giả tự xây dựng bộ dữ liệu riêng (AB-Chest), tự chuẩn hóa và làm việc với bác sĩ để gán nhãn. Đây là công việc tốn nhiều công sức hơn gấp nhiều lần so với việc chỉ tải một bộ dữ liệu có sẵn trên mạng về chạy.	
III	Đánh giá cấu trúc 1 bài báo		
1	Tựa đề cô đọng chỉ rõ đóng góp nghiên cứu và chưa được công bố	❖ Tựa đề (Trang 1): <i>"MÔ HÌNH HỌC SÂU PHÁT HIỆN BẤT THƯỜNG ĐẬM ĐỘ TRÊN ẢNH Y KHOA HỖ TRỢ TRONG CHẨN ĐOÁN UNG THƯ"</i> ❖ Phân tích tính cô đọng & Đóng góp: - Phương pháp: <i>"Mô hình học sâu"</i> (Deep Learning). - Bài toán kỹ thuật: <i>"Phát hiện bất thường đậm độ"</i> (Detection of density abnormality). Đây là cụm từ rất chính xác về mặt y học (thay vì nói chung chung là "phát hiện bệnh"). - Đối tượng: <i>"Trên ảnh y khoa"</i> (Cụ thể trong bài là X-quang). - Mục đích ứng dụng: <i>"Hỗ trợ trong chẩn đoán ung thư"</i>. ⇒ Tựa đề hơi dài (20 chữ) nhưng đầy đủ các thành phần cần thiết. Nó định vị chính xác phạm vi nghiên cứu là Hỗ trợ (Assist) chứ không thay thế bác sĩ. ❖ Tính "Chưa được công bố": Tại thời điểm 2018, việc kết hợp "Học sâu" với "Bất thường đậm độ" trên dữ liệu Việt Nam là một hướng đi mới mẻ, chưa bị trùng lặp với các công bố trước đó trong nước.	Tốt
2	Phần tóm tắt: tổng quan vấn đề nghiên cứu, yêu cầu (xác nhận) và minh chứng	Tác giả <i>Lưu ý: Trong ảnh chụp không có trang "Tóm tắt" (Abstract) riêng biệt, nên tôi đánh giá dựa trên phần "Mở đầu" (Trang 9-12), nơi đóng vai trò tương đương</i> ❖ Tổng quan vấn đề (Trang 9): Tác giả dẫn dắt từ xu hướng <i>"khối lượng dữ liệu hình ảnh ngày càng lớn"</i> đến nhu cầu <i>"tự động phát hiện đối tượng"</i>. Đặc biệt nhấn mạnh vai trò của X-quang trong sàng lọc ung thư phổi. ❖ Yêu cầu/Vấn đề cần giải quyết (Trang 10): - Xác nhận vấn đề: Bác sĩ quá tải, cần công cụ hỗ trợ độ tin cậy cao. - Yêu cầu kỹ thuật: Xây dựng mô hình CNN có độ chính xác cao để giải quyết bài toán phân loại ảnh y tế. ❖ Minh chứng (Trang 11-12): Tác giả tóm tắt ngay các minh chứng sẽ thực hiện: Dữ liệu: <i>"Thu thập từ bệnh viện ở TP. Hồ Chí Minh"</i> và <i>"Bộ dữ liệu chuẩn đã được công bố"</i>. Giải pháp: Đề xuất mô hình <i>"Multi-CNNs"</i> và <i>"Quy tắc kết hợp (Fusion rules)"</i>. ⇒ Phần Mở đầu này đóng vai trò như một bản tóm tắt hoàn chỉnh, giúp người đọc hình dung toàn bộ bức tranh nghiên cứu.	Tốt
3	Phần giới thiệu: giới thiệu lĩnh vực nghiên cứu, mục tiêu động cơ nghiên cứu	❖ Lĩnh vực nghiên cứu: Luận văn giới thiệu rõ ràng lĩnh vực nghiên cứu là sự giao thoa giữa Thị giác máy tính (Computer Vision) và Y học (Chẩn đoán hình ảnh). Cụ thể là ứng dụng kỹ thuật Học sâu (Deep Learning) để xử lý ảnh X-quang ngực thẳng. ❖ Động cơ nghiên cứu: Tác giả xây dựng động cơ từ thực trạng bức thiết: - Ung thư phổi là nguyên nhân gây tử vong hàng đầu. - X-quang là phương pháp sàng lọc phổ biến nhất nhưng khó đọc, phụ thuộc nhiều vào trình độ bác sĩ. - Tình trạng quá tải tại các bệnh viện Việt Nam khiến bác sĩ dễ bỏ sót các tổn thương nhỏ. ❖ Mục tiêu: Xây dựng một hệ thống tự động có khả năng phát hiện các vùng "bất thường đậm độ" (dấu hiệu sớm của bệnh lý phổi) với độ chính xác cao và có thể chạy trên máy tính cấu hình thấp.	Tốt
3.1	Bài báo tham khảo chính hỗ trợ động cơ nghiên cứu	❖ Sự kết hợp giữa Y học và Kỹ thuật: Tác giả xây dựng động cơ nghiên cứu dựa trên 2 trụ cột tham khảo chính: - Động cơ Y tế (Trang 14): Dựa vào tài liệu [13] (<i>Tataru et al., 2017</i>) và [8] (<i>Gruetzemacher, 2016</i>) để khẳng định: "Suy tim và phổi chiếm hơn 500.000 ca tử vong... X-quang thường được dùng để sàng lọc". - Động cơ Kỹ thuật (Trang 15): Tham khảo các nghiên cứu về CNN (như LeCun [5], Krizhevsky - AlexNet) để thấy sự vượt trội của CNN so với các phương pháp cũ (KNN, SVM) trong nhận dạng ảnh. - Các báo cáo y tế (WHO/Bộ Y tế): Để chứng minh mức độ nguy hiểm và tỷ lệ tử vong của ung thư phổi (để thấy tính cấp thiết). - Các nghiên cứu về hạn chế của phương pháp cũ: Tác giả tham khảo các nghiên cứu sử dụng K-NN, SVM hoặc Neural Network truyền thống (như tài liệu tham khảo [12], [13] trong danh mục) để chỉ ra rằng độ chính xác của chúng đã bão hòa và việc trích xuất đặc trưng thủ công (hand-crafted features) là tốn kém, không hiệu quả. - Các nghiên cứu về CNN: Tham khảo sự thành công của CNN trong bài toán nhận dạng ảnh (ImageNet) để đặt niềm tin rằng Deep Learning là hướng đi đúng đắn cho ảnh y khoa. ⇒ Việc chọn các bài báo năm 2016-2017 (sát thời điểm làm luận văn 2018) làm động lực chính cho thấy tính thời sự cao.	Khá
3.2	Công việc đang tồn tại là gì? Có khác so với những đóng góp từ sáng tạo riêng như thế nào?	❖ Công việc đang tồn tại: - Thủ công: Bác sĩ chẩn đoán bằng mắt thường → Quá tải, dễ sai sót (Trang 10). - Máy học cổ điển: Sử dụng SVM, KNN (như luận văn của Nguyễn Thị Thu [2] - Trang 16). <i>Hạn chế:</i> Cần trích xuất đặc trưng thủ công, độ chính xác chưa cao với ảnh phức tạp. - Deep Learning khác: Các nghiên cứu nước ngoài tập trung nhiều vào <i>Ung thư vú</i> (Trang 16-17) hoặc dùng mạng CNN đơn lẻ.	Tốt

		❖ Sự khác biệt và Sáng tạo riêng: - Đối tượng: Tập trung chuyên biệt vào X-quang Phổi (Khác với các nghiên cứu về Vú hay Biển số xe). - Kiến trúc: Thay vì dùng 1 mạng, tác giả sáng tạo ra kiến trúc Multi-CNNs (3 luồng). Việc tách riêng phổi trái/phải giúp mạng "soi" kỹ hơn vào chi tiết cục bộ, giải quyết nhược điểm mất thông tin khi co nhỏ ảnh của các phương pháp tồn tại. - Xử lý xung đột: Tác giả đề xuất Quy tắc kết hợp FR3 (xử lý vùng xung đột). Các công việc cũ thường chỉ cộng trung bình (Average Voting), còn tác giả xây dựng cơ chế "ưu tiên cảnh báo" (nếu mạng con thấy bệnh thì phải báo động ngay), giúp tăng độ nhạy. - Khác biệt về Triển khai: Tác giả đi ngược dòng xu hướng "phần cứng khủng" bằng cách tối ưu hóa mô hình để chạy trên Web (ConvNetJS), tạo ra sự khác biệt lớn về tính khả dụng cho y tế cơ sở	
3.3	Nhắc lại thông tin tóm tắt hiệu quả và dàn ý bài báo	❖ Nhắc lại hiệu quả (Trang 11): Phần giới thiệu Tóm tắt hiệu quả (Trang 11-12). Phần "6. Đóng góp của đề tài" tóm tắt rất gãy gọn 3 điểm chính: Cấu trúc Multi-CNNs, Quy tắc kết hợp (Fusion rules), và Bộ dữ liệu tự thu thập. Phần cuối chương giới thiệu thường tóm tắt nhanh kết quả để khẳng định hướng đi đúng đắn: Hệ thống đề xuất đạt độ chính xác 96% trên dữ liệu thực tế và thời gian xử lý chỉ ~300ms. Điều này đóng vai trò như một lời cam kết về chất lượng của giải pháp sẽ được trình bày chi tiết sau đó. ❖ Dàn ý (Outline - Trang 12): Tác giả trình bày cấu trúc 5 chương rất mạch lạc: - Chương 1: Tổng quan. - Chương 2: Cơ sở lý thuyết. - Chương 3: Mô hình Multi-CNNs (Trọng tâm). - Chương 4: Thực nghiệm. - Chương 5: Kết luận. ⇒ Dàn ý này giúp người đọc định vị được nội dung ngay từ đầu.	Tốt
4	Phát biểu bài toán thiết kế thuật toán: giải thích chi tiết ý tưởng	❖ Phát biểu bài toán: Tác giả đã chuyển đổi bài toán chẩn đoán y khoa sang bài toán tin học một cách tường minh. Không còn sự mơ hồ của ngôn ngữ y khoa, bài toán trở nên tường minh để máy tính xử lý. - Mô hình toán học: Đây là bài toán Phân lớp nhị phân (Binary Classification). - Đầu vào (Input): Một ảnh X-quang ngực thẳng I (đã qua tiền xử lý, ảnh xám). - Đầu ra (Output): Nhãn $y = \{0, 1\}$, trong đó: - "0": Bình thường (Normal). - "1": Bất thường đậm độ (Abnormal/Opacity). - Hàm mục tiêu: Tìm hàm ánh xạ $f(I) \rightarrow y$ sao cho tối thiểu hóa sai số dự đoán, đồng thời cực đại hóa độ nhạy (Sensitivity) để không bỏ sót bệnh <pre>graph LR; A[Ảnh X-quang] --> B[Tiền xử lý]; B --> C[Trích chọn và biểu diễn đặc trưng]; C --> D[Bộ phân loại hoặc bộ nhận diện]; D --> E["Kết quả: Bất thường hoặc Không bất thường"]</pre> Hình 1-2: Mô hình tổng quát bài toán phát hiện bất thường hình ảnh y khoa ❖ Ý tưởng thiết kế cốt lõi: Chiến lược "Chia để trị" (Trang 57) là ý tưởng thiết kế sáng tạo nhất. Thay vì ném cả bức ảnh to vào mạng (dễ mất chi tiết) hoặc resize nhỏ lại (mất thông tin), tác giả thiết kế mô hình Multi-CNNs: - Mạng cục bộ: Tách riêng phổi Trái và Phổi Phải. Lý do: Để máy học tập trung vào đặc trưng chi tiết của nhu mô phổi mà không bị nhiễu bởi phần cột sống hay khoảng không bên ngoài. - Mạng toàn cục: Giữ nguyên ảnh toàn cảnh để máy học tương quan vị trí. ⇒ Ý tưởng này mô phỏng chính xác tư duy đọc phim của bác sĩ (so sánh đối xứng 2 bên phổi). ❖ Chi tiết hóa thuật toán: Thiết kế mạng nơ-ron tường minh (Trang 58, 64). Tác giả không dùng các hộp đen có sẵn. Tác giả vẽ chi tiết kiến trúc từng lớp: - CNN-128F: 6 lớp, Filter 5x5, Max pooling 2x2. - CNN-64L/R: Kiến trúc tương tự nhưng input khác (64x128).	Tốt

		Input Image (64x128x3) ↓ Convolution Layer 1: With filter size: 5x5, filters: 8, stride: 1, pad: 2 ↓ Pooling Layer 1: With max pooling size: 2x2, stride: 2 ↓ Convolution Layer 2: With filter size: 5x5, filters: 8, stride: 1, pad: 2 ↓ Pooling Layer 2: With max pooling size: 2x2, stride: 2 ↓ Convolution Layer 3: With filter size: 5x5, filters: 16, stride: 1, pad: 2 ↓ Pooling Layer 3: With max pooling size: 2x2, stride: 2 ↓ Convolution Layer 4: With filter size: 5x5, filters: 16, stride: 1, pad: 2 ↓ Pooling Layer 4: With max pooling size: 2x2, stride: 2 ↓ Fully connected layer (1x1x2) ↓ Classifier Layers: softmax (1x1x2) ↓ Normal 0 1 Abnormal Hình 3-14: Kiến trúc mạng của thành phần CNN-64L và CNN-64R của mô hình Multi-CNNs - Tham số: Số lượng filter tăng dần (8 → 16). ⇒ Mức độ chi tiết này cho phép người đọc có thể lập trình lại (re-implement) y hệt mô hình của tác giả. ❖ Giải thích cơ chế hoạt động: Trực quan hóa luồng dữ liệu (Trang 60-63). Tác giả giải thích ý tưởng thuật toán không chỉ bằng lời mà bằng hình ảnh các Feature Maps (Bản đồ đặc trưng) sau mỗi lớp Conv/ReLU/Pool. Người đọc thấy rõ thuật toán đang làm gì: <i>Lọc cạnh xương sườn, làm nổi bật vùng phổi, giảm chiều dữ liệu...</i> ❖ Thuật toán Kết hợp: Xử lý xung đột thông tin (Trang 67-69). Tác giả thiết kế thuật toán Fusion Rules (FR3) rất logic: - Input: 3 xác suất từ 3 mạng con (Pleft,Pright,PfullPleft,Pright,Pfull). - Logic: Nếu mạng Full báo "Có bệnh" nhưng mạng Left/Right báo "Không", thì phải tính lại trọng số dựa trên độ tin cậy của vùng bị nghi ngờ. ⇒ Đây là một thiết kế thuật toán tinh tế, giải quyết được điểm yếu của các mạng CNN đơn lẻ.	
5	Kết quả: minh chứng hỗ trợ đóng góp nghiên cứu	❖ Minh chứng cho hiệu quả của Kiến trúc Multi-CNNs: - Đóng góp: Đề xuất mô hình kết hợp 3 mạng con thay vì 1 mạng đơn lẻ. - Minh chứng (Trang 75): Bảng 4-4: Độ chính xác của các mạng đơn lẻ lần lượt là 92% (128F), 86% (64L), 78% (64R). Bảng 4-5: Khi kết hợp lại (Multi-CNNs), độ chính xác tăng lên 96%. ⇒ Số liệu 96% > 92% là bằng chứng định lượng rõ ràng nhất khẳng định kiến trúc đề xuất ưu việt hơn các thành phần cấu tạo nên nó. ❖ Minh chứng cho tính ưu việt của Luật kết hợp FR3: - Đóng góp: Đề xuất quy tắc kết hợp dựa trên vùng xung đột (FR3) để xử lý dữ liệu tốt hơn trung bình cộng (FR1, FR2). - Minh chứng (Trang 76): Trên dữ liệu quen (An Bình): FR3 (96%) chỉ nhỉnh hơn FR1 (94%) một chút. Trên dữ liệu lạ (Shenzhen - Bảng 4-7): FR1 tụt xuống 72%, trong khi FR3 vẫn giữ vững 92%. ⇒ Đây là minh chứng mạnh mẽ nhất của luận văn. Nó chứng minh thuật toán đề xuất (FR3) có khả năng chống nhiễu và tổng quát hóa cực tốt khi gặp dữ liệu mới. ❖ Minh chứng cho khả năng Ứng dụng Y tế (Sàng lọc): - Đóng góp: Hỗ trợ chẩn đoán (giúp bác sĩ không bỏ sót bệnh). - Minh chứng (Trang 79, 81): Tác giả tính toán chỉ số TPR (Độ nhạy) đạt 0.96 và FNR (Tỷ lệ bỏ sót) chỉ 0.04. ⇒ Trong y tế, độ nhạy cao là yếu tố tiên quyết để một hệ thống được chấp nhận làm công cụ sàng lọc. Con số 0.96 là minh chứng thuyết phục cho giá trị sử dụng thực tế. ❖ Minh chứng cho tính Khả thi về Triển khai: - Đóng góp: Chạy trên nền tảng Web/PC không GPU. - Minh chứng (Trang 77): Bảng 4-8: Thời gian xử lý trung bình cho một ca bệnh (1 ảnh) là 305.87 ms (khoảng 1/3 giây). ⇒ Tác giả chứng minh rằng mô hình dù phức tạp (kết hợp 3 mạng) nhưng vẫn chạy "nhanh như điện" trên trình duyệt, đảm bảo trải nghiệm người dùng mượt mà.	Tốt

6	Kết luận: tóm tắt đóng góp nghiên cứu thảo luận hiệu quả và chỉ ra hướng phát triển trong tương lai	❖ Tóm tắt đóng góp nghiên cứu: - Đóng góp về lý thuyết: Nghiên cứu tổng quan về Deep Learning/CNN cho phân lớp ảnh. - Đóng góp về mô hình hóa: Đưa bài toán y tế về bài toán kỹ thuật (phân lớp nhị phân). - Đóng góp về giải pháp: Đề xuất mô hình Multi-CNNs và Quy tắc kết hợp (Fusion rules). Xây dựng được bộ dữ liệu Bệnh viện An Bình. - Đóng góp về thuật toán: Đề xuất thành công kiến trúc Multi-CNNs (kết hợp mạng toàn thể và mạng cục bộ) cùng Quy tắc kết hợp FR3 (xử lý xung đột). Đây là lời giải cho bài toán làm sao giữ được độ chính xác cao khi xử lý ảnh y tế có chi tiết nhỏ. - Đóng góp về dữ liệu: Xây dựng và chuẩn hóa bộ dữ liệu AB-Chest X-rays từ Bệnh viện An Bình. Việc nhấn mạnh dữ liệu này có sự tham gia gắn nhãn của chuyên gia y tế (PGS.BS Nguyễn Hoài Nam) làm tăng giá trị tin cậy của đóng góp. - Đóng góp về ứng dụng: Hiện thực hóa mô hình trên nền tảng Web bằng thư viện ConvNetJS, chứng minh tính khả thi của việc triển khai ứng dụng hỗ trợ chẩn đoán tại các cơ sở y tế có hạ tầng phần cứng hạn chế (không cần GPU). ⇒ Cách tóm tắt này rất cô đọng, khớp hoàn toàn với phần "Mục tiêu" và "Đóng góp" đã nêu ở đầu luận văn. ❖ Thảo luận hiệu quả: Khẳng định tính khả thi qua số liệu: - Tác giả nhắc lại hai con số "đỉnh": 96% (An Bình) và 92% (Quốc tế). - Từ đó đưa ra kết luận: <i>"Qua đó cho thấy tính khả thi của mô hình đã đề xuất"</i>. - Hiệu quả triển khai: Tác giả thảo luận về tốc độ xử lý ~305ms/ảnh. Tốc độ này được khẳng định là đáp ứng tốt nhu cầu thời gian thực (real-time) của bác sĩ, không gây gián đoạn quy trình khám bệnh. - Điểm hạn chế: Phần thảo luận này hơi ngắn. Tác giả chủ yếu nhắc lại con số. Sẽ hay hơn nếu tác giả thảo luận thêm về ý nghĩa của việc <i>tại sao</i> mô hình lại khả thi (ví dụ: nhờ cơ chế fusion, nhờ tách ảnh...). Tuy nhiên, sự ngắn gọn này cũng chấp nhận được. ❖ Chỉ ra hướng phát triển trong tương lai: Đề xuất 4 hướng đi rất logic (Trang 83-84): - Kỹ thuật: <i>"Song song hóa việc phân lớp"</i> → Để giảm thời gian xử lý (từ 300ms xuống thấp hơn). Đây là tư duy tối ưu hóa hệ thống. - Dữ liệu: <i>"Thử nghiệm trên nhiều bộ dữ liệu khác"</i> → Để tăng độ ổn định (Robustness). - Nghiệp vụ Y tế (Quan trọng nhất): <i>"Phát triển bài toán cho việc phân lớp với multi-label (nhiều nhãn)"</i>. Tức là không chỉ báo "Bất thường", mà báo cụ thể là "Lao", "Viêm phổi" hay "U". Đây là bước tiến tự nhiên tiếp theo để tăng giá trị lâm sàng. - Hạ tầng: <i>"Cài đặt trên hệ thống tính toán mạnh"</i> → Để thử nghiệm các mô hình sâu hơn.	Tốt
IV	Đăng báo	❖ Số lượng và Hình thức công bố: - Minh chứng (Trang 85 & Phụ lục Trang 90-97): Tác giả đã công bố 01 bài báo khoa học tại hội nghị quốc tế: - Tên bài: <i>"Applying Multi-CNNs model for detecting abnormal problem on chest x-ray images"</i>. - Tác giả: Phat Nguyen (Tác giả chính), Hai Tran, Thai Le (GVHD), Tuan Le, Thuy Nguyen. - Năm công bố: 2018. ⇒ Tác giả là tác giả đứng đầu (First Author), chứng tỏ tác giả là người trực tiếp thực hiện chính các nội dung nghiên cứu, không phải chỉ là người phụ việc. ❖ Uy tín của nơi công bố: Hội nghị IEEE KSE (Knowledge and Systems Engineering): - Đây là Hội nghị Quốc tế lần thứ 10, được bảo trợ và xuất bản bởi IEEE (Tổ chức Kỹ sư Điện và Điện tử uy tín nhất thế giới). - Kỷ yếu hội nghị (Proceedings) của IEEE KSE thường được lập chỉ mục trong các cơ sở dữ liệu khoa học lớn như Scopus, DBLP, IEEE Xplore. - Việc vượt qua vòng phản biện (Peer-review) của một hội nghị IEEE quốc tế khó khăn hơn nhiều so với các tạp chí trong nước hoặc hội thảo nội bộ. ⇒ Đây là một địa chỉ công bố có uy tín học thuật cao, đảm bảo chất lượng của luận văn đạt chuẩn quốc tế. ❖ Sự phù hợp nội dung: Đối chiếu Luận văn và Bài báo. - Nội dung: Bài báo (Trang 90-97) trình bày chính xác mô hình Multi-CNNs và các kết quả thực nghiệm trên bộ dữ liệu An Bình/Shenzhen mà luận văn đã mô tả. - Đóng góp: Các đóng góp chính (Fusion Rules, Architecture) trong bài báo khớp hoàn toàn với Chương 3 và 4 của luận văn. ⇒ Bài báo là bản tóm tắt tinh gọn bằng tiếng Anh của luận văn, chứng minh rằng nội dung luận văn là kết quả nghiên cứu nhất quán và trung thực.	Tốt

⇒ **Kết luận:** Đây là một luận văn **tốt**